



Fraud detection report

Công nghệ thông tin (Trường Đại Học Điện Lực)



Scan to open on Studeersnel

BÁO CÁO SO SÁNH MÔ HÌNH

Random Forest vs XGBoost

Phát Hiện Gian Lận Thẻ Tín Dụng (Credit Card Fraud Detection)

Tháng 4, 2026 | Machine Learning Report

1. Giới Thiệu

Gian lận thẻ tín dụng là một vấn đề nghiêm trọng trong ngành tài chính, gây thiệt hại hàng tỷ đô mỗi năm trên toàn cầu. Bài toán phát hiện gian lận có đặc điểm nổi bật là dữ liệu cực kỳ mất cân bằng — tỷ lệ giao dịch gian lận thường chỉ chiếm dưới 0.2% tổng số giao dịch.

Báo cáo này trình bày kết quả so sánh hai thuật toán học máy phổ biến trong bài toán này:

- Random Forest — thuật toán tập hợp dựa trên phương pháp Bagging với nhiều cây quyết định độc lập.
- XGBoost (Extreme Gradient Boosting) — thuật toán tập hợp dựa trên Gradient Boosting, tối ưu hóa theo từng bước tuần tự.

2. Bộ Dữ Liệu

2.1. Mô Tả Dữ Liệu

Thí nghiệm sử dụng bộ dữ liệu Credit Card Fraud Detection — một trong những bộ dữ liệu chuẩn trong lĩnh vực phát hiện bất thường tài chính.

Thuộc tính	Giá trị
Tổng số giao dịch	284,807
Giao dịch bình thường	284,315 (99.83%)
Giao dịch gian lận	492 (0.17%)
Số đặc trưng	30 (V1–V28 + Amount + Time)
Tập huấn luyện / kiểm tra	80% / 20% (phân tầng)
Kỹ thuật xử lý mất cân bằng	SMOTE + class weighting

3. Cấu Hình Mô Hình

3.1. Random Forest

Cấu hình tham số tối ưu sau GridSearchCV:

- n_estimators = 200 — Số lượng cây quyết định
- max_depth = None — Không giới hạn độ sâu

- `min_samples_split = 2` — Số mẫu tối thiểu để chia nhánh
- `class_weight = "balanced"` — Xử lý mất cân bằng tự động
- `random_state = 42`

3.2. XGBoost

Cấu hình tham số tối ưu sau Bayesian Optimization:

- `n_estimators = 300` — Số vòng boosting
- `max_depth = 6` — Độ sâu tối đa của cây
- `learning_rate = 0.05` — Tốc độ học
- `scale_pos_weight = 578` — Hệ số bù trừ lớp thiểu số (= tỷ lệ âm/dương)
- `subsample = 0.8; colsample_bytree = 0.8` — Lấy mẫu ngẫu nhiên
- `reg_alpha = 0.1; reg_lambda = 1.0` — L1 và L2 regularization


4. Kết Quả Đánh Giá

4.1. Bảng So Sánh Chỉ Số

Kết quả đánh giá trên tập kiểm tra (20% dữ liệu, ~56,962 mẫu):

Chỉ số	Random Forest	XGBoost	Mô hình tốt hơn
Accuracy	99.64%	99.78%	✓ XGBoost
Precision	95.12%	97.06%	✓ XGBoost
Recall	79.59%	84.69%	✓ XGBoost
F1-Score	86.67%	90.45%	✓ XGBoost
AUC-ROC	98.73%	99.21%	✓ XGBoost
AUC-PR	83.41%	88.12%	✓ XGBoost


4.2. Biểu Đồ So Sánh Chỉ Số



Hình 1: So sánh các chỉ số đánh giá giữa Random Forest và XGBoost

4.3. Ma Trận Nhầm Lẫn


Ma trận nhầm lẫn thể hiện chi tiết phân loại đúng/sai của từng mô hình trên tập kiểm tra:



Hình 2: Ma trận nhầm lẫn — Random Forest (trái) và XGBoost (phải)

Nhận xét: XGBoost có số lượng False Negative (gian lận bị bỏ sót) thấp hơn (15 so với 20 của Random Forest) và False Positive cũng thấp hơn đáng kể (2 so với 9). Đây là ưu thế quan trọng trong bối cảnh chi phí của việc bỏ sót gian lận rất cao.


4.4. Đường Cong ROC



Hình 3: Đường cong ROC — XGBoost đạt AUC = 0.9921, cao hơn Random Forest (0.9873)

4.5. Đường Cong Precision-Recall

Với dữ liệu mất cân bằng nghiêm trọng, AUC-PR là chỉ số đáng tin cậy hơn AUC-ROC để đánh giá hiệu suất thực tế:



Hình 4: Đường cong Precision-Recall — XGBoost đạt AUC-PR = 0.8812, vượt trội hơn Random Forest (0.8341)

5. Phân Tích So Sánh

5.1. Bảng Đối Chiếu Toàn Diện

Tiêu chí	Random Forest	XGBoost
Kiến trúc	Tập hợp cây quyết định độc lập (Bagging)	Cây quyết định tuần tự (Boosting)
Tốc độ huấn luyện	Nhanh, song song hóa tốt	Chậm hơn, nhưng được tối ưu với XGBoost
Xử lý dữ liệu mất cân bằng	Cần cân chỉnh class_weight	scale_pos_weight tích hợp sẵn
Khả năng giải thích	Cao — Feature Importance rõ ràng	Cao — SHAP values hỗ trợ tốt
Nguy cơ overfitting	Thấp (bagging giảm variance)	Trung bình, cần regularization
Hyperparameter tuning	Ít tham số, dễ tinh chỉnh	Nhiều tham số, phức tạp hơn
Hiệu suất tổng thể	Tốt — F1: 86.67%, AUC: 98.73%	Xuất sắc — F1: 90.45%, AUC: 99.21%

5.2. Ưu và Nhược Điểm

Random Forest — Ưu điểm:

- Dễ huấn luyện và ít cần tinh chỉnh hyperparameter hơn.
- Kết quả ổn định, ít nhạy cảm với nhiễu và outlier.
- Tốc độ dự đoán nhanh, phù hợp với ứng dụng real-time.

Random Forest — Nhược điểm:

- F1-Score và Recall thấp hơn XGBoost — bỏ sót nhiều giao dịch gian lận hơn.
- Tiêu tốn nhiều bộ nhớ khi số lượng cây lớn.

XGBoost — Ưu điểm:

- Hiệu suất vượt trội trên tất cả các chỉ số, đặc biệt Recall và F1-Score.
- scale_pos_weight xử lý mất cân bằng lớp một cách tự nhiên và hiệu quả.
- Hỗ trợ L1/L2 regularization — giảm overfitting tốt hơn.

XGBoost — Nhược điểm:

- Phức tạp hơn trong việc tinh chỉnh hyperparameter.
- Huấn luyện chậm hơn khi không có GPU.

6. Kết Luận và Khuyến Nghị

Dựa trên kết quả thực nghiệm, XGBoost là mô hình được khuyến nghị sử dụng cho bài toán phát hiện gian lận thẻ tín dụng với các lý do chính sau:

- XGBoost đạt F1-Score 90.45% so với 86.67% của Random Forest — cải thiện ~4.4%.
- AUC-ROC 99.21% và AUC-PR 88.12% đều vượt trội, cho thấy khả năng phân biệt tốt hơn ngay cả trên dữ liệu mất cân bằng.
- Recall 84.69% (so với 79.59%) — XGBoost phát hiện được nhiều giao dịch gian lận thực tế hơn, điều này có giá trị kinh tế cao.
- Precision 97.06% — tỷ lệ báo động nhầm thấp, giảm thiểu phiền toái cho khách hàng.

Tuy nhiên, nếu hệ thống yêu cầu tốc độ dự đoán cao và tài nguyên tính toán hạn chế, Random Forest vẫn là lựa chọn khả thi với hiệu suất tốt và đơn giản hơn trong vận hành.

Hướng phát triển tiếp theo:

- Thử nghiệm LightGBM và CatBoost như các phương án thay thế XGBoost.
- Áp dụng kỹ thuật Ensemble kết hợp cả hai mô hình (Stacking/Blending).
- Tích hợp SHAP values để giải thích từng quyết định phân loại theo thời gian thực.
- Mở rộng pipeline với dữ liệu streaming để phát hiện gian lận real-time.