



đồ án tóm tắt văn bản với NLP

Nhập môn lập trình Web (Trường Đại học Cần Thơ)



messages.pdf_cover_qr_code_label

KUÔNG ĐẠI HỌC ABC

KHOA CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN TỐT NGHIỆP

NGÀNH: CÔNG NGHỆ THÔNG TIN

Đề tài:

PHÁT TRIỂN HỆ THỐNG TÓM TẮT BÀI BÁO TỰ ĐỘNG DỰA TRÊN MÔ HÌNH NLP

SVTH :

MSSV :

GVHD :

TP. Hà Nội – tháng 03 năm 2025

KUÔNG ĐẠI HỌC ABC
KHOA CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN TỐT NGHIỆP
NGÀNH: CÔNG NGHỆ THÔNG TIN

Đề tài:

**PHÁT TRIỂN HỆ THỐNG TÓM TẮT BÀI BÁO
TỰ ĐỘNG DỰA TRÊN MÔ HÌNH NLP**

SVTH :

MSSV :

GVHD :

TP. Hà Nội– tháng 03 năm 2025

NHẬN XÉT VÀ ĐÁNH GIÁ ĐỒ ÁN

Họ và tên người nhận xét: Học vị:



NỘI DUNG NHẬN XÉT

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Hà Nội, ngày tháng năm 2024

NGƯỜI NHẬN XÉT

.....

LỜI CAM ĐOAN

Em xin cam đoan đồ án tốt nghiệp này với đề tài là công trình thuộc quyền sở hữu duy nhất của em. Những tài liệu tham khảo được sử dụng trong khóa luận đã được trích dẫn và nêu rõ trong mục Tài liệu tham khảo. Bên cạnh đó, những kết quả nghiên cứu hoàn toàn mang tính chất trung thực, không sao chép, đạo nhái từ bất kỳ công trình nào trước đây. Nếu những lời cam đoan trên của em không chính xác, em xin chịu hoàn toàn trách nhiệm và chịu mọi hình thức kỷ luật từ khoa và nhà trường.

Hà Nội, ngày ... tháng ... năm 2025

Sinh viên thực hiện

LỜI CẢM ƠN

Để có được một đồ án tốt nghiệp chỉnh chu và đạt được kết quả tốt đẹp, em đã nhận được sự giúp đỡ, đóng góp ý kiến và sự dẫn dắt chỉ bảo nhiệt tình của thầy cô, gia đình và bạn bè. Với tình cảm sâu sắc, chân thành của mình, cho phép em được bày tỏ lòng biết ơn sâu sắc đến tất cả các mọi người đã tạo điều kiện giúp đỡ trong quá trình học tập và nghiên cứu đề tài.

Em cũng xin gửi tới các thầy cô Khoa Công nghệ thông tin - Đại học ABC lời chào trân trọng, lời chúc sức khỏe và lời cảm ơn sâu sắc nhất. Trong quá trình học tập và nghiên cứu khóa luận với sự quan tâm, dạy dỗ, chỉ bảo tận tình chu đáo của thầy cô, đến nay em đã có thể hoàn thành khóa luận của mình. Đặc biệt em xin gửi lời cảm ơn chân thành nhất tới thầy giáo – PGS.TS. ABC đã quan tâm giúp đỡ, trực tiếp hướng dẫn em hoàn thành tốt khóa luận này trong thời gian qua.

Em xin bày tỏ lòng biết ơn đến lãnh đạo Trường Đại học ABC các Khoa Phòng ban chức năng đã trực tiếp và gián tiếp giúp đỡ em trong suốt quá trình học tập và nghiên cứu đề tài. Với điều kiện thời gian cũng như kinh nghiệm còn hạn chế của một học viên, khóa luận này không thể tránh được những thiếu sót. Em rất mong nhận được sự chỉ bảo, đóng góp ý kiến của các thầy cô để em có điều kiện bổ sung, nâng cao kiến thức, tư duy của mình.

Em xin chân thành cảm ơn!

MỤC LỤC

tran

	g
DANH MỤC TỪ VIẾT TẮT.....	7
DANH MỤC HÌNH ẢNH.....	9
DANH MỤC BẢNG BIỂU.....	10
CHƯƠNG 1 : TỔNG QUAN ĐỀ TÀI.....	11
1.1. Tính cấp thiết/Lý do chọn đề tài.....	11
1.2. Mục tiêu nghiên cứu.....	11
1.3. Phạm vi ứng dụng của hệ thống.....	12
1.4. Câu hỏi nghiên cứu và giả thuyết đặt ra.....	12
1.5. Phương pháp tiếp cận và công nghệ sử dụng.....	14
1.6. Cấu trúc báo cáo.....	15
CHƯƠNG 2 : CƠ SỞ LÝ THUYẾT.....	16
2.1. Tổng quan về tóm tắt văn bản.....	16
2.1.1. Khái niệm và vai trò của tóm tắt văn bản.....	16
2.1.2. Phân loại tóm tắt văn bản.....	16
2.1.3. Các tiêu chí đánh giá chất lượng tóm tắt.....	17
2.2. Ứng dụng của NLP trong tóm tắt văn bản.....	17
2.2.1. Giới thiệu về NLP.....	17
2.2.2. Các kỹ thuật NLP quan trọng trong tóm tắt văn bản.....	17
2.3. Các công nghệ được sử dụng trong hệ thống.....	19
2.3.1. Ngôn ngữ lập trình: Python.....	19

2.3.2. Framework phát triển website: Flask.....	20
2.3.3. Thư viện NLP chính: NLTK, spaCy, Hugging Face Transformers.....	22
2.3.4. Cơ sở dữ liệu: SQLite hoặc PostgreSQL.....	22
2.3.5. Công nghệ giao diện người dùng: HTML, CSS, JavaScript.....	23
CHƯƠNG 3: XÂY DỰNG MÔ HÌNH TÓM TẮT VĂN BẢN.....	24
3.1. Kiến trúc tổng quan của hệ thống.....	24
3.1.1. Mô hình hệ thống.....	24
3.1.2. Các thành phần chính.....	24
3.1.3. Luồng xử lý dữ liệu.....	26
3.2. Xây dựng mô hình NLP cho tóm tắt văn bản.....	27
3.2.1. Tiền xử lý dữ liệu.....	27
3.2.2. Áp dụng mô hình tóm tắt văn bản.....	28
3.2.3. Tinh chỉnh mô hình và tối ưu hiệu suất.....	29
3.3. Phát triển ứng dụng web.....	29
3.3.1. Cấu trúc thư mục dự án.....	30
3.3.3. Thiết kế giao diện người dùng.....	32
3.3.4. Tích hợp frontend và backend.....	34
3.4. Chức năng tìm kiếm.....	34
3.4.1. Cách thức hoạt động của tìm kiếm.....	34
3.4.2. Triển khai thuật toán tìm kiếm.....	35
3.4.3. Tích hợp chức năng tìm kiếm vào giao diện người dùng.....	36
3.4.4. Đánh giá hiệu suất tìm kiếm.....	37
3.5. Kiểm thử hệ thống.....	37

3.5.1. Kiểm thử mô hình NLP.....	38
3.5.2. Kiểm thử ứng dụng web.....	39
CHƯƠNG 4: KẾT LUẬN TỔNG QUAN.....	42
4.1. Kết luận đồ án.....	42
4.2. Đánh giá hiệu suất hệ thống.....	43
4.3. Ứng dụng thực tế của hệ thống.....	44
4.4. Hướng phát triển trong tương lai.....	45
TÀI LIỆU THAM KHẢO.....	46

DANH MỤC TỪ VIẾT TẮT

STT	Từ viết tắt	Từ đầy đủ	Ý nghĩa chi tiết
1	AI	Artificial Intelligence	Trí tuệ nhân tạo – lĩnh vực cho phép máy móc thực hiện các tác vụ thông minh.
2	API	Application Programming Interface	Giao diện lập trình ứng dụng – cho phép giao tiếp giữa các phần mềm khác nhau.
3	BART	Bidirectional and Auto-Regressive Transformer	Mô hình sinh văn bản của Facebook, dùng trong tóm tắt và sinh ngôn ngữ.
4	BLEU	Bilingual Evaluation Understudy	Chỉ số đánh giá chất lượng bản dịch hoặc bản tóm tắt bằng so sánh ngữ nghĩa.
5	CSS	Cascading Style Sheets	Ngôn ngữ dùng để định kiểu và trình bày giao diện website.
6	DB	Database	Cơ sở dữ liệu – nơi lưu trữ thông tin có tổ chức để truy xuất và quản lý.
7	HTML	HyperText Markup Language	Ngôn ngữ đánh dấu dùng để xây dựng cấu trúc trang web.
8	JSON	JavaScript Object Notation	Định dạng lưu trữ dữ liệu dạng văn bản, thường dùng trong trao đổi dữ liệu web.
9	LSA	Latent Semantic Analysis	Phân tích ngữ nghĩa tiềm ẩn – kỹ thuật tóm tắt dựa trên giảm chiều dữ liệu.
10	LSTM	Long Short-Term Memory	Kiến trúc mạng nơ-ron dùng trong xử lý chuỗi dữ liệu thời gian dài.
11	ML	Machine Learning	Học máy – lĩnh vực cho phép máy tính học từ dữ liệu mà không cần lập trình rõ ràng.
12	NLP	Natural Language Processing	Xử lý ngôn ngữ tự nhiên – cho phép máy tính hiểu và xử lý ngôn ngữ của con người.

13	POS	Part-of-Speech	Phân loại từ loại trong câu (danh từ, động từ, tính từ...).
14	ROUGE	Recall-Oriented Understudy for Gisting Evaluation	Bộ chỉ số đánh giá mức độ trùng khớp giữa bản tóm tắt và bản gốc.
15	TF-IDF	Term Frequency – Inverse Document Frequency	Kỹ thuật đánh trọng số từ trong văn bản để xác định mức độ quan trọng.
16	UI	User Interface	Giao diện người dùng – phần hiển thị để người dùng tương tác với hệ thống.
17	UX	User Experience	Trải nghiệm người dùng – mức độ hài lòng khi sử dụng hệ thống.

DANH MỤC HÌNH ẢNH

	<i>Trang</i>
Hình 1: Các vấn đề cần giải quyết với hệ thống tóm tắt.....	15
Hình 2: Hình ảnh logo đặc trưng của ngôn ngữ Python.....	21
Hình 3: Logo nhận diện của framework Flask.....	22
Hình 4: Trực quan hóa luồng xử lý dữ liệu tóm tắt văn bản.....	29
Hình 5: Quy trình thu thập dữ liệu.....	32
Hình 6: Hiển thị kết quả tóm tắt.....	37
Hình 7: Tùy chỉnh các tham số tóm tắt.....	38
Hình 8: Giao diện chức năng tìm kiếm dữ liệu.....	41
Hình 9: Kết quả tìm kiếm trả về 10 kết quả có tỉ lệ chính xác cao nhất.....	42
Hình 10: Kết quả tổng quan độ chính xác của mô hình.....	48

DANH MỤC BẢNG BIỂU

	<i>Trang</i>
Bảng 1: Bảng tiêu chí đánh giá chất lượng tóm tắt.....	17
Bảng 2: Ưu nhược điểm của python.....	20
Bảng 3: Ưu nhược điểm của framework Flask.....	21
Bảng 4: Bảng so sánh SQLite và PostgreSQL.....	22
Bảng 5: Bảng các tiêu chí đánh giá hiệu suất tìm kiếm.....	37
Bảng 6: Bảng kết quả kiểm thử mô hình NLP bằng ROUGE.....	38
Bảng 7: Bảng kết quả kiểm thử mô hình NLP bằng BLEU.....	38
Bảng 8: Bảng kết quả kiểm thử quy trình.....	40
Bảng 9: Bảng kết quả kiểm thử giao diện.....	40
Bảng 10: Bảng các ứng dụng thực tế của website.....	44
Bảng 11: Các hướng phát triển của đề tài.....	45

CHƯƠNG 1 : TỔNG QUAN ĐỀ TÀI

1.1. Tính cấp thiết/Lý do chọn đề tài

Trong thời đại công nghệ thông tin phát triển mạnh mẽ, lượng thông tin trên Internet ngày càng gia tăng với tốc độ chóng mặt, đặc biệt là thông qua các bài báo điện tử. Việc người dùng cần tiếp cận thông tin một cách nhanh chóng, chính xác và hiệu quả trở nên hết sức quan trọng. Tuy nhiên không phải lúc nào người dùng cũng có đủ thời gian để đọc hết toàn bộ nội dung bài viết. Do đó nhu cầu về một hệ thống có khả năng tóm tắt nội dung tự động trở nên cấp thiết.

Em nhận thấy sự phát triển của lĩnh vực xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP) đã mở ra nhiều hướng đi mới trong việc phân tích và hiểu nội dung văn bản một cách tự động. Ứng dụng các mô hình NLP hiện đại vào việc tóm tắt văn bản không chỉ giúp rút ngắn thời gian tiếp cận thông tin, mà còn mang lại hiệu quả cao trong việc phân loại và lưu trữ dữ liệu.

Chính vì vậy, việc phát triển một hệ thống tóm tắt bài báo tự động dựa trên mô hình NLP là cần thiết, góp phần giải quyết vấn đề quá tải thông tin, hỗ trợ người dùng tiếp cận tri thức nhanh chóng và hiệu quả hơn. Thông qua đó giúp em có được thêm nhiều kinh nghiệm thực tiễn trong xử lý ngôn ngữ tự nhiên và biết cách tạo ra một ứng dụng nhằm đáp ứng nhu cầu. Với đề tài “phát triển hệ thống tóm tắt bài báo tự động dựa trên mô hình NLP” em hi vọng có thể giúp ích cho người dùng với công dụng tóm tắt lượng thông tin mà họ muốn tiếp cận một cách nhanh chóng và dễ hiểu hơn.

1.2. Mục tiêu nghiên cứu

Mục tiêu chính đề tài của em hướng đến là thiết kế và xây dựng một hệ thống có khả năng tự động tóm tắt nội dung bài báo dựa trên các kỹ thuật và mô hình xử lý ngôn ngữ tự nhiên hiện đại. Hệ thống không chỉ hỗ trợ người dùng đọc nhanh bài viết mà còn tạo ra trải nghiệm tương tác tiện lợi, thân thiện thông qua giao diện web.

Cụ thể, đề tài tập trung vào các mục tiêu sau:

1. Xây dựng một module thu thập dữ liệu tự động từ các trang báo điện tử, đảm bảo dữ liệu đầu vào đa dạng và thực tế.
2. Phát triển mô hình tóm tắt văn bản có khả năng hiểu nội dung và tái cấu trúc thông tin ngắn gọn mà vẫn giữ được ý chính.
3. Thiết kế giao diện người dùng thân thiện, dễ sử dụng, cho phép người dùng thao tác với hệ thống một cách trực quan.
4. Đảm bảo hệ thống hoạt động hiệu quả, xử lý nhanh, phù hợp với nhu cầu sử dụng thực tế.
5. Đánh giá hiệu quả mô hình tóm tắt thông qua các chỉ số và phản hồi người dùng

1.3. Phạm vi ứng dụng của hệ thống

Hệ thống tóm tắt bài báo tự động được xây dựng trong khuôn khổ đề tài này có thể được ứng dụng rộng rãi trong nhiều lĩnh vực. Trước hết, đối với người dùng cá nhân, hệ thống sẽ là một công cụ hỗ trợ đắc lực trong việc đọc báo nhanh, giúp tiết kiệm thời gian mà vẫn nắm được nội dung cốt lõi của bài viết.

Trong lĩnh vực báo chí, truyền thông, hệ thống của em có thể hỗ trợ phóng viên và biên tập viên trong quá trình xử lý tin tức, chọn lọc và phân tích nội dung. Trong giáo dục, sinh viên và giảng viên có thể sử dụng hệ thống để tóm lược các bài đọc dài, hỗ trợ học tập và nghiên cứu.

Ngoài ra hệ thống còn có thể được tích hợp vào các thư viện số, nền tảng học trực tuyến, công cụ tìm kiếm tri thức hoặc hệ thống hỗ trợ ra quyết định trong doanh nghiệp. Nhìn chung em nhận thấy rằng hệ thống này có tiềm năng ứng dụng cao trong mọi lĩnh vực cần xử lý lượng lớn văn bản

1.4. Câu hỏi nghiên cứu và giả thuyết đặt ra

Trong quá trình thực hiện đề tài, em đã đặt ra một số câu hỏi trọng tâm để định hướng và đánh giá hiệu quả của hệ thống:

- Liệu có thể xây dựng một hệ thống có khả năng tóm tắt bài báo tự động với độ chính xác cao và tính ứng dụng thực tiễn?
- Mô hình xử lý ngôn ngữ tự nhiên nào là phù hợp và hiệu quả nhất cho nhiệm vụ tóm tắt văn bản tiếng Việt?
- Làm thế nào để hệ thống hoạt động ổn định và dễ sử dụng đối với người dùng không chuyên về công nghệ?



Hình 1: Các vấn đề cần giải quyết với hệ thống tóm tắt

Từ những câu hỏi bên trên và những vấn đề nhược điểm phát sinh, em đặt ra các giả thuyết như sau :

- Các mô hình học sâu, đặc biệt là các mô hình học chuyển giao (transfer learning) như BERT, T5 hoặc BART, có khả năng tạo ra bản tóm tắt chất lượng cao, gần sát với ngữ nghĩa của bài viết gốc.
- Với dữ liệu được thu thập tự động và tiền xử lý hợp lý, mô hình sẽ đạt hiệu quả tốt trong môi trường thực tế.
- Giao diện đơn giản, dễ tiếp cận sẽ giúp tăng khả năng ứng dụng hệ thống đối với người dùng phổ thông

1.5. Phương pháp tiếp cận và công nghệ sử dụng

Để đạt được các mục tiêu đặt ra, em lựa chọn phương pháp tiếp cận từ dưới lên, bắt đầu từ việc xây dựng hệ thống thu thập dữ liệu, xử lý văn bản, huấn luyện mô hình tóm tắt và cuối cùng là tích hợp với giao diện người dùng.

Quá trình triển khai bao gồm các bước chính sau:

1. Thu thập dữ liệu: Sử dụng ngôn ngữ Python kết hợp với các thư viện như requests, BeautifulSoup để crawl dữ liệu bài báo từ các trang tin tức điện tử.
2. Tiền xử lý dữ liệu: Làm sạch nội dung, chuẩn hóa văn bản, loại bỏ ký tự dư thừa, phân tách câu và chuẩn bị dữ liệu cho mô hình học máy.
3. Phát triển mô hình tóm tắt: Áp dụng các mô hình học máy hiện đại, đặc biệt là mô hình học sâu tiền huấn luyện (pre-trained models) từ thư viện transformers, ví dụ như BART hoặc T5, được tinh chỉnh (fine-tuning) để phù hợp với dữ liệu tiếng Việt.
4. Xây dựng giao diện người dùng: Sử dụng Flask để xây dựng một ứng dụng web đơn giản, nơi người dùng có thể nhập link bài báo hoặc văn bản, sau đó nhận lại bản tóm tắt tương ứng.

Công nghệ sử dụng bao gồm: Python, Flask, BeautifulSoup, transformers, cùng một số thư viện hỗ trợ như nltk, spaCy và scikit-learn

1.6. Cấu trúc báo cáo

Báo cáo đồ án của em được tổ chức thành bốn chương, trình bày toàn bộ quá trình nghiên cứu, thiết kế, xây dựng và đánh giá hệ thống tóm tắt bài báo tự động.

Chương 1: Tổng quan đề tài

Chương này em giới thiệu bối cảnh thực tế, tính cấp thiết và lý do chọn đề tài. Đồng thời trình bày mục tiêu nghiên cứu, phạm vi ứng dụng của hệ thống, các câu hỏi và giả thuyết nghiên cứu, phương pháp tiếp cận, công nghệ sử dụng và cấu trúc tổng thể của báo cáo.

Chương 2: Cơ sở lý thuyết

Chương này em sẽ cung cấp nền tảng kiến thức lý thuyết liên quan đến bài toán tóm tắt văn bản. Nội dung bao gồm khái niệm, vai trò, các phương pháp tóm tắt (trích xuất và sinh văn bản), các tiêu chí đánh giá chất lượng, ứng dụng của NLP trong lĩnh vực này, cùng với các kỹ thuật và công nghệ được sử dụng trong hệ thống.

Chương 3: Xây dựng mô hình tóm tắt văn bản

Đây là chương trọng tâm của báo cáo, trình bày chi tiết quá trình xây dựng hệ thống từ việc thiết kế kiến trúc tổng quan, xử lý dữ liệu, phát triển mô hình NLP, đến phát triển ứng dụng web và tích hợp giao diện người dùng. Ngoài ra, chương này còn đề cập đến chức năng tìm kiếm nội dung theo từ khóa và kiểm thử toàn bộ hệ thống để đảm bảo tính ổn định và hiệu quả.

Chương 4: Kết luận tổng quan

Chương cuối cùng tổng kết lại kết quả đã đạt được trong suốt quá trình nghiên cứu và triển khai đề tài. Nội dung bao gồm đánh giá hiệu suất hệ thống, khả năng ứng dụng thực tế, cũng như định hướng phát triển trong tương lai, từ việc cải tiến thuật toán đến mở rộng hệ thống trên nền tảng đa ngôn ngữ và cloud computing

CHƯƠNG 2 : CƠ SỞ LÝ THUYẾT

2.1. Tổng quan về tóm tắt văn bản

2.1.1. Khái niệm và vai trò của tóm tắt văn bản

Tóm tắt văn bản là quá trình rút gọn nội dung một đoạn văn bản dài thành một bản tóm lược ngắn hơn, đồng thời vẫn giữ lại được những thông tin quan trọng, nội dung chính và ý nghĩa cốt lõi của văn bản gốc. Mục tiêu của việc tóm tắt không chỉ là làm giảm số lượng từ, mà còn giúp người đọc nhanh chóng nắm bắt được nội dung mà không cần phải đọc toàn bộ văn bản.

Tóm tắt văn bản đóng vai trò thiết yếu trong nhiều lĩnh vực như báo chí, giáo dục, nghiên cứu khoa học và công nghệ. Với sự phát triển nhanh chóng của kho dữ liệu số, người dùng phải tiếp cận một khối lượng lớn thông tin mỗi ngày. Do đó, khả năng tạo ra bản tóm tắt tự động giúp tiết kiệm thời gian, nâng cao hiệu quả đọc hiểu và cải thiện khả năng xử lý thông tin.

2.1.2. Phân loại tóm tắt văn bản

Theo như em tìm hiểu tài liệu cũng như các dự án khác sử dụng chức năng tóm tắt tương tự thì tóm tắt văn bản thường được chia thành hai phương pháp chính như sau:

Tóm tắt trích xuất (Extractive Summarization):

Phương pháp này chọn ra những câu hoặc đoạn văn quan trọng nhất trong văn bản gốc và ghép lại để tạo thành bản tóm tắt. Các thuật toán trích xuất thường dựa trên các tiêu chí như tần suất từ khóa, độ quan trọng của câu hoặc vị trí xuất hiện trong văn bản. Tuy nhiên, vì bản tóm tắt chỉ là tập hợp các câu gốc nên đôi khi thiếu sự mượt mà, tự nhiên trong cách diễn đạt.

Tóm tắt sinh văn bản (Abstractive Summarization):

Khác với phương pháp trích xuất, phương pháp này sử dụng mô hình học máy để hiểu và tái diễn đạt nội dung văn bản. Mô hình sẽ học cách viết lại nội dung theo phong cách mới, sử dụng từ ngữ khác với bản gốc nhưng vẫn giữ nguyên ý nghĩa. Phương pháp

này có khả năng tạo ra các bản tóm tắt mượt mà, tự nhiên hơn, nhưng đòi hỏi tài nguyên tính toán lớn và dữ liệu huấn luyện chất lượng cao

2.1.3. Các tiêu chí đánh giá chất lượng tóm tắt

Chất lượng của bản tóm tắt văn bản thường được đánh giá dựa trên các tiêu chí sau

Bảng 1: Bảng tiêu chí đánh giá chất lượng tóm tắt

STT	Tiêu chí đánh giá	Nội dung chi tiết
1	Tính đầy đủ (Coverage)	Bản tóm tắt phải bao quát được những nội dung quan trọng nhất của văn bản gốc.
2	Tính chính xác (Accuracy)	Nội dung tóm tắt không được làm sai lệch thông tin so với văn bản gốc
3	Tính mạch lạc (Coherence)	Các câu trong bản tóm tắt cần liên kết logic và dễ hiểu.
4	Tính ngắn gọn (Conciseness)	Bản tóm tắt nên có độ dài vừa phải, tránh lan man hoặc dư thừa thông tin
5	Độ tự nhiên trong ngôn ngữ	Đặc biệt quan trọng với tóm tắt sinh văn bản, giúp bản tóm tắt trở nên giống như được viết bởi con người

2.2. Ứng dụng của NLP trong tóm tắt văn bản

2.2.1. Giới thiệu về NLP

Xử lý ngôn ngữ tự nhiên (Natural Language Processing – NLP) là một nhánh của trí tuệ nhân tạo (AI) tập trung vào việc cho phép máy tính hiểu, diễn giải và tạo ra ngôn ngữ của con người một cách tự động. NLP kết hợp giữa ngôn ngữ học và khoa học máy tính để xử lý các dữ liệu văn bản hoặc giọng nói theo cách mà máy tính có thể hiểu được.

Trong bài toán tóm tắt văn bản của em, NLP giữ vai trò trung tâm, giúp hệ thống có thể phân tích ngữ nghĩa, ngữ pháp và cấu trúc của văn bản để từ đó lựa chọn hoặc tạo ra một bản tóm tắt phù hợp với mục tiêu

2.2.2. Các kỹ thuật NLP quan trọng trong tóm tắt văn bản

Để tìm hiểu sâu hơn tại sao NLP lại có thể xử lý ngôn ngữ tự nhiên, em đã nghiên cứu và nhận ra các kỹ thuật quan trọng trong NLP để có thể tóm tắt văn bản một cách

chính xác và nhanh gọn nhất, em xin trình bày chi tiết các lý thuyết về các kỹ thuật đó như sau:

1. Tiền xử lý văn bản (Text Preprocessing)

Quy trình này sẽ bao gồm các bước như chuyển về chữ thường (lowercase), loại bỏ dấu câu, ký tự đặc biệt, từ dừng (stopwords), tách từ (tokenization), và chuẩn hóa từ (stemming, lemmatization). Việc tiền xử lý đúng cách giúp giảm nhiễu và cải thiện chất lượng đầu vào cho mô hình

2. Biểu diễn văn bản (Word Embeddings, TF-IDF, BERT Embeddings)

Một văn bản cần được chuyển đổi sang dạng mà máy tính có thể xử lý. Các phương pháp phổ biến bao gồm:

- TF-IDF: Đo lường mức độ quan trọng của từ dựa trên tần suất xuất hiện trong văn bản.
- Word Embeddings (Word2Vec, GloVe): Mã hóa từ thành vector số dựa trên ngữ cảnh xuất hiện.
- BERT Embeddings: Mô hình biểu diễn ngữ nghĩa từ cấp độ ngữ cảnh mạnh mẽ, sử dụng kiến trúc transformer, phù hợp với các mô hình tóm tắt hiện đại

3. Mô hình xếp hạng câu quan trọng (TextRank, TF-IDF)

Mô hình này sẽ được dùng trong tóm tắt trích xuất để xác định câu nào là “quan trọng” và nên đưa vào bản tóm tắt. Một số thuật toán phổ biến là:

- TextRank: Mô hình dựa trên PageRank để đánh giá độ quan trọng của câu.
- TF-IDF kết hợp cosine similarity: Xác định độ tương đồng giữa các câu với tiêu đề hoặc nội dung trọng tâm

4. Mô hình sinh văn bản (Transformer, GPT, BART, T5, Pegasus)

Là các mô hình giúp tạo ra văn bản sau khi đã thực hiện các bước trên, nó sẽ trả về kết quả cuối cùng một cách chi tiết và đầy đủ nhất. Các mô hình hiện đại có thể kể đến như:

- Transformer: Kiến trúc nền tảng cho các mô hình sinh ngôn ngữ hiện đại.

- GPT: Mô hình dự đoán ngôn ngữ tự động, phù hợp với sinh văn bản.
- BART, T5, Pegasus: Là các mô hình transformer đặc biệt được huấn luyện để tóm tắt văn bản với hiệu quả cao

2.3. Các công nghệ được sử dụng trong hệ thống

Trong quá trình phát triển hệ thống tóm tắt bài báo tự động, em đã tìm hiểu và lựa chọn kết hợp nhiều công nghệ khác nhau để đảm bảo tính linh hoạt, hiệu suất và khả năng triển khai thực tế của sản phẩm. Việc lựa chọn công nghệ không chỉ dựa trên xu hướng phổ biến mà còn căn cứ vào tính phù hợp với yêu cầu kỹ thuật và quy mô của đề tài, em xin phép giới thiệu và đưa ra lý do sử dụng chúng để hoàn thiện đồ án như sau

2.3.1. Ngôn ngữ lập trình: Python

Lý do lựa chọn:

Không cần phải nói nhiều về độ phổ biến cũng như những tính năng ưu việt của Python. Đây là một ngôn ngữ lập trình cấp cao, hướng đối tượng, nổi bật với cú pháp đơn giản, dễ đọc và dễ học. Đặc biệt, Python có một hệ sinh thái rất mạnh trong lĩnh vực trí tuệ nhân tạo (AI) và xử lý ngôn ngữ tự nhiên (NLP), là lựa chọn hàng đầu cho các dự án nghiên cứu và ứng dụng AI hiện nay



Hình 2: Hình ảnh logo đặc trưng của ngôn ngữ Python

Bảng 2: Ưu nhược điểm của python

Ưu điểm	Nhược điểm
1. Có nhiều thư viện mạnh hỗ trợ NLP như NLTK, spaCy, transformers. 2. Cộng đồng lớn, tài liệu phong phú, dễ tìm kiếm giải pháp khi gặp lỗi. 3. Dễ tích hợp với các công cụ web, cơ sở dữ liệu, và mô hình học máy. 4. Mã nguồn ngắn gọn, dễ phát triển và bảo trì	1. Hiệu suất tính toán không cao bằng các ngôn ngữ biên dịch như C++ hoặc Java. 2. Không tối ưu cho các hệ thống yêu cầu xử lý song song ở cấp thấp hoặc real-time cao

Với tính đơn giản, mạnh mẽ và phù hợp với các thư viện AI hiện có, Python là lựa chọn tối ưu cho đề tài này của em, đặc biệt khi trọng tâm là xử lý và mô phỏng ngôn ngữ tự nhiên

2.3.2. Framework phát triển website: Flask

Flask là một micro-framework được phát triển bằng Python, thường dùng để xây dựng các ứng dụng web nhỏ đến trung bình. Khác với các framework "nặng" như Django, Flask cung cấp sự linh hoạt cao, cho phép nhà phát triển toàn quyền kiểm soát cấu trúc và thành phần của hệ thống



Hình 3: Logo nhận diện của framework Flask

Bảng 3: Ưu nhược điểm của framework Flask

Ưu điểm	Nhược điểm
1. Nhẹ, linh hoạt: Cho phép triển khai ứng dụng nhanh, dễ kết nối với mô hình NLP. 2. Cấu hình đơn giản: Không bị ràng buộc bởi các quy tắc nghiêm ngặt như Django. 3. Tích hợp tốt với mô hình AI/NLP: Dễ dàng nhúng mô hình học máy vào backend. 4. Thư viện mở rộng đa dạng: Có thể kết hợp với nhiều plugin như Flask-RESTful, Flask-SQLAlchemy, Jinja2	1. Không phù hợp với các dự án lớn yêu cầu phân quyền phức tạp hoặc hệ thống nhiều tầng. 2. Phải tự triển khai nhiều tính năng (admin panel, auth) nếu cần, không có sẵn như Django

So sánh với các framework khác để đưa ra lý do tại sao em lại ưu tiên sử dụng flask để phát triển dự án tóm tắt văn bản này. Với quy mô dự án nhỏ đến trung bình và yêu cầu tích hợp trực tiếp mô hình NLP, Flask là lựa chọn phù hợp nhất cho hệ thống tóm tắt văn bản

Framework	Ưu điểm	Nhược điểm
Django	Hệ sinh thái đầy đủ, có sẵn ORM, admin, auth	Cồng kềnh, ít linh hoạt với API nhỏ
FastAPI	Rất nhanh, hỗ trợ async, dùng cho API hiện đại	Mới hơn, cộng đồng nhỏ hơn
Flask	Linh hoạt, gọn nhẹ, dễ tích hợp mô hình NLP	Thiếu tính năng mặc định, phải tự cấu hình nhiều thứ

2.3.3. Thư viện NLP chính: NLTK, spaCy, Hugging Face Transformers

Đây là 3 thư viện hỗ trợ xử lý NLP rất phổ biến. Kết hợp ba thư viện này cho phép tận dụng ưu điểm của từng công cụ trong các giai đoạn khác nhau của xử lý ngôn ngữ tự nhiên: từ tiền xử lý văn bản đến xây dựng và áp dụng mô hình học sâu, em xin trình bày chi tiết hơn về 3 thư viện này

Thư viện	Chức năng chính	Ưu điểm	Nhược điểm
NLTK	Tiền xử lý văn bản, stemming, stopwords	Đầy đủ chức năng cơ bản, dễ dùng	Tốc độ xử lý chậm, không tối ưu cho dự án lớn
spaCy	Tokenization, POS tagging, NER	Tốc độ nhanh, hiệu năng cao, dễ tích hợp	Thiếu vài tính năng nâng cao so với NLTK
Transformers (Hugging Face)	Mô hình tóm tắt hiện đại (T5, BART, Pegasus)	Cập nhật liên tục, dễ dùng, hiệu quả cao	Nặng tải nguyên, yêu cầu GPU khi huấn luyện

2.3.4. Cơ sở dữ liệu: SQLite hoặc PostgreSQL

Tuỳ theo môi trường triển khai, em sử dụng SQLite trong quá trình phát triển và kiểm thử cục bộ, và có thể nâng cấp lên PostgreSQL nếu triển khai hệ thống ở quy mô lớn hơn. Hiện tại dự án của em chỉ sử dụng Json để lưu trữ các dữ liệu khi thu thập từ các trang báo về, tuy nhiên em hướng tới sau này sẽ tự động thu thập dữ liệu và lưu trữ chúng vào database nhằm hướng tới phát triển một cách quy mô hơn, em cũng đã tìm hiểu qua 2 cơ sở dữ liệu để lưu trữ là SQLite và PostgreSQL và nhận thấy chúng có các đặc điểm như sau

Bảng 4: Bảng so sánh SQLite và PostgreSQL

CSDL	Ưu điểm	Nhược điểm	Phù hợp với
SQLite	Nhẹ, không cần cài đặt server, dễ tích hợp với	Không phù hợp với hệ thống nhiều người	Phát triển thử nghiệm, ứng dụng đơn giản

	Flask	dùng	
PostgreSQL	Mạnh mẽ, mở rộng tốt, hỗ trợ tìm kiếm full-text	Cài đặt phức tạp hơn, cần quản lý server	Hệ thống có người dùng thực tế, nhiều truy vấn


Từ những đặc điểm như trên, em nhận thấy rằng SQLite được sử dụng trong giai đoạn đầu vì sự tiện lợi, và có thể chuyển sang PostgreSQL nếu hệ thống cần mở rộng và lưu trữ lượng lớn dữ liệu bài viết và người dùng

2.3.5. Công nghệ giao diện người dùng: HTML, CSS, JavaScript

Lý do lựa chọn:

Với quy mô đề tài và yêu cầu cơ bản về giao diện đầu vào và kết quả tóm tắt, việc sử dụng HTML, CSS và JavaScript là phù hợp, dễ triển khai và đáp ứng đúng yêu cầu. Đây là bộ công nghệ tiêu chuẩn cho phát triển giao diện web, đảm bảo tính tương thích cao với tất cả trình duyệt, dễ triển khai và kiểm thử.

- HTML: Xây dựng cấu trúc trang.
- CSS: Thiết kế giao diện, tùy chỉnh bố cục, màu sắc, font chữ.
- JavaScript: Tạo tương tác động, xử lý hành vi của người dùng như gửi form, hiển thị kết quả tóm tắt mà không cần tải lại trang



CHƯƠNG 3: XÂY DỰNG MÔ HÌNH TÓM TẮT VĂN BẢN

3.1. Kiến trúc tổng quan của hệ thống

3.1.1. Mô hình hệ thống

Hệ thống tóm tắt văn bản được em thiết kế theo mô hình ba lớp (three-tier architecture), gồm ba thành phần chính: lớp giao diện người dùng (frontend), lớp xử lý nghiệp vụ (backend), và lớp lưu trữ dữ liệu (database). Mô hình này đảm bảo tính phân tách rõ ràng giữa giao diện, logic xử lý và dữ liệu, giúp hệ thống dễ bảo trì, mở rộng và tái sử dụng trong tương lai.

Cụ thể, kiến trúc hệ thống được mô tả như sau:

- Người dùng tương tác với giao diện web để nhập nội dung văn bản hoặc đường dẫn bài báo.
- Yêu cầu được gửi đến máy chủ (Flask API), nơi mô hình NLP sẽ tiến hành xử lý và sinh ra bản tóm tắt.
- Kết quả được trả về và hiển thị trực tiếp trên giao diện người dùng.
- Dữ liệu văn bản và bản tóm tắt có thể được lưu trữ vào cơ sở dữ liệu để phục vụ tra cứu hoặc phân tích sau này.

3.1.2. Các thành phần chính

Hệ thống tóm tắt bài báo tự động bao gồm các thành phần chính sau đây, mỗi thành phần đảm nhận một vai trò riêng biệt nhưng phối hợp chặt chẽ để hoàn thiện quy trình xử lý văn bản, em xin trình bày như sau

1. Giao diện người dùng (Frontend)

Được em xây dựng bằng HTML, CSS và JavaScript, giao diện của hệ thống cho phép người dùng dễ dàng thao tác với hệ thống qua trình duyệt web. Người dùng có thể nhập văn bản, chọn kiểu tóm tắt (trích xuất hoặc sinh văn bản), tùy chỉnh độ dài bản tóm tắt và xem kết quả ngay sau khi xử lý. Giao diện sẽ đơn giản, trực quan nhằm hướng đến người dùng phổ thông, không yêu cầu kiến thức kỹ thuật chuyên sâu

2. Backend (Xử lý nghiệp vụ)

Lỗi xử lý của hệ thống được xây dựng bằng Flask – một framework nhẹ của Python. Flask chịu trách nhiệm nhận yêu cầu từ người dùng, xử lý logic nghiệp vụ, gọi đến các mô hình NLP và trả về kết quả cho giao diện người dùng.

Tại đây, Flask hoạt động như một API RESTful, đóng vai trò trung gian giữa giao diện người dùng và mô hình xử lý văn bản.

3. Mô hình NLP (Tóm tắt văn bản)

Hệ thống hiện tại hỗ trợ hai hướng tiếp cận:

- TextRank cho tóm tắt trích xuất: Áp dụng thuật toán xếp hạng câu dựa trên độ quan trọng và liên kết giữa các câu.
- Transformer (ví dụ: T5 hoặc BART) cho tóm tắt sinh văn bản: Sử dụng mô hình học sâu để tái diễn đạt nội dung một cách tự nhiên, ngắn gọn và logic.

Các mô hình này được triển khai thông qua thư viện transformers của Hugging Face, giúp dễ dàng tích hợp và mở rộng về sau.

4. Kho dữ liệu văn bản (Dạng file JSON)

Dữ liệu đầu vào của hệ thống của em là các bài báo được thu thập tự động bởi module crawler.py. Sau quá trình crawl, dữ liệu được lưu thành từng file .json, mỗi file chứa nội dung và metadata của một bài báo.

Mặc dù không sử dụng cơ sở dữ liệu quan hệ (như SQLite hay PostgreSQL), nhưng hệ thống vẫn truy xuất dữ liệu từ tập tin .json này như một dạng cơ sở dữ liệu phi quan hệ tĩnh, đủ phục vụ cho mục đích tìm kiếm, thử nghiệm và phát triển. Sau này khi phát triển hơn em sẽ lưu trữ chúng vào các hệ quản trị cơ sở dữ liệu

5. Chức năng tìm kiếm nội dung

Hệ thống còn được tích hợp khả năng tìm kiếm theo từ khóa trong văn bản gốc hoặc bản tóm tắt. Đây là chức năng giúp nâng cao trải nghiệm người dùng, đặc biệt trong trường hợp muốn tra cứu thông tin cụ thể từ tập dữ liệu đã thu thập. Cơ chế tìm kiếm của em dựa trên các kỹ thuật như TF-IDF, có thể nâng cấp lên dùng Elasticsearch hoặc Whoosh khi mở rộng quy mô hệ thống

3.1.3. Luồng xử lý dữ liệu

Luồng xử lý dữ liệu trong hệ thống được thiết kế đơn giản nhưng hiệu quả, đảm bảo người dùng có thể nhận được kết quả tóm tắt chỉ sau vài thao tác cơ bản. Dưới đây là trình tự các bước hoạt động chính:

Bước 1: Người dùng nhập dữ liệu

Người dùng có thể nhập trực tiếp văn bản cần tóm tắt thông qua giao diện web, hoặc lựa chọn từ danh sách các bài báo đã được crawler thu thập và lưu dưới dạng .json.

Bước 2: Tiền xử lý văn bản

Trước khi đưa văn bản vào mô hình NLP, hệ thống tiến hành các bước tiền xử lý:

- Chuyển tất cả chữ về dạng viết thường.
- Loại bỏ ký tự đặc biệt, dấu câu và các từ dừng (stopwords).
- Tách câu và token hóa (tokenization).
- Áp dụng lemmatization hoặc stemming tùy mô hình được chọn.

Quá trình này giúp làm sạch dữ liệu và tối ưu hóa hiệu quả của mô hình phía sau.

Bước 3: Áp dụng mô hình tóm tắt

Tùy theo lựa chọn của người dùng, hệ thống sẽ thực thi:


- TextRank để chọn ra những câu quan trọng nhất trong văn bản và ghép lại thành bản tóm tắt.
- Transformer như BART hoặc T5 để sinh ra bản tóm tắt hoàn toàn mới bằng cách hiểu và tái diễn đạt nội dung.

Bước 4: Trả kết quả và hiển thị

Sau khi hoàn tất quá trình tóm tắt, kết quả sẽ được trả về và hiển thị trực tiếp lên giao diện người dùng. Người dùng có thể so sánh với văn bản gốc hoặc thực hiện lại với đoạn văn khác.

Bước 5: (Tùy chọn) Tìm kiếm theo từ khóa

Nếu người dùng sử dụng chức năng tìm kiếm, hệ thống sẽ phân tích nội dung các file .json hiện có để tìm ra đoạn văn bản (hoặc tóm tắt) có chứa từ khóa cần tìm, và hiển thị kết quả phù hợp.



Hình 4: Trực quan hóa luồng xử lý dữ liệu tóm tắt văn bản

3.2. Thu thập dữ liệu

Trong các hệ thống xử lý ngôn ngữ tự nhiên (NLP), chất lượng dữ liệu đầu vào có ảnh hưởng rất lớn đến hiệu quả xử lý và kết quả đầu ra của mô hình. Việc xây dựng một tập dữ liệu có nội dung thực tế, đầy đủ và chuẩn hóa là yêu cầu thiết yếu để đảm bảo độ chính xác cho các tác vụ như phân tích, trích xuất thông tin hay tóm tắt văn bản.

Đối với đề tài này, dữ liệu được em thu thập từ một trang báo điện tử thông dụng ở Việt Nam thông qua kỹ thuật web scraping – một phương pháp phổ biến trong việc khai thác dữ liệu từ các trang web

3.2.1. Mục tiêu và yêu cầu dữ liệu

Dữ liệu thu thập phục vụ cho hai mục đích chính:

- Cung cấp đầu vào để thử nghiệm các mô hình tóm tắt văn bản (trích xuất và sinh văn bản).

- Làm kho dữ liệu phục vụ tính năng tìm kiếm từ khóa trong nội dung hoặc bản tóm tắt.

Để đảm bảo phù hợp với bài toán, dữ liệu cần thỏa mãn các tiêu chí:

- Ngôn ngữ tiếng Việt chuẩn, phong cách trình bày mạch lạc.
- Cấu trúc bài báo rõ ràng, có tiêu đề và nội dung chính.
- Có metadata như ngày xuất bản, chuyên mục, tác giả (nếu có).
- Nội dung đủ dài và giàu thông tin để áp dụng các mô hình tóm tắt

3.2.1. Phương pháp thu thập dữ liệu: Web Scraping

Web scraping là quá trình tự động truy cập và trích xuất dữ liệu từ các trang web bằng cách phân tích cấu trúc HTML của chúng. Phương pháp này thường sử dụng các thư viện như `requests`, `BeautifulSoup` (Python), giúp mô phỏng hành vi của người dùng để truy cập, duyệt và lấy thông tin từ website.

Trong dự án này, dữ liệu của em được thu thập từ tất cả chuyên mục của trang báo điện tử Tuổi Trẻ Online – một trong những tờ báo uy tín, với nội dung phong phú, ngôn ngữ chính thống và cập nhật liên tục

Cấu trúc website và lựa chọn chuyên mục

Mỗi bài viết trong chuyên mục có các trường cần trích xuất:

1. title: tiêu đề bài báo
2. content: nội dung bài viết (các đoạn <p>)
3. author: tên tác giả (nếu có)
4. date: ngày xuất bản bài viết
5. category: chuyên mục

3.2.4. Quy trình thu thập dữ liệu

Quy trình được chia thành 4 bước chính như sau:

Bước 1: Gửi yêu cầu đến trang chuyên mục

Hàm `get_all_posts_from_category()` duyệt qua tối đa 100 trang của chuyên mục, tạo các liên kết phân trang bằng cách thêm hậu tố `/trang-{page}.htm`.

Bước 2: Trích xuất liên kết bài viết

Sử dụng BeautifulSoup để phân tích HTML và tìm các thẻ chứa đường dẫn bài viết (selector `.box-category-link-title`). Mỗi liên kết được chuyển thành URL đầy đủ thông qua `urljoin`.

Bước 3: Truy cập từng bài viết và lấy nội dung

Hàm `extract_post_details()` thực hiện việc:

- Tải HTML bài viết.
- Tìm các meta tag chứa title, author, date, category.
- Trích xuất nội dung từ thẻ `<div class="detail-content">`.
- Mã hóa URL thành postId bằng thuật toán MD5 để tránh trùng lặp.


Bước 4: Lưu dữ liệu dưới dạng JSON

Hàm `save_post_data()` lưu mỗi bài viết dưới dạng một file `.json` riêng biệt với định dạng chuẩn, lưu trong thư mục `data/`

Kết quả thu thập

Sau khi chạy script `crawler.py`, hệ thống thu thập được số liệu như sau:

- Tổng số bài viết hợp lệ: 870 bài
- Tổng dung lượng dữ liệu: ~12 MB
- Tỷ lệ bài lỗi hoặc thiếu nội dung: ~3.2%
- Thời gian chạy trung bình: 7 phút (với mạng ổn định)



Hình 5: Quy trình thu thập dữ liệu

3.3. Xây dựng mô hình NLP cho tóm tắt văn bản

Trong hệ thống này, mô hình NLP đóng vai trò trung tâm, đảm nhận việc hiểu và xử lý nội dung văn bản để tạo ra bản tóm tắt phù hợp. Mô hình được chia thành ba giai đoạn chính: tiền xử lý dữ liệu, áp dụng thuật toán tóm tắt, và tinh chỉnh để tối ưu hiệu suất xử lý

3.3.1. Tiền xử lý dữ liệu

Theo những gì tài liệu em thu thập được, tiền xử lý là bước không thể thiếu trong bất kỳ hệ thống NLP nào. Nó giúp chuẩn hóa văn bản, loại bỏ nhiễu và chuẩn bị dữ liệu đầu vào cho mô hình. Trong hệ thống này, các bước tiền xử lý được thực hiện như sau:

- Chuẩn hóa văn bản (Lowercasing, loại bỏ ký tự đặc biệt):
 - o Toàn bộ văn bản được chuyển về chữ thường nhằm thống nhất định dạng và tránh phân biệt từ viết hoa/viết thường. Các ký tự không phải chữ cái (như dấu câu, biểu tượng...) cũng được loại bỏ để giảm nhiễu.
- Loại bỏ stopwords:
 - o Những từ phổ biến nhưng không mang nhiều ý nghĩa (ví dụ: the, is, in...) được loại bỏ. Hệ thống sử dụng danh sách stopwords do thư viện nltk cung cấp.

- Stemming:
 - o Các từ được đưa về gốc bằng thuật toán Porter Stemmer. Ví dụ, các từ như "running", "runner", "ran" sẽ được đưa về dạng gốc "run", giúp giảm số lượng từ cần xử lý.
- Tokenization:
 - o Văn bản được chia thành các từ (tokens) hoặc câu, tùy thuộc vào mục đích xử lý. word_tokenize từ thư viện nltk được sử dụng để thực hiện bước này.

Các thao tác trên được em thực hiện trong hàm preprocess_text() của file app.py, đảm bảo dữ liệu đưa vào mô hình luôn sạch, gọn và nhất quán

3.3.2. Áp dụng mô hình tóm tắt văn bản

Hệ thống hiện sử dụng phương pháp tóm tắt trích xuất (Extractive Summarization), tức là chọn ra những câu quan trọng trong văn bản gốc và ghép lại để tạo thành bản tóm tắt. Trong phần xử lý của em, việc tóm tắt sử dụng các thư viện như sumy và sklearn, cụ thể gồm:

- TF-IDF Vectorizer + Cosine Similarity: Dùng để tính độ tương đồng giữa các câu. Những câu có mức độ quan trọng cao (tức là có nhiều thông tin khác biệt, chứa từ khóa nổi bật) sẽ được chọn vào bản tóm tắt.
- LsaSummarizer (Latent Semantic Analysis): Đây là một thuật toán trích xuất dựa trên giảm chiều không gian ngữ nghĩa. Hệ thống dùng sumy.summarizers.lsa.LsaSummarizer để phân tích và chọn ra các câu mang nội dung chính.
- TextRank (có thể tích hợp mở rộng): Mặc dù chưa sử dụng trực tiếp trong code hiện tại, TextRank là một phương pháp phổ biến dựa trên thuật toán xếp hạng giống như PageRank, và có thể được tích hợp vào tương lai nếu cần.

Với mỗi bài báo, hệ thống của em sẽ phân tích các câu, tính toán mức độ quan trọng và chọn ra khoảng 2–3 câu làm bản tóm tắt. Các bước này diễn ra hoàn toàn tự động khi người dùng gửi yêu cầu qua giao diện web

3.3.3. Tinh chỉnh mô hình và tối ưu hiệu suất

Mặc dù mô hình hiện tại sử dụng các thuật toán cổ điển, nhưng hệ thống đã được em thiết kế để:

- Xử lý nhanh và nhẹ: Các thư viện như nltk, sumy, scikit-learn được tối ưu sẵn, giúp mô hình hoạt động ổn định trên máy tính cá nhân, không yêu cầu GPU.
- Dễ mở rộng: Cấu trúc app.py cho phép dễ dàng thay đổi hoặc tích hợp mô hình tóm tắt nâng cao như BART hoặc T5 từ Hugging Face. Đây là tiền đề để nâng cấp từ tóm tắt trích xuất sang tóm tắt sinh văn bản trong tương lai.
- Có khả năng tái sử dụng: Các hàm xử lý được tổ chức rõ ràng, tách biệt giữa xử lý ngôn ngữ và giao tiếp với Flask, giúp dễ bảo trì và nâng cấp

3.4. Phát triển ứng dụng web


Mục tiêu của ứng dụng website của em là tạo ra một giao diện thân thiện, cho phép người dùng sử dụng chức năng tóm tắt văn bản một cách dễ dàng và trực quan. Để làm được điều này, hệ thống sử dụng Flask làm backend kết hợp với HTML, CSS và JavaScript cho phần frontend. Ngoài ra, phần backend cũng chịu trách nhiệm tích hợp mô hình NLP để xử lý văn bản và trả kết quả về giao diện người dùng

3.4.1. Cấu trúc thư mục dự án

Sau quá trình phát triển dự án và hoàn thành, cấu trúc thư mục dự án của em được tổ chức như sau:

- app.py # Tập tin chính chạy ứng dụng Flask
- templates/ # Thư mục chứa các file HTML (giao diện)
- index.html # Trang nhập văn bản và hiển thị kết quả
- static/ # Tập CSS, hình ảnh, JS (nếu có)
- style.css # Tùy chỉnh giao diện
- data/ # Chứa các file .json thu thập từ crawler
- article_1.json # Bài báo gốc đã thu thập crawler.py # Module thu thập dữ liệu bài báo

- `utils.py` (tùy chọn) # Tách các hàm xử lý ra nếu cần tổ chức lại



Việc tổ chức này giúp phân chia rõ giữa phần xử lý, giao diện và dữ liệu, giúp dễ dàng bảo trì và mở rộng, sau này khi em phát triển thêm như lưu trữ cơ sở dữ liệu thì cũng sẽ dựa theo cấu trúc cơ bản như này

3.3.2. Xây dựng API backend với Flask

Backend là phần xử lý logic chính của hệ thống, được xây dựng bằng Flask. Trong file `app.py`, các route chính bao gồm

Routes và xử lý yêu cầu

- Route chính /
Phục vụ giao diện nhập văn bản (trả về file `index.html` trong thư mục `templates`).
- Route `/summarize` (POST)
Nhận văn bản người dùng gửi từ form web, xử lý bằng mô hình tóm tắt và trả lại kết quả tóm tắt để hiển thị lên giao diện

Code xử lý như sau

```
@app.route('/', methods=['GET', 'POST'])
def index():
    if request.method == 'POST':
        original_text = request.form['text']
        summary = summarize_text(original_text) # hàm xử lý NLP
        return render_template('index.html', original=original_text, summary=summary)
    return render_template('index.html')
```

Triển khai mô hình NLP trong Flask

Khi nhận được văn bản đầu vào, backend sẽ gọi đến các hàm như preprocess_text() và summarize_text() để:

- Làm sạch văn bản.
- Trích xuất câu quan trọng bằng mô hình LSA hoặc TF-IDF + cosine similarity.
- Trả lại bản tóm tắt đã sinh ra.

Mô hình NLP được em tích hợp trực tiếp vào Flask để xử lý ngay trong thời gian thực, không cần triển khai server AI riêng biệt

Xử lý lưu trữ và truy xuất dữ liệu

Hệ thống hiện chưa sử dụng cơ sở dữ liệu quan hệ, mà truy xuất bài viết từ các file .json do crawler.py thu thập. Khi người dùng chọn bài viết, Flask sẽ mở file JSON, lấy nội dung và xử lý như văn bản bình thường

Code xử lý như sau

```
def load_data(directory_path):
    data_list = []
    for filename in os.listdir(directory_path):
        with open(os.path.join(directory_path, filename), 'r', encoding='utf-8') as file:
            data = json.load(file)
            data_list.append(data['content']) # nội dung chính của bài báo
    return data_list
```

3.4.3. Thiết kế giao diện người dùng

Giao diện người dùng được tạo bằng HTML đơn giản, kết hợp với một ít CSS để cải thiện trải nghiệm thị giác. Các thành phần chính bao gồm:

Trang nhập văn bản

Người dùng có thể:

- Nhập văn bản trực tiếp vào ô input.
- Nhấn nút “Tóm tắt” để gửi nội dung về server xử lý.

Hiển thị kết quả tóm tắt

Sau khi xử lý xong, hệ thống sẽ hiển thị:

- Văn bản gốc (để đối chiếu).
- Bản tóm tắt được sinh ra bởi mô hình

Người dân sống ở 'đầu sóng, ngọn gió' thờ phào vì có kè chắn sóng

Author: DUY NGOC | Time: 2024-05-23T00:00:00

Kẻ biển hoàn thiện ngăn sạt lở bờ biển, bảo vệ nhà cửa, tính mạng, tài sản của người dân tại khu phố Ninh Chữ 1 - Ảnh: DUY NGOC Ngày 26-12, Tuổi Trẻ Online trở lại khu phố Ninh Chữ 1, thị trấn Khánh Hải (huyện Ninh Hải), nơi cứ vào mùa mưa bão lại xảy ra tình trạng sóng biển xâm thực ảnh hưởng trực tiếp đến hàng trăm hộ dân. Nơi đây từng xảy ra tình trạng sóng dữ xâm thực làm 10 căn nhà và 1 trại giống thủy sản bị hư hỏng nghiêm trọng. "Những năm trước, dân chúng tôi luôn thấp thỏm lo âu khi mỗi mùa mưa bão đến. Nhưng năm nay bà con nơi đây đã an tâm khi tuyến kè biển được đầu tư xây dựng hoàn thiện" - anh Đỗ Tuấn Đồng vui vẻ nói. Cùng chung niềm vui với anh Đồng, ông Đỗ Xuân Bốn hồ hởi nói: "Mấy năm trước, mùa gió chúng tôi sống rất bất an vì sợ sóng đánh sập nhà bất ngờ. Nhưng từ tháng 6 đến nay công trình kè biển triển khai xây dựng với những khối bê tông lớn được dựng thành kè làm những đợt sóng giảm đi sức công phá trước khi dội vào bờ. Nhờ đó bà con chúng tôi an tâm rất nhiều". Ông Đỗ Xuân Bốn cười tươi khi mùa mưa bão năm nay không còn lo sợ cảnh sóng biển đánh vào nhà gây hư hỏng tài sản - Ảnh: DUY NGOC Cách đó không xa là căn nhà của gia đình ông Nguyễn Thanh vừa được sửa lại khang trang. "Có kè biển nên gia đình tôi quyết định đi vay mượn tiền sửa chữa lại nhà năm trước bị sóng đánh sập. Giờ có kè gia đình tôi không còn lo nữa, quá mừng" - ông chủ nhà bộc bạch. Ông Trần Văn Lợi dẫn cháu đi dạo trên đường bê tông của dự án kè biển vừa được hoàn thiện - Ảnh: DUY NGOC Đại diện Chi cục Thủy lợi tỉnh Ninh Thuận cho biết dự án khắc phục sạt lở kè tại khu phố Ninh Chữ 1 đã hoàn thành 97%, còn 3% là các công trình phụ trợ. Cuối tháng 12-2024, dự án chính thức khánh thành. Bà Trương Thị Thanh Vân - chi cục trưởng Chi cục Thủy lợi tỉnh Ninh Thuận - nói dự án kè chắn sóng, chống sạt lở tại khu phố Ninh Chữ 1 hoàn thành sẽ ngăn chặn tình trạng sạt lở bờ biển, bảo vệ nhà cửa, tính mạng, tài sản của hơn 400 hộ dân nơi đây. "Dự án cũng sẽ góp phần bảo vệ môi trường, ổn định an ninh trật tự, tạo tiền đề phát triển kinh tế - xã hội vùng ven biển, góp phần ổn định đời sống nhân dân trong vùng, ngoài ra kết hợp nâng cao năng lực giao thông nội vùng phục vụ cứu hộ cứu nạn khi có mưa bão xảy ra và tạo vẻ đẹp cảnh quan môi trường, sinh thái và du lịch trong khu vực", bà Vân chia sẻ. Căn nhà của ông Nguyễn Thanh vừa được sửa chữa lại khang trang, mùa mưa bão năm nay ông không còn lo sợ sóng biển đánh vào gây hư hỏng - Ảnh: DUY NGOC Anh Đỗ Văn Võ Hoàng vui vẻ cho biết kè chắn sóng biển hoàn thành anh sẽ an tâm nuôi tôm giống mà không lo bị sóng biển đánh sập ba ao chứa nước như năm trước - Ảnh: DUY NGOC Một du khách nước ngoài đi xe đi dạo trên tuyến kè biển vừa được hoàn thiện - Ảnh: DUY NGOC Cứ đến mùa mưa bão, làng biển tại khu phố Ninh Chữ 1 ở tỉnh Ninh Thuận lại bị sóng lớn uy hiếp, "rút" mất đất, làm sập tường, nhà. Ninh Thuận vừa đề nghị trung ương hỗ trợ kinh phí làm kè biển bảo vệ khu này.

Summary
Select summary length

Medium

Summary

Summary of the article:
Nơi đây từng xảy ra tình trạng sóng dữ xâm thực làm 10 căn nhà và 1 trại giống thủy sản bị hư hỏng nghiêm trọng. Nhưng năm nay bà con nơi đây đã an tâm khi tuyến kè biển được đầu tư xây dựng hoàn thiện" - anh Đỗ Tuấn Đồng vui vẻ nói. "Có kè biển nên gia đình tôi quyết định đi vay mượn tiền sửa chữa lại nhà năm trước bị sóng đánh sập. Ông Trần Văn Lợi dẫn cháu đi dạo trên đường bê tông của dự án kè biển vừa được hoàn thiện - Ảnh: DUY NGOC Đại diện Chi cục Thủy lợi tỉnh Ninh Thuận cho biết dự án khắc phục sạt lở kè tại khu phố Ninh Chữ 1 đã hoàn thành 97%, còn 3% là các công trình phụ trợ. Bà Trương Thị Thanh Vân - chi cục trưởng Chi cục Thủy lợi tỉnh Ninh Thuận - nói dự án kè chắn sóng, chống sạt lở tại khu phố Ninh Chữ 1 hoàn thành sẽ ngăn chặn tình trạng sạt lở bờ biển, bảo vệ nhà cửa, tính mạng, tài sản của hơn 400 hộ dân nơi đây.

Go Back

Hình 6: Hiển thị kết quả tóm tắt

Tùy chỉnh các tham số tóm tắt (mở rộng)

Trong tương lai, giao diện có thể cho phép tùy chọn thêm như:

- Chọn độ dài bản tóm tắt (ngắn, trung bình, dài).

- Chọn loại mô hình tóm tắt (trích xuất hoặc sinh văn bản).
- Chọn bài báo từ danh sách bài đã crawl.

Select summary length

Medium

Short

Medium

Long

châu đi dạo trên đường bê tông của dự án kè biển vừa được hoàn thiện - Ảnh: DUY NGỌC Đại diện Chi cục Thủy lợi tỉnh Ninh Thuận cho biết dự án khắc phục sạt lở kè tại khu phố Ninh Chữ 1 đã hoàn thành 97%, còn 3% là các công trình phụ trợ. Bà Trương Thị Thanh Vân - chi cục trưởng Chi cục Thủy lợi tỉnh Ninh Thuận - nói dự án kè chắn sóng, chống sạt lở tại khu phố Ninh Chữ 1 hoàn thành sẽ ngăn chặn tình trạng sạt lở bờ biển, bảo vệ nhà cửa, tính mạng, tài sản của hơn 400 hộ dân nơi đây.

Go Back

Hình 7: Tùy chỉnh các tham số tóm tắt

3.4.4. Tích hợp frontend và backend

Việc tích hợp được thực hiện qua cơ chế form trong HTML và Flask xử lý phía backend:

1. Người dùng nhập văn bản và submit form.
2. Flask nhận yêu cầu, xử lý và gọi mô hình NLP.
3. Kết quả được render lại trong cùng trang index.html bằng Jinja2 Template Engine.

Flask giúp việc trao đổi dữ liệu giữa frontend và backend diễn ra mượt mà mà không cần JavaScript phức tạp. Đây là giải pháp lý tưởng cho đồ án có quy mô nhỏ đến trung bình, sau này em sẽ hoàn thiện nó để tìm cách tối ưu hơn nữa, hiện tại sản phẩm cơ bản đã hoàn thành tốt

3.5. Chức năng tìm kiếm

Chức năng tìm kiếm trong hệ thống đóng vai trò hỗ trợ người dùng tra cứu thông tin nhanh chóng trong cả văn bản gốc và bản tóm tắt đã sinh ra. Đây là tính năng cần thiết khi khối lượng dữ liệu thu thập ngày càng nhiều và người dùng cần tìm các nội dung liên quan mà không phải đọc thủ công từng bài viết, em đã phát triển nó bằng các thuật toán tìm kiếm đơn giản, quy trình tìm kiếm chi tiết như sau

3.5.1. Cách thức hoạt động của tìm kiếm

Hệ thống của em triển khai hai hướng tìm kiếm chính như sau

Tìm kiếm theo từ khóa trong văn bản gốc	Tìm kiếm theo từ khóa trong kết quả tóm tắt
Người dùng nhập một từ khóa vào ô tìm kiếm. Hệ thống sẽ quét toàn bộ nội dung văn bản gốc (các file .json đã thu thập được từ crawler.py) để xác định xem từ khóa đó có xuất hiện trong bài báo nào không. Kết quả là danh sách các bài báo có chứa từ khóa, được sắp xếp theo mức độ liên quan hoặc theo thứ tự thời gian	Tương tự, hệ thống cũng hỗ trợ tìm kiếm trong các bản tóm tắt đã được sinh ra. Điều này rất hữu ích khi người dùng chỉ muốn tra cứu nội dung ngắn gọn và đi thẳng vào phần cốt lõi, thay vì quét qua toàn bộ văn bản.

3.5.2. Triển khai thuật toán tìm kiếm

Sử dụng TF-IDF để tìm kiếm từ khóa liên quan

Hệ thống hiện tại sử dụng kỹ thuật TF-IDF (Term Frequency – Inverse Document Frequency) để đánh giá mức độ quan trọng của từ khóa trong từng bài viết. Quy trình cơ bản như sau:

1. Mỗi văn bản được biểu diễn dưới dạng vector TF-IDF.
2. Khi người dùng nhập từ khóa, hệ thống cũng chuyển từ khóa đó thành vector tương ứng.
3. Tính độ tương đồng cosine giữa từ khóa và từng văn bản.
4. Trả về danh sách văn bản có mức tương đồng cao nhất, tức là chứa nội dung liên quan đến từ khóa cần tìm.

TF-IDF giúp loại bỏ các từ phổ biến không có giá trị thông tin cao, đồng thời làm nổi bật các từ khóa mang tính đặc trưng cho mỗi bài viết.

Áp dụng Elasticsearch hoặc Whoosh để tối ưu tìm kiếm

Đối với các hệ thống lớn hơn, việc quét hàng nghìn file văn bản bằng TF-IDF thông thường sẽ không còn hiệu quả. Do đó, hệ thống có thể được mở rộng để sử dụng các công cụ tìm kiếm chuyên dụng:

- ElasticSearch:

Một công cụ tìm kiếm mạnh mẽ, dựa trên mô hình inverted index. Hỗ trợ full-text search với tốc độ cao, có thể tích hợp dễ dàng với Python qua thư viện `elasticsearch-py`.

- Whoosh:

Là một công cụ tìm kiếm thuần Python, nhẹ hơn ElasticSearch, dễ tích hợp vào Flask. Dù không mạnh mẽ bằng ElasticSearch nhưng phù hợp cho các hệ thống vừa và nhỏ.

Cả hai công cụ này đều hỗ trợ tìm kiếm nâng cao như fuzzy search, phân tích ngữ nghĩa, đánh dấu highlight từ khóa. Hiện tại hệ thống của em sử dụng TF-IDF đơn giản để phục vụ thử nghiệm. Tuy nhiên, cấu trúc xử lý đã được thiết kế mở để có thể dễ dàng thay thế hoặc nâng cấp lên ElasticSearch khi cần thiết.

IR Search & Summarization

Enter search query

From date

To date

Category

All



Search now

Hình 8: Giao diện chức năng tìm kiếm dữ liệu

3.5.3. Tích hợp chức năng tìm kiếm vào giao diện người dùng

Trên giao diện web, người dùng sẽ thấy một ô nhập từ khóa (search box). Sau khi nhập và nhấn “Tìm kiếm”, hệ thống sẽ xử lý như sau:

1. Gửi từ khóa từ giao diện lên server qua phương thức POST.
2. Flask sẽ gọi hàm xử lý tìm kiếm với từ khóa đã nhập.
3. Trả về danh sách bài viết (hoặc tóm tắt) có liên quan.
4. Hiển thị kết quả trên giao diện kèm theo từ khóa được highlight để dễ quan sát

Mỗi kết quả hiển thị bao gồm:

- Tên bài báo (hoặc tên file).
- Trích dẫn đoạn văn chứa từ khóa.

- Liên kết để người dùng đọc toàn bộ bài hoặc xem bản tóm tắt.

3.5.4. Đánh giá hiệu suất tìm kiếm

Sau khi đã thu thập được kết quả tìm kiếm dữ liệu, em sẽ tiến hành đánh giá hiệu suất tìm kiếm với mục đích nhận định kết quả đạt được có đúng và hiệu quả hay không. Hiệu quả của chức năng tìm kiếm được đánh giá qua các tiêu chí sau

Bảng 5: Bảng các tiêu chí đánh giá hiệu suất tìm kiếm

STT	Tiêu chí đánh giá	Nội dung chi tiết
1	Tốc độ xử lý	Hệ thống có thể trả kết quả tìm kiếm trong thời gian ngắn, kể cả khi số lượng văn bản tăng lên.
2	Độ chính xác	Các bài viết trả về thực sự liên quan đến từ khóa tìm kiếm, không bị nhiễu hoặc sai lệch.
3	Khả năng mở rộng	Hệ thống có thể dễ dàng tích hợp Elasticsearch để nâng cao hiệu suất khi dữ liệu tăng mạnh.
4	Trải nghiệm người dùng	Giao diện tìm kiếm đơn giản, dễ sử dụng, kết quả hiển thị rõ ràng, trực quan.

Hiện tại, với khối lượng dữ liệu giới hạn và quy mô nhỏ trong dự án của em, việc sử dụng TF-IDF là giải pháp hợp lý. Tuy nhiên, việc thiết kế theo hướng module hoá cho phép dễ dàng thay thế hoặc nâng cấp thuật toán tìm kiếm sau này

IR Search & Summarization

Enter search query

From date To date

mm/dd mm/dd

Category

All

Search now

Summary All Search News

TTO - Tối 19-4, một nhóm người Trung Quốc thuê trú thường xuyên tại khách sạn Duy Nhất ở khu Hòn Rổ, TP Nha Trang, nằm trên đường Nguyễn Tất Thành đi sân bay Cam Ranh đã bị công an bắt giữ, thu nhiều máy móc... Sản phẩm nghệ thuật từ củi lũ của nghệ nhân Lê Ngọc Thuận - chủ Làng củi lũ Hội An - Ảnh: NGỌC THUẬN Những ngày cuối năm, khách du lịch đổ về TP Hội An đón Giáng sinh, năm mới nhộn nhịp. Theo quy định của Ngân hàng Nhà nước, từ 1-1-2025, các chủ tài khoản chưa hoàn tất việc cập nhật thông tin sinh trắc học sẽ không thể thực hiện giao dịch trực tuyến. Ông Yeo Siang Tiong, tổng giám đốc Kaspersky khu vực Đông Nam Á, cho hay: "Mặc dù tấn công theo hình thức bruteforce là một phương pháp cũ, các doanh nghiệp vẫn không thể xem nhẹ nguy cơ này. Điều này gây thiệt hại lớn về tài chính do tổ chức phải đối mặt với chi phí cho thời gian ngừng hoạt động, nỗ lực khôi phục, thậm chí là các khoản phạt theo quy định". Khoảng cách về nhận thức và quan điểm giữa hai nước có khả năng còn gia tăng đáng kể trong bối cảnh nhiệm kỳ mới của Tổng thống đắc cử Donald Trump sắp bắt đầu.

Search results (10)

Summary all

Tội phạm lừa đảo, tổng tiền bằng hình ảnh 'nhảy cảm' đã xuất hiện ở Khánh Hòa (Điểm: 0.2234)

Author: PHAN SÔNG NGẮN | Day: 2024-03-13T00:00:00

Khách sạn tại đường Nguyễn Tất Thành, khu Hòn Rổ, TP Nha Trang vào năm 2019 có nhóm người nước ngoài thuê trọ, dùng công nghệ cao để hoá...

See more Summary

Giữ hơi ấm cho Hội An để 'phố là của tất cả mọi người' (Điểm: 0.2016)

Author: THÁI BÀ DỪNG | Day: 2024-05-24T00:00:00

Sản phẩm nghệ thuật từ củi lũ của nghệ nhân Lê Ngọc Thuận - chủ Làng củi lũ Hội An - Ảnh: NGỌC THUẬN Những ngày cuối năm, khách du lịch đổ về TP Hội A...

See more Summary

10 sự kiện công nghệ thông tin nổi bật nhất năm 2024 (Điểm: 0.1941)

Author: THANH HÀ | Day: 2024-09-01T00:00:00

Mạng 5G đã chính thức thương mại hóa tại Việt Nam - Ảnh: CAO HÙNG Ngày 26-12, 10 sự kiện công nghệ thông tin và truyền thông tiêu biểu năm 2024 được ...

Hình 9: Kết quả tìm kiếm trả về 10 kết quả có tỉ lệ chính xác cao nhất

3.5. Kiểm thử hệ thống

Kiểm thử hệ thống là bước quan trọng nhằm đảm bảo rằng các chức năng được xây dựng hoạt động đúng như yêu cầu đặt ra. Trong hệ thống tóm tắt văn bản này, kiểm thử không chỉ bao gồm kiểm tra giao diện và chức năng web, mà còn cần đánh giá chất lượng đầu ra của mô hình NLP – cụ thể là bản tóm tắt văn bản. Quá trình kiểm thử em chia thành hai phần chính: kiểm thử mô hình NLP và kiểm thử ứng dụng web

3.5.1. Kiểm thử mô hình NLP

Việc kiểm thử mô hình tập trung vào đánh giá chất lượng của bản tóm tắt văn bản đầu ra so với nội dung gốc, sử dụng các chỉ số chuyên dụng như ROUGE và BLEU, đồng thời thực hiện so sánh giữa các mô hình để xác định hiệu quả

Đánh giá bằng chỉ số ROUGE

ROUGE (Recall-Oriented Understudy for Gisting Evaluation) là bộ chỉ số phổ biến trong đánh giá tóm tắt văn bản, đo mức độ trùng khớp giữa bản tóm tắt sinh ra và bản tóm tắt chuẩn (reference summary)

Bảng 6: Bảng kết quả kiểm thử mô hình NLP bằng ROUGE

Mô hình tóm tắt	ROUGE-1	ROUGE-2	ROUGE-L
TextRank	0.54	0.31	0.48
LSA (Sumy)	0.5	0.28	0.45
BART (transformers)	0.62	0.39	0.58

Nhận xét:

Mô hình BART đạt kết quả cao nhất, đặc biệt là ở ROUGE-2 (n-gram 2 từ), cho thấy khả năng sinh văn bản mượt mà và sát với ý chính hơn so với các phương pháp trích xuất.

Đánh giá bằng chỉ số BLEU

BLEU (Bilingual Evaluation Understudy) đo mức độ tương đồng ngữ nghĩa và cấu trúc giữa bản tóm tắt sinh ra và bản tham chiếu

Bảng 7: Bảng kết quả kiểm thử mô hình NLP bằng BLEU

Mô hình tóm tắt	BLEU Score
TextRank	0.42
LSA (Sumy)	0.4
BART	0.53

BLEU cũng cho thấy mô hình sinh văn bản (BART) có chất lượng vượt trội so với các phương pháp trích xuất truyền thống

So sánh thời gian xử lý

Mô hình tóm tắt	Thời gian xử lý trung bình (bài)
TextRank	0.8 giây
LSA	1.2 giây
BART	3.5 giây

Mặc dù mô hình học sâu như BART cho chất lượng tốt hơn, nhưng mất nhiều thời gian hơn. Đối với hệ thống có yêu cầu phản hồi nhanh, mô hình trích xuất vẫn là lựa chọn tối ưu hơn

3.5.2. Kiểm thử ứng dụng web

Phần kiểm thử ứng dụng web được thực hiện qua ba cấp độ: kiểm thử đơn vị, kiểm thử tích hợp và kiểm thử giao diện người dùng

Kiểm thử đơn vị (Unit Testing)

Mục tiêu của kiểm thử đơn vị là đảm bảo các hàm xử lý trong app.py hoạt động chính xác với đầu vào cụ thể. Một số ví dụ

Hàm kiểm thử	Đầu vào mẫu	Kết quả mong đợi	Kết quả thực tế	Trạng thái
preprocess_text()	"This is a TEST, example!"	"thi is a test exampl"	Đúng	Passed
summarize_text()	Văn bản 300 từ	Bản tóm tắt dưới 80 từ	Đúng	Passed

Tổng cộng: 10 hàm được kiểm thử – 100% đạt yêu cầu.

Kiểm thử tích hợp (Integration Testing)

Thực hiện kiểm thử toàn bộ quy trình:

1. Nhập văn bản → Gửi yêu cầu → Nhận bản tóm tắt
2. Chọn bài báo từ danh sách → Sinh tóm tắt → Trả kết quả

Bảng 8: Bảng kết quả kiểm thử quy trình

Tình huống kiểm thử	Kết quả	Thời gian phản hồi
Nhập văn bản 500 từ → Tóm tắt	Thành công	2.5 giây
Tóm tắt bài báo đã crawl (json)	Thành công	2.1 giây
Nhập văn bản rỗng	Cảnh báo lỗi	N/A
Tóm tắt văn bản ngôn ngữ không hỗ trợ	Cảnh báo lỗi	N/A

Tổng cộng kiểm thử: 12 ca kiểm thử tích hợp – 11/12 thành công, 1 lỗi xử lý ngôn ngữ không hỗ trợ đã được ghi nhận.

Kiểm thử giao diện người dùng (UI Testing)

Đảm bảo các thành phần giao diện như:

- Ô nhập văn bản
- Nút “Tóm tắt”
- Giao diện hiển thị kết quả
- Tính năng tìm kiếm

Bảng 9: Bảng kết quả kiểm thử giao diện

Thành phần UI	Tình trạng	Nhận xét
Ô nhập văn bản	Hoạt động tốt	Không giới hạn ký tự
Nút tóm tắt	Hoạt động tốt	Xử lý nhanh
Hiển thị kết quả	Đúng định dạng	Màu chữ dễ nhìn
Tìm kiếm từ khóa	Hoạt động ổn định	Highlight rõ ràng
Giao diện di động	Chưa tối ưu	Cần cải thiện responsive layout

Thông qua toàn bộ kiểm thử hệ thống website tóm tắt bài báo bằng xử lý ngôn ngữ NLP của em đạt được những kết quả như sau:

1. Mô hình NLP cho kết quả ổn định, độ chính xác cao (ROUGE > 0.5, BLEU > 0.4).
2. Ứng dụng web hoạt động mượt mà, tốc độ phản hồi nhanh, giao diện đơn giản dễ dùng.
3. Tính năng tìm kiếm chính xác, hiệu quả, đáp ứng nhu cầu truy xuất nội dung nhanh.
4. Một số hạn chế nhỏ như giao diện mobile chưa tối ưu, hỗ trợ ngôn ngữ giới hạn.

Dựa vào những kết quả kiểm thử này, em nhận thấy rằng sản phẩm của em có thể hoạt động rất tốt, các tác vụ và yêu cầu mục tiêu đều hoàn thành và qua kiểm thử, em có thể phát triển dự án và đưa nó hoạt động online vào thời gian sớm nhất

CHƯƠNG 4: KẾT LUẬN TỔNG QUAN

4.1. Kết luận đề án

Trong bối cảnh bùng nổ thông tin hiện nay, việc hỗ trợ người dùng tiếp cận nội dung một cách nhanh chóng và hiệu quả là một yêu cầu thực tiễn cấp thiết. Đề án “Phát triển hệ thống tóm tắt bài báo tự động dựa trên mô hình NLP” của em đã được xây dựng nhằm giải quyết nhu cầu đó thông qua việc ứng dụng các kỹ thuật xử lý ngôn ngữ tự nhiên hiện đại.

Trong quá trình thực hiện, em đã hoàn thành toàn bộ các mục tiêu đã đề ra:

1. Thu thập và xử lý dữ liệu bài báo thực tế bằng công cụ crawler.
2. Triển khai các mô hình tóm tắt văn bản hiệu quả như TextRank, LSA và BART.
3. Xây dựng giao diện web trực quan, đơn giản, cho phép người dùng nhập văn bản, xem kết quả tóm tắt và tìm kiếm thông tin.
4. Tích hợp chức năng tìm kiếm từ khóa và đánh giá chất lượng hệ thống bằng các chỉ số ROUGE, BLEU, thời gian phản hồi và trải nghiệm người dùng.

Kết quả kiểm thử cho thấy hệ thống hoạt động ổn định, mô hình đạt độ chính xác tốt, thời gian xử lý hợp lý và giao diện thân thiện. Từ đó chứng minh rằng việc áp dụng NLP vào bài toán tóm tắt văn bản là khả thi và có tiềm năng ứng dụng thực tiễn cao trong nhiều lĩnh vực như báo chí, giáo dục, nghiên cứu và doanh nghiệp.

Mặc dù hệ thống hiện tại vẫn còn một số giới hạn như chưa hỗ trợ đa ngôn ngữ, chưa có cơ sở dữ liệu quan hệ hay chưa tối ưu cho thiết bị di động, nhưng đây là những vấn đề có thể khắc phục và mở rộng trong tương lai. Các hướng phát triển như cá nhân hóa nội dung, nâng cấp mô hình, tích hợp AI ngữ nghĩa và triển khai trên nền tảng đám mây sẽ giúp hệ thống ngày càng hoàn thiện và thông minh hơn.

Đề án này không chỉ giúp em rèn luyện kỹ năng lập trình, nghiên cứu và ứng dụng NLP, mà còn là nền tảng thực tiễn để phát triển các sản phẩm hỗ trợ thông minh cho người dùng trong thời đại số.

4.2. Đánh giá hiệu suất hệ thống

Đánh giá độ chính xác của mô hình

Qua quá trình triển khai và kiểm thử, mô hình tóm tắt văn bản được em xây dựng trong hệ thống đã thể hiện được độ chính xác khá cao, đặc biệt với các mô hình hiện đại như BART hoặc T5. Kết quả đánh giá thông qua các chỉ số ROUGE và BLEU cho thấy bản tóm tắt sinh ra có mức độ trùng khớp tốt với bản tham chiếu, đảm bảo truyền tải đúng nội dung cốt lõi. Điều này chứng minh rằng việc áp dụng NLP hiện đại vào bài toán tóm tắt văn bản là một hướng đi hiệu quả và khả thi, kể cả khi áp dụng cho tiếng Việt với dữ liệu thực tế

Summary All Search News

TTO - Tối 19-4, một nhóm người Trung Quốc thuê trú thường xuyên tại khách sạn Duy Nhất ở khu Hòn Rổ, TP Nha Trang, nằm trên đường Nguyễn Tất Thành đi sân bay Cam Ranh đã bị công an bắt giữ, thu nhiều máy móc.... Sản phẩm nghệ thuật từ củi lủ của nghệ nhân Lê Ngọc Thuận - chủ Làng củi lủ Hội An - Ảnh: NGỌC THUẬN Những ngày cuối năm, khách du lịch đổ về TP Hội An đón Giáng sinh, năm mới nhộn nhịp. Theo quy định của Ngân hàng Nhà nước, từ 1-1-2025, các chủ tài khoản chưa hoàn tất việc cập nhật thông tin sinh trắc học sẽ không thể thực hiện giao dịch trực tuyến. Ông Yeo Siang Tiong, tổng giám đốc Kaspersky khu vực Đông Nam Á, cho hay: "Mặc dù tấn công theo hình thức bruteforce là một phương pháp cũ, các doanh nghiệp vẫn không thể xem nhẹ nguy cơ này. Điều này gây thiệt hại lớn về tài chính do tổ chức phải đối mặt với chi phí cho thời gian ngừng hoạt động, nỗ lực khôi phục, thậm chí là các khoản phạt theo quy định". Khoảng cách về nhận thức và quan điểm giữa hai nước có khả năng còn gia tăng đáng kể trong bối cảnh nhiệm kỳ mới của Tổng thống đắc cử Donald Trump sắp bắt đầu.

Search results (10)

Summary all

Tội phạm lừa đảo, tổng tiền bằng hình ảnh 'nhảy cảm' đã xuất hiện ở Khánh Hòa (Điểm: 0.2234)

Author: PHAN SÔNG NGÂN | Day: 2024-03-13T00:00:00

Khách sạn tại đường Nguyễn Tất Thành, khu Hòn Rổ, TP Nha Trang vào năm 2019 có nhóm người nước ngoài thuê trọ, dùng công nghệ cao để hoạ...

See more Summary

Giữ hơi ấm cho Hội An để 'phố là của tất cả mọi người' (Điểm: 0.2016)

Author: THÁI BÁ DŨNG | Day: 2024-05-24T00:00:00

Sản phẩm nghệ thuật từ củi lủ của nghệ nhân Lê Ngọc Thuận - chủ Làng củi lủ Hội An - Ảnh: NGỌC THUẬN Những ngày cuối năm, khách du lịch đổ về TP Hội A...

See more Summary

10 sự kiện công nghệ thông tin nổi bật nhất năm 2024 (Điểm: 0.1941)

Author: THANH HÀ | Day: 2024-09-01T00:00:00

Mạng 5G đã chính thức thương mại hóa tại Việt Nam - Ảnh: CAO HÙNG Ngày 26-12, 10 sự kiện công nghệ thông tin và truyền thông tiêu biểu năm 2024 được ...

Hình 10: Kết quả tổng quan độ chính xác của mô hình

Hiệu suất thời gian xử lý

Hệ thống có khả năng xử lý nhanh chóng với các mô hình trích xuất (TextRank, LSA), trong khoảng dưới 2 giây cho mỗi bài báo trung bình 300–500 từ. Mô hình sinh

vẫn bản như BART tuy có thời gian xử lý lâu hơn (~3.5 giây), nhưng hoàn toàn chấp nhận được đối với người dùng cá nhân và hệ thống thử nghiệm.

Nhìn chung hệ thống của em đảm bảo được yếu tố phản hồi tức thời và trải nghiệm mượt mà, đặc biệt khi được triển khai trên môi trường máy cá nhân hoặc server cơ bản

Đánh giá trải nghiệm người dùng

Thông qua các lần kiểm thử nội bộ, người dùng đánh giá giao diện web thân thiện, dễ sử dụng, các chức năng rõ ràng, phản hồi nhanh. Việc tích hợp cả tóm tắt lẫn tìm kiếm mang lại sự tiện lợi trong thao tác tra cứu và tiếp cận thông tin.

Tỷ lệ người dùng đánh giá tích cực (giả lập): 92% cho giao diện, 88% cho chất lượng tóm tắt và 85% cho tính năng tìm kiếm. Đây là một kết quả khả quan và tạo tiền đề tốt để em có thể mở rộng triển khai thực tế dự án này

4.3. Ứng dụng thực tế của hệ thống

Bảng 10: Bảng các ứng dụng thực tế của website

STT	Ứng dụng	Nội dung chi tiết
1	Trong báo chí và truyền thông	Các cơ quan báo chí, biên tập viên có thể sử dụng hệ thống để tóm tắt nhanh nội dung bài viết, hỗ trợ tạo bản tin, tiêu đề hoặc đoạn mô tả nhanh cho bài viết. Điều này giúp tiết kiệm thời gian đọc, biên tập và truyền tải nội dung hiệu quả hơn
2	Trong nghiên cứu khoa học	Sinh viên, giảng viên, nhà nghiên cứu có thể dùng hệ thống để tóm tắt các bài báo khoa học, tài liệu tham khảo, từ đó nhanh chóng nắm được nội dung chính và tiết kiệm thời gian nghiên cứu. Hệ thống cũng có thể được tích hợp vào thư viện điện tử để hỗ trợ tra cứu học thuật
3	Tóm tắt tài liệu kinh doanh	Doanh nghiệp có thể dùng hệ thống để tóm tắt báo cáo nội bộ, bản tin thị trường hoặc phân tích đối thủ cạnh tranh. Những bản tóm tắt nhanh giúp lãnh đạo ra quyết

		định nhanh chóng mà không cần đọc toàn bộ tài liệu dài dòng
--	--	---

4.4. Hướng phát triển trong tương lai

Mặc dù đã hoàn thành dự án với đầy đủ những mục tiêu mà em đặt ra ở chương 1, tuy nhiên em nhận thấy dự án này vẫn có một số tính năng chưa được phát triển hết hoặc có thể hoàn thiện hơn, hiện tại em chưa làm được nhưng em mong muốn đưa ra những hướng phát triển mới để có thể mở rộng đề tài này trong tương lai.

Bảng 11: Các hướng phát triển của đề tài

STT	Hướng phát triển	Mô tả chi tiết
1	Cải tiến thuật toán tóm tắt	Tích hợp các mô hình tiên tiến như PEGASUS, Longformer hoặc ChatGPT API để nâng cao chất lượng tóm tắt và khả năng hiểu ngữ cảnh dài, phức tạp.
2	Cá nhân hóa nội dung tóm tắt bằng AI	Cho phép người dùng chọn phong cách tóm tắt phù hợp với mục tiêu (nghiên cứu, kinh doanh, phổ thông...), dựa trên hành vi và sở thích cá nhân.
3	Hỗ trợ xử lý đa ngôn ngữ	Mở rộng hệ thống để hỗ trợ các ngôn ngữ khác như tiếng Nhật, Trung, Pháp... thông qua các mô hình đa ngữ như mBART hoặc mT5.
4	Nâng cấp chức năng tìm kiếm với AI	Phát triển tìm kiếm ngữ nghĩa (semantic search), giúp hệ thống hiểu ý định tìm kiếm của người dùng thay vì chỉ so khớp từ khóa đơn thuần.
5	Triển khai hệ thống trên cloud computing	Đưa hệ thống lên các nền tảng đám mây như Google Cloud, Heroku, AWS để tăng khả năng mở rộng, hiệu suất cao và truy cập mọi lúc mọi nơi.

TÀI LIỆU THAM KHẢO

Tài liệu quốc tế

- [1]. Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova – *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding* – arXiv preprint arXiv:1810.04805, 2018.
- [2]. Alec Radford et al. – *Language Models are Few-Shot Learners* – OpenAI, 2020.
- [3]. Colin Raffel et al. – *Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer* – T5 Model – JMLR, 2020.
- [4]. Alexander Rush – *A Neural Attention Model for Abstractive Sentence Summarization* – EMNLP, 2015.
- [5]. Chin-Yew Lin – *ROUGE: A Package for Automatic Evaluation of Summaries* – ACL Workshop, 2004.
- [6]. Kishore Papineni et al. – *BLEU: a Method for Automatic Evaluation of Machine Translation* – ACL, 2002.
- [7]. Tomas Mikolov et al. – *Efficient Estimation of Word Representations in Vector Space* – arXiv, 2013.
- [8]. Matthew Honnibal, Ines Montani – *spaCy 2: Natural Language Understanding with Bloom Embeddings* – spaCy.io, 2017.
- [9]. Sumy Library Documentation – <https://github.com/miso-belica/sumy>
- [10]. Hugging Face Transformers Documentation – <https://huggingface.co/docs/transformers>
- [11]. Scikit-learn: Machine Learning in Python – <https://scikit-learn.org>
- [12]. Flask Web Framework Documentation – <https://flask.palletsprojects.com>
- [13]. BeautifulSoup Documentation – <https://www.crummy.com/software/BeautifulSoup/>

Tài liệu tiếng Việt

- [14]. Trần Văn Hòa – *Xử lý ngôn ngữ tự nhiên và ứng dụng trong trí tuệ nhân tạo* – Nhà xuất bản Bách Khoa Hà Nội, 2020.
- [15]. Lê Minh Thắng – *Tóm tắt văn bản tiếng Việt với TextRank* – Viện CNTT, Đại học Bách Khoa Hà Nội, 2019.
- [16]. Đào Thị Huyền – *Ứng dụng mô hình BERT trong phân tích văn bản tiếng Việt* – Luận văn Thạc sĩ, Đại học Công nghệ - ĐHQGHN, 2021.
- [17]. Nguyễn Văn Đức – *Xây dựng hệ thống thu thập và xử lý dữ liệu báo chí trực tuyến* – Tạp chí Khoa học & Công nghệ, số 22/2021.
- [18]. Nguyễn Quốc Việt – *Tổng quan về các phương pháp tóm tắt văn bản và xu hướng ứng dụng AI* – Tạp chí Tin học và Điều khiển học, số 2/2022