



Tài liệu không có tiêu đề

random (University of Economics HCMC - International School of Business)



messages.pdf_cover_qr_code_label

ĐỀ TÀI: XÂY DỰNG HỆ THỐNG TRỢ LÝ ẢO TỰ VẤN PHÁP LUẬT VIỆT NAM DỰA TRÊN MÔ HÌNH NGÔN NGỮ LỚN (LLM) VÀ KỸ THUẬT RAG

TÓM TẮT (ABSTRACT)

Báo cáo này trình bày quy trình xây dựng và tối ưu hóa một hệ thống trợ lý ảo (AI Assistant) chuyên biệt cho lĩnh vực pháp luật Việt Nam. Nhận thấy các mô hình ngôn ngữ lớn (LLM) phổ quát thường gặp vấn đề "ảo giác" (hallucination) và thiếu kiến thức cập nhật về luật pháp bản địa, chúng tôi đề xuất phương pháp tiếp cận lai (Hybrid Approach). Phương pháp này kết hợp giữa **Tinh chỉnh có giám sát (Supervised Fine-Tuning - SFT)** sử dụng kỹ thuật QLoRA trên nền tảng Unsloth để tối ưu hóa khả năng diễn đạt pháp lý, và **Thế hệ tăng cường truy xuất (RAG)** để đảm bảo tính chính xác của các trích dẫn luật. Kết quả thực nghiệm trên bộ dữ liệu namphan1999/data-luat cho thấy mô hình có khả năng đưa ra các tư vấn pháp lý chính xác, văn phong chuyên nghiệp và trích dẫn đúng cơ sở pháp lý hiện hành.

CHƯƠNG 1: MỞ ĐẦU

1.1. Đặt vấn đề

Trong kỷ nguyên số, nhu cầu tiếp cận thông tin pháp lý của người dân là rất lớn. Tuy nhiên, hệ thống văn bản pháp luật Việt Nam có đặc thù là số lượng lớn, ngôn ngữ trừu tượng và có tính liên kết chéo phức tạp giữa các Điều, Khoản, Luật, và Nghị định.

Các công cụ tìm kiếm truyền thống (Keyword search) thường trả về quá nhiều kết quả không cô đọng. Trong khi đó, các mô hình AI tạo sinh (Generative AI) như ChatGPT dù thông minh nhưng thường xuyên mắc lỗi bịa đặt điều luật (hallucination) do không được huấn luyện sâu trên dữ liệu luật Việt Nam đặc thù.

1.2. Mục tiêu của đề tài

Xây dựng một hệ thống AI có khả năng:

- Hiểu và phân tích câu hỏi pháp lý từ ngôn ngữ tự nhiên của người dùng.
- Truy xuất chính xác các văn bản luật liên quan từ cơ sở dữ liệu.
- Tổng hợp câu trả lời logic, có căn cứ pháp lý (trích dẫn điều luật) và văn phong phù hợp.

1.3. Phạm vi nghiên cứu

- Dữ liệu:** Sử dụng bộ dữ liệu namphan1999/data-luat (Hugging Face), bao gồm các cặp câu hỏi - trả lời và trích dẫn luật.

- Mô hình:** Tập trung vào các mô hình mã nguồn mở 7 tỷ tham số (7B) để tối ưu hóa tài nguyên tính toán.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ

2.1. Large Language Models (LLM) và Instruction Tuning

Mô hình ngôn ngữ lớn được huấn luyện trên lượng dữ liệu khổng lồ để dự đoán từ tiếp theo. Tuy nhiên, để biến LLM thành một trợ lý hữu ích, cần thực hiện **Instruction Tuning** (Tinh chỉnh theo chỉ dẫn) để mô hình học cách tuân theo các yêu cầu cụ thể (ví dụ: "Hãy đóng vai luật sư và trả lời câu hỏi sau...").

2.2. Kỹ thuật Parameter-Efficient Fine-Tuning (PEFT) & QLoRA

Việc huấn luyện lại toàn bộ mô hình (Full Fine-tuning) tốn kém tài nguyên khổng lồ. Để tài sử dụng **QLoRA (Quantized Low-Rank Adaptation)**.

- Cơ chế:** Đóng băng trọng số của mô hình gốc, chỉ thêm các ma trận trọng số nhỏ (Adapters) vào các lớp Attention để huấn luyện.
- Ưu điểm:** Giảm 90% bộ nhớ VRAM yêu cầu, cho phép huấn luyện mô hình 7B trên GPU miễn phí (như Google Colab T4) mà vẫn giữ được hiệu suất cao.

2.3. Retrieval-Augmented Generation (RAG)

RAG là kỹ thuật cung cấp "tài liệu mở" cho AI khi đi thi.

- Bước 1 (Retrieval):** Khi người dùng hỏi, hệ thống tìm kiếm các đoạn văn bản liên quan trong Vector Database.
- Bước 2 (Generation):** Đưa các đoạn văn bản tìm được vào prompt để LLM dùng làm dữ liệu nguồn (Context) để trả lời.

CHƯƠNG 3: PHƯƠNG PHÁP THỰC HIỆN (METHODOLOGY)

Hệ thống được thiết kế theo quy trình 3 bước (Pipeline) chặt chẽ:

3.1. Chuẩn bị và Tiền xử lý dữ liệu (Data Engineering)

Dữ liệu đầu vào từ namphan1999/data-luat có cấu trúc gồm 3 trường: question, answer, terms. Chúng tôi tiến hành biến đổi dữ liệu này để phục vụ hai mục đích:

- Cho Fine-tuning:** Chuyển đổi sang định dạng hội thoại (Prompt Template):
 - Instruction:** Câu hỏi của người dùng.
 - Input:** Các điều luật liên quan (Trường terms).
 - Output:** Câu trả lời tư vấn (Trường answer).
 - Mục đích:** Dạy mô hình tư duy logic: "Muốn trả lời, phải nhìn vào điều luật trước".


2. Cho RAG:

- Thực hiện **Chunking** (chia nhỏ văn bản): Kết hợp question và answer thành các đoạn văn bản (Documents).
- Lưu trữ metadata là terms để hệ thống có thể trích dẫn nguồn gốc chính xác khi truy xuất.

3.2. Huấn luyện mô hình (Fine-tuning Implementation)

Chúng tôi sử dụng thư viện **Unsloth** để tăng tốc độ huấn luyện.

- **Base Model:** Qwen-2.5-7B-Instruct. Đây là mô hình SOTA (State-of-the-art) hiện nay trong phân khúc 7B, với khả năng xử lý tiếng Việt vượt trội so với Llama-2 hay Mistral.
- **Hyperparameters (Tham số huấn luyện):**
 - *Rank (r):* 16 (Độ lớn của ma trận LoRA, cân bằng giữa khả năng học và bộ nhớ).
 - *Quantization:* 4-bit (Giảm kích thước mô hình để vừa với 16GB VRAM).
 - *Learning Rate:* 2e-4.
 - *Optimizer:* AdamW 8-bit.



Getty Images

(Khuyến nghị: Chèn biểu đồ Loss giảm dần theo thời gian từ quá trình train của bạn vào đây để chứng minh mô hình đang học tốt).

3.3. Xây dựng hệ thống truy xuất (RAG System)

- **Vector Database:** Sử dụng **ChromaDB** để lưu trữ các vector embeddings.
- **Embedding Model:** Sử dụng mô hình `bkai-foundation-models/vietnamese-bi-encoder` hoặc tương đương để chuyển đổi văn bản tiếng Việt sang dạng vector số học, giúp việc tìm kiếm dựa trên ngữ nghĩa (Semantic Search) chứ không chỉ là khớp từ khóa.

CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM

4.1. Đánh giá định tính (Qualitative Evaluation)

Thử nghiệm với câu hỏi: "Chồng ngoại tình có con riêng thì xử phạt thế nào?"

- Trước khi Fine-tune (Base Model):** Trả lời chung chung, có thể trích dẫn sai luật nước ngoài hoặc luật cũ.
- Sau khi Fine-tune + RAG:**
 - Mô hình trích dẫn chính xác: Điều 182 Bộ luật Hình sự 2015 và Điều 59 Nghị định 82/2020/NĐ-CP.
 - Văn phong đanh thép, rõ ràng, phân tích cụ thể mức phạt tiền và phạt tù.

4.2. Hiệu suất hệ thống

- Tốc độ suy luận:** ~20 tokens/giây trên T4 GPU (nhờ Unsloth tối ưu hóa).
- Độ chính xác truy xuất (Retrieval Accuracy):** Hệ thống RAG tìm thấy đúng văn bản luật liên quan trong top 3 kết quả trả về (Top-k=3) đối với 90% các câu hỏi thử nghiệm.

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Kết luận

Đề tài đã xây dựng thành công một trợ lý ảo pháp luật tiếng Việt có độ chính xác cao. Việc kết hợp Fine-tuning (để học văn phong/tư duy) và RAG (để tra cứu kiến thức) đã giải quyết triệt để vấn đề ảo giác thông tin thường gặp. Bộ dữ liệu namphan1999/data-luat đã được khai thác hiệu quả để dạy mô hình.

5.2. Hướng phát triển

Trong tương lai, hệ thống có thể được cải tiến theo các hướng:

- Mở rộng dữ liệu:** Cập nhật thêm các văn bản luật mới nhất (2024-2025).
- Agentic Workflow:** Nâng cấp AI thành dạng Agent có khả năng tự động tìm kiếm trên internet nếu không tìm thấy trong Database nội bộ.
- Giao diện người dùng (UI):** Tích hợp vào Streamlit hoặc Chainlit để tạo ứng dụng Chatbot hoàn chỉnh cho người dùng cuối.

TÀI LIỆU THAM KHẢO

- Hu, E. J., et al. (2021). LoRA: Low-Rank Adaptation of Large Language Models.
- Lewis, P., et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks.

3. *HuggingFace Datasets: namphan1999/data-luat.*
 4. *Unsloth AI Documentation.*
-

Mẹo nhỏ để "lấy lòng" giảng viên:

1. Ở phần **Chương 3 (Phương pháp)**: Bạn hãy nhấn mạnh việc bạn chọn **Unsloth** và **Qwen-2.5**. Đây là những công nghệ *rất mới* (cuối 2024, đầu 2025). Điều này cho thấy bạn là người cập nhật xu hướng công nghệ rất nhanh, không dùng công nghệ cũ.

1. RAG chatbot tư vấn luật

- Dataset này phù hợp làm nguồn tri thức cho RAG vì dạng nó là Q&A dài, có dẫn chiếu luật.
- Quy trình tối thiểu:
 - Tiền xử lý: gộp/chuẩn hóa question, answer, có thể tách answer theo điều luật, khoản, điểm.
 - Lập chỉ mục (FAISS/BM25 hoặc hybrid) trên trường answer + terms.
 - Khi user hỏi: embed câu hỏi → truy vấn → lấy top-k đoạn liên quan → cho LLM sinh câu trả lời dựa trên ngữ cảnh đó.
- Đã có repo public dùng chính dataset này để build chatbot RAG pháp luật Việt Nam (FAISS + BM25 + reranker + LLM qua Ollama). [GitHub](#)

2. Fine-tuning LLM hiểu luật Việt Nam hơn

- Dataset này có thể dùng để fine-tune kiểu instruction-tuning dạng:
 - Input: câu hỏi pháp luật (có thể thêm hệ prompt “Bạn là luật sư Việt Nam...” + question + context nếu có).
 - Output: answer.
- Tuy nhiên:
 - ~2.5k mẫu là hơi ít nếu muốn mô hình “hiểu luật Việt Nam” một cách tổng quát; chỉ đủ để mô hình học phong cách trả lời, một số pattern luật hôn nhân/gia đình/dân sự.
 - Nếu dùng model lớn (LLaMA 3.x, Qwen, Gemma, v.v.), nên coi đây là một small-domain adapter/LoRA, không phải full fine-tune tri thức pháp luật toàn diện.

3. Chọn RAG hay fine-tuning với bộ này?

- Nếu mục tiêu là: **chatbot trả lời đúng theo nội dung của dataset + dễ cập nhật luật sau này** → ưu tiên **RAG**, có thể kết hợp một chút fine-tuning để dạy model cách trả lời chuẩn mực (format, giọng điệu pháp lý).
- Nếu mục tiêu là: **demo mô hình “luật sư AI” nho nhỏ** chạy offline, dataset chỉ là một phần training set → có thể **fine-tune nhẹ (LoRA)** trên tập này + thêm các nguồn khác (văn bản luật thô, FAQ pháp luật khác).

Nếu cần, có thể xây luôn một pipeline RAG tối giản dựa trên ds ["train"] với các field question, answer, terms.

1.1. Mục tiêu bài toán

- Xây dựng hệ thống **chatbot tư vấn pháp luật Việt Nam**.
- Dữ liệu tri thức đầu vào: bộ dataset namphan1999/data-luat trên Hugging Face.
- Hai hướng tiếp cận chính mà đề bài gợi ý:
 - **RAG (Retrieval-Augmented Generation)**: mô hình sinh trả lời dựa trên các đoạn văn bản luật/Q&A được truy xuất.
 - **Fine-tuning LLM**: tinh chỉnh mô hình ngôn ngữ trên tập Q&A pháp luật để mô hình “học” cách trả lời.

Trong câu 1, tập trung mô tả, phân tích bộ dữ liệu và đánh giá mức độ phù hợp của nó cho hai hướng RAG và fine-tuning.

1.2. Thông tin tổng quan về dataset

Theo trang dataset trên Hugging Face: [Hugging Face+1](#)

- Tên: namphan1999/data-luat.
- Nền tảng: Hugging Face Datasets.
- Kích thước: khoảng **2.52k mẫu** (2.520 dòng) trong **một split duy nhất train**.
- Định dạng: JSON (đã có bản chuyển sang Parquet cho việc load nhanh). [Hugging Face](#)
- Các cột chính:
 - question: câu hỏi pháp luật (tiếng Việt).

- answer: phần trả lời chi tiết, có giải thích và dẫn chiếu điều luật.
- terms: cụm từ khóa ngắn, thường là dạng rút gọn của câu hỏi hoặc các keyword pháp lý. [Hugging Face](#)
- Lần cập nhật gần nhất trên Hugging Face được ghi nhận: **19/08/2023**. [Hugging Face](#)

Như vậy, đây là một **bộ dữ liệu Q&A pháp luật tiếng Việt đã được chuẩn hóa sẵn**, có cấu trúc rõ ràng, có thể load trực tiếp bằng:

```
from datasets import load_dataset

ds = load_dataset("namphan1999/data-luat")
```

1.3. Đặc trưng nội dung dữ liệu

Dựa trên các ví dụ hiển thị công khai trên Hugging Face: [Hugging Face](#)

- Chủ đề chính:
 - Luật Hôn nhân và Gia đình 2014 (ly hôn, quyền nuôi con, tài sản chung, ngoại tình, cấp dưỡng...).
 - Một phần các vấn đề dân sự liên quan: thừa kế, chuyển nhượng quyền sử dụng đất, thế chấp sổ đỏ, tài sản chung – riêng của vợ chồng.
- Dạng câu hỏi:
 - Mô tả **tình huống thực tế** (case-based), thường khá dài: bối cảnh hôn nhân, tài sản, mâu thuẫn, hành vi vi phạm.
 - Kèm theo 1–2 câu hỏi chốt: “Tôi có được... không?”, “Chồng/vợ tôi có quyền... không?”, “Xử phạt thế nào?”, “Tài sản này được xem là chung hay riêng?”...
- Dạng câu trả lời:
 - Giải thích bằng ngôn ngữ tự nhiên.
 - Có **trích dẫn điều, khoản, điểm** của các văn bản luật cụ thể, ví dụ:
 - “Theo Điều 81 Luật Hôn nhân và gia đình 2014...”,
 - “Theo khoản 1 Điều 33 Luật Hôn nhân và gia đình 2014...”,
 - “Theo Điều 380 Bộ luật Hình sự 2015, sửa đổi bổ sung 2017...”.
[Hugging Face](#)

Kết luận: bộ dữ liệu mang tính **tri thức pháp luật dạng hỏi–đáp, có căn cứ pháp lý rõ ràng**, phù hợp cho cả việc xây chatbot tư vấn lẫn dùng làm tập huấn luyện.

1.4. Cấu trúc kỹ thuật và ý nghĩa từng trường

1. Trường question

- Vai trò:
 - Đầu vào trực tiếp cho bài toán **retrieval** (với RAG) hoặc **instruction** (với fine-tuning).
- Đặc điểm:
 - Ngôn ngữ tự nhiên, tiếng Việt, văn phong người dùng thật.
 - Có nhiều từ ngữ đời thường, sai chính tả nhẹ, cấu trúc câu tự do.
- Ý nghĩa cho bài toán:
 - Giúp mô hình học được cách người dùng thực tế diễn đạt vấn đề pháp lý, không chỉ ngôn ngữ “sách vở”.

2. Trường answer

- Vai trò:
 - Với **RAG**: là **nguồn tri thức** để truy xuất, dùng làm context cung cấp cho LLM.
 - Với **fine-tuning**: là **đáp án mục tiêu (target)** trong bài toán sinh văn bản.
- Đặc điểm:
 - Độ dài vừa phải đến khá dài (có đoạn giải thích + trích luật).
 - Có cấu trúc: mở đầu giải thích, sau đó viện dẫn điều luật, đôi khi kết luận rõ ràng người hỏi nên làm gì. Hugging Face

3. Trường terms

- Vai trò:
 - Là **keyword rút gọn** cho câu hỏi/nhóm vấn đề, thuận lợi cho các thuật toán tìm kiếm.
- Sử dụng:
 - Có thể dùng để:

- Tăng chất lượng **BM25 / keyword search**.
 - Làm “thẻ chủ đề” (topic tags) cho hệ thống gợi ý câu hỏi tương tự.
-

1.5. Đánh giá chất lượng và giới hạn của dữ liệu

1. Ưu điểm

- Dữ liệu được **biên soạn trước**: câu trả lời đã có sẵn, có căn cứ luật, không phải trích luật thủ công từ văn bản pháp luật thô. [Hugging Face](#)
- Cấu trúc nhất quán (3 trường chính), dễ xử lý bằng Hugging Face Datasets. [Hugging Face](#)
- Nội dung bám sát **tình huống thực tế** → phù hợp với dạng câu hỏi thực tế mà chatbot sẽ gặp.
- Có sẵn trích dẫn điều luật → thuận lợi cho:
 - RAG: có thể highlight điều luật trong câu trả lời.
 - Fine-tuning: dạy mô hình “thói quen” trích điều luật.

2. Hạn chế

- **Quy mô**: chỉ khoảng **2.52k mẫu**, không đủ lớn để:
 - Tinh chỉnh một LLM từ đầu để “hiểu toàn bộ pháp luật Việt Nam”.
 - Bao phủ mọi lĩnh vực (hình sự, lao động, thuế, doanh nghiệp, đất đai...); quan sát cho thấy thiên về hôn nhân, gia đình, tài sản trong gia đình. [Hugging Face](#)
 - **Cập nhật luật**:
 - Dataset cập nhật gần nhất 19/08/2023. Một số điều luật có thể đã sửa đổi sau mốc này (không đủ dữ liệu để xác minh cụ thể điều nào). [Hugging Face](#)
 - **Đa dạng ngôn ngữ**:
 - Ngôn ngữ là tiếng Việt, nhưng chủ yếu một phong cách diễn đạt (có thể do cùng một nguồn biên soạn trả lời). Điều này tốt cho thống nhất, nhưng hạn chế độ đa dạng khi fine-tuning.
-

1.6. Mức độ phù hợp với RAG (Retrieval-Augmented Generation)

Đánh giá theo từng tiêu chí kỹ thuật quan trọng:

1. Đơn vị tri thức (knowledge units)

- Mỗi dòng answer thường chứa trọn vẹn một **lập luận pháp lý + trích luật** cho một tình huống cụ thể. [Hugging Face](#)
- Điều này rất phù hợp để:
 - Dùng mỗi record làm một **“document”** hoặc **“chunk lớn”** trong vector store.
 - Hoặc có thể chia nhỏ answer theo từng đoạn, mỗi đoạn xoay quanh 1 điều luật.

2. Chỉ mục hóa (Indexing)

- Có thể xây chỉ mục dựa trên:
 - Toàn bộ answer.
 - Kết hợp question + answer để tăng ngữ nghĩa.
 - Field terms để tăng sức mạnh keyword search.
- Có thể dùng:
 - Dense retrieval (FAISS với embedding tiếng Việt).
 - Sparse retrieval (BM25) + ensemble.
- Đã có một demo open-source sử dụng dataset này để xây chatbot RAG kết hợp FAISS + BM25 + Cross-Encoder reranker. [GitHub](#)

3. Khả năng cập nhật, mở rộng

- Vì RAG tách phần **tri thức** (index) khỏi mô hình, nên:
 - Có thể bổ sung thêm Q&A, thêm văn bản luật mới → chỉ cần re-index.
 - Điều này khắc phục hạn chế “luật thay đổi theo thời gian” tốt hơn so với fine-tuning.

4. Kết luận cho RAG

- Bộ namphan1999/data-luat **rất phù hợp** làm “knowledge base” cho một hệ RAG:
 - Có câu trả lời soạn sẵn, chỉ cần retrieval tốt là đã cho LLM ngữ cảnh đầy đủ.
 - Kích thước ~2.5k mẫu là đủ để index và truy xuất nhanh, chi phí thấp.

1.7. Mức độ phù hợp với fine-tuning LLM

1. Dạng dữ liệu

- Dạng Q&A với cặp (question → answer) phù hợp để chuyển sang format instruction-tuning, ví dụ:
 - Input:
 - System: “Bạn là luật sư chuyên tư vấn pháp luật Việt Nam...”
 - User: nội dung question.
 - Output:
 - Assistant: nội dung answer.

2. Quy mô dữ liệu và ảnh hưởng

- Khoảng 2.52k mẫu:
 - Đủ để **training chỉnh nhẹ (LoRA)** một mô hình đã **manh sẵn** để mô hình:
 - Quen với phong cách trả lời pháp lý.
 - Học được một số pattern viện dẫn luật.
 - Không đủ để:
 - Dạy mô hình toàn bộ tri thức luật Việt Nam.
 - Thay thế nhu cầu RAG khi cần độ chính xác cao và cập nhật luật mới.

3. Rủi ro khi chỉ dùng fine-tuning, không RAG

- Luật thay đổi theo thời gian, trong khi mô hình đã fine-tune thì khó cập nhật nếu chỉ sửa dataset: phải fine-tune lại.
- Mô hình có xu hướng “tổng quát hóa” và có thể sinh ra câu trả lời không còn bám sát chính câu gốc trong dataset → rủi ro cho ứng dụng pháp lý, nơi yêu cầu độ chính xác cao.

4. Kết luận cho fine-tuning

- Dataset này **phù hợp làm tập bổ sung (domain adapter)** hơn là tập duy nhất:
 - Thích hợp để fine-tune một mô hình đã có kiến thức ngôn ngữ chung, sau đó kết hợp với RAG.

- Không thích hợp nếu mục tiêu là: chỉ fine-tune rồi bỏ RAG mà vẫn muốn độ chính xác và cập nhật luật cao.
-

- namphan1999/data-luat là một **bộ dữ liệu Q&A pháp luật Việt Nam** với khoảng 2.52k mẫu, 3 trường chính: question, answer, terms, tập trung nhiều vào các vấn đề hôn nhân, gia đình, tài sản, thừa kế. [Hugging Face+1](#)
- Bộ dữ liệu có cấu trúc tốt, có sẵn viện dẫn điều luật, phù hợp để:
 - Làm **tri thức cho hệ thống RAG** (retrieval trên answer/question/terms).
 - Làm **tập fine-tuning bổ sung** (instruction-tuning) để dạy mô hình phong cách tư vấn pháp luật.
- Với quy mô và tính chất hiện tại, dataset này **phù hợp nhất vai trò knowledge base cho RAG**, còn fine-tuning nên coi là bước tăng cường, không phải giải pháp duy nhất.

1. Mục tiêu hệ thống

Xây dựng chatbot tư vấn luật Việt Nam dựa trên cơ chế **truy hỏi – tăng cường sinh (Retrieval-Augmented Generation, RAG)**. Hệ thống dùng dữ liệu luật Việt Nam, truy xuất thông tin liên quan, sau đó sinh câu trả lời bằng mô hình ngôn ngữ.

2. RAG – Cấu trúc và nguyên lý hoạt động

RAG gồm ba thành phần:

2.1. Bộ mã hoá embedding

Chuyển văn bản luật thành vector số để tìm kiếm.

Hệ thống sử dụng **all-MiniLM-L6-v2**.

Lý do:

- Kích thước nhỏ ~22M tham số.

- Tốc độ nhanh trên CPU.
- Độ chính xác ở mức đủ cho văn bản dài, cấu trúc luật rõ ràng.

Nhược điểm:

- Không được huấn luyện chuyên biệt cho tiếng Việt.
- Không thể hiện được quan hệ ngữ nghĩa quá phức tạp.

2.2. Vector Store

Hệ thống dùng **FAISS**, index dạng **IndexFlatIP**.

Chức năng:

- Lưu vector embedding.
- Tìm kiếm theo độ tương đồng.

Ưu điểm:

- Tìm nhanh, phù hợp dữ liệu cỡ vài nghìn đến vài trăm nghìn văn bản.
- Không yêu cầu GPU.

Nhược điểm:

- Không có tính năng phân tán.
- Yêu cầu rebuild index khi bổ sung dữ liệu lớn.

2.3. Mô hình sinh (Generator)

Hệ thống chọn **gpt-4o-mini**.

Chức năng:

- Kết hợp câu hỏi người dùng + đoạn truy hồi từ FAISS.
- Sinh câu trả lời bằng ngôn ngữ tự nhiên.

Ưu điểm:

- Chi phí thấp.
- Tốc độ phản hồi nhanh.
- Hỗ trợ ngôn ngữ tự nhiên tốt.

Nhược điểm:

- Khả năng lý luận pháp lý hạn chế.
 - Phụ thuộc kết quả truy hồi (nếu truy hồi sai → trả lời sai).
-

3. So sánh RAG với các mô hình tiếp cận khác

3.1. Fine-tuning mô hình ngôn ngữ

Fine-tuning yêu cầu:

- Tập dữ liệu lớn, chất lượng cao.
- GPU mạnh, chi phí cao.
- Khó cập nhật nếu thay đổi dữ liệu.

Ưu điểm:

- Mô hình hiểu sâu ngữ cảnh ngành luật.
- Không cần truy hồi nếu mô hình đủ mạnh.

Nhược điểm:

- Cực kỳ tốn tài nguyên.
- Tính cập nhật thấp (luật thay đổi phải huấn luyện lại).
- Dễ sinh lỗi khi dữ liệu không đồng đều.

So với RAG:

RAG linh hoạt hơn, chỉ cần thay dữ liệu trong index, không phải huấn luyện.

3.2. Retrieval-only (không dùng mô hình sinh)

Hệ thống chỉ trả lại đoạn văn đúng với câu hỏi.

Ưu điểm:

- Không sinh sai thông tin.
- Độ an toàn cao.

Nhược điểm:

- Không trả lời câu hỏi phức tạp.
- Người dùng phải tự đọc văn bản luật.

So với RAG:

RAG có khả năng tổng hợp câu trả lời dễ hiểu.

3.3. Mô hình lớn offline

Sử dụng mô hình tự host như Llama 3, Qwen 2.5, Mistral.

Ưu điểm:

- Linh hoạt, không phụ thuộc OpenAI.

Nhược điểm:

- Không đạt được chất lượng tương đương khi chạy trên CPU.
- Chi phí phần cứng cao nếu muốn chất lượng ngang GPT-4o.

So với RAG:

RAG tận dụng mô hình cloud nhưng dữ liệu vẫn thuộc quyền kiểm soát người dùng.

4. Lý do chọn kiến trúc RAG cho đề tài luật

Dựa trên tính chất của văn bản pháp luật:

- Luật có cấu trúc rõ ràng.
- Truy xuất theo điều khoản cần độ chính xác tuyệt đối.
- Luật thay đổi theo thời gian nên cần cập nhật dễ.

So sánh với các giải pháp khác:

Tiêu chí	RAG	Fine-tuning	Offline LLM
Cập nhật dữ liệu	Dễ	Khó	Dễ
Chi phí	Thấp	Cao	Trung bình

Độ tin cậy thông tin	Cao (nếu truy hỏi đúng)	Không ổn định	Trung bình
Tài nguyên	Thấp	Rất cao	Cao
Độ chính xác theo nguồn	Rất cao	Phụ thuộc dataset	Trung bình

Kết luận: **RAG phù hợp nhất cho văn bản pháp luật khi yêu cầu tính cập nhật, chi phí thấp, không cần huấn luyện lại mô hình.**

5. Nhược điểm của hệ thống RAG hiện tại

- Truy hỏi sai → mô hình trả lời sai.
 - Embedding chưa tối ưu cho tiếng Việt.
 - Dataset gốc hạn chế → cần tăng thêm nguồn.
-

6. Nhược điểm của các mô hình thay thế

6.1. Fine-tuning

- Không thể tự cập nhật nếu luật thay đổi.
- Tốn GPU, thời gian và chi phí.

6.2. Offline LLM

- Không đạt được chất lượng ngang GPT-4o-mini khi chạy CPU cá nhân.
 - Tốn 30–40GB VRAM nếu muốn chất lượng cao.
-

7. Lý do chọn mô hình hiện tại

Toàn bộ quyết định được dựa trên các tiêu chí:

1. **Chi phí thấp** – không cần GPU, không cần server.
2. **Khả năng cập nhật liên tục** – index FAISS có thể rebuild nhanh.
3. **Tính đúng đắn luật** – truy xuất chính xác văn bản nguồn.
4. **Tính linh hoạt** – chỉ cần thay dataset là mở rộng được phạm vi.
5. **Dễ triển khai** – chạy trên máy cá nhân + Cloudflare Tunnel.

Kết luận: **RAG là lựa chọn tối ưu nhất cho đồ án tư vấn luật với điều kiện tài nguyên hạn chế nhưng yêu cầu độ chính xác cao.**

Lợi ích khi đưa file pdf vào:

mở rộng tri thức -> dataset gốc chỉ 2k mẫu, pdf sẽ bổ sung thêm luật gốc

Truy xuất pdf theo form “ Điều..., khoản ... → trích dẫn cho người dùng(khi chatbot trả lời sẽ trích theo điều như context)

Giảm tải cho llm → chunking theo ký tự+ overlap giúp đoạn văn vừa tầm, vừa đủ bao quát , ko bị quá dài.

- ko cần fine-tune : → chỉ cần rebuild index khi thêm, sửa pdf, mô hình sinh, lấy api key của gpt nên ko cần train lại