



Tiểu luận giữa kỳ - tiểu luận chuỗi tgan

Phân tích dữ liệu (Trường Đại học Kinh tế – Luật, Đại học Quốc gia Thành phố Hồ Chí Minh)



messages.pdf_cover_qr_code_label

**BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KINH TẾ - LUẬT**



**BÁO CÁO TIỂU LUẬN GIỮA KỲ
ỨNG DỤNG CÁC PHƯƠNG PHÁP CHUỖI THỜI GIAN TRONG
DỰ BÁO SỐ LƯỢNG HÀNH KHÁCH:
NGHIÊN CỨU THỰC NGHIỆM VỚI DỮ LIỆU
AIRLINE PASSENGERS**

GVHD: THS.LƯƠNG THANH QUỲNH

MÃ HỌC PHẦN: 243TO3501

SINH VIÊN THỰC HIỆN: NGUYỄN THỊ HỒNG NHƯ

MSSV: K214011407

Thành phố Hồ Chí Minh, ngày 17 tháng 06 năm 2025

LỜI CẢM ƠN

Em xin chân thành cảm ơn giảng viên bộ môn – GV.Ths Lương Thanh Quỳnh đã tận tình truyền đạt kiến thức, định hướng nội dung và hỗ trợ em trong suốt quá trình thực hiện bài tiểu luận.

Bên cạnh đó, em cũng xin gửi lời cảm ơn đến quý thầy cô trong bộ môn đã cung cấp nền tảng lý thuyết và kỹ năng thực hành cần thiết, giúp em có thể vận dụng hiệu quả các công cụ phân tích dữ liệu vào bài làm.

Cuối cùng, em xin cảm ơn các bạn trong lớp đã cùng trao đổi, chia sẻ kinh nghiệm và góp ý trong quá trình học tập và hoàn thành đề tài.

Do thời gian và kiến thức còn hạn chế, bài tiểu luận không tránh khỏi thiếu sót. Em kính mong nhận được sự góp ý quý báu từ thầy cô để em có thể hoàn thiện hơn trong các nghiên cứu sau này.

Em xin trân trọng cảm ơn.

MỤC LỤC

MỞ ĐẦU	1
CHƯƠNG 1. TỔNG QUAN LÝ THUYẾT	2
1.1. Khái niệm chuỗi thời gian	2
1.2. Các thành phần của chuỗi thời gian:	2
1.3. Giới thiệu các phương pháp dự báo:.....	4
CHƯƠNG 2. DỮ LIỆU VÀ MÔ TẢ BAN ĐẦU	6
2.1. Nguồn dữ liệu và cách thu thập	6
2.2. Thông tin biến số chính	6
2.3. Chuyển đổi và tiền xử lý dữ liệu trong Stata	7
2.3.1. Nhập dữ liệu vào Stata và kiểm tra biến.....	7
2.3.2. Chuyển chuỗi month sang biến thời gian mới Stata có thể nhận diện.....	8
2.3.3. Kiểm tra lại sau chuyển đổi	10
2.4. Biểu đồ khám phá dữ liệu ban đầu.....	11
2.4.1. Biểu đồ đường thời gian	11
2.4.2. Biểu đồ phân phối và thống kê tóm tắt	13
CHƯƠNG 3. CÁC PHƯƠNG PHÁP THỰC NGHIỆM	16
3.1. Phương pháp Naive.....	16
3.1.1. Mô tả ý tưởng, công thức	16
3.1.2. Thực hiện bằng thủ công (tính toán trên excel)	16
3.1.3. Thực hành trên Stata.....	17
3.2. Phương pháp Trung bình trượt - Moving Average (MA).....	19
3.2.1. Mô tả ý tưởng và công thức	19
3.2.2. Lựa chọn độ dài cửa sổ (kỳ)	19
3.2.3. Tính toán thủ công bằng excel	19
3.2.4. Thực hành trên Stata.....	20
3.3. Phương pháp Trọng số trung bình trượt - Weighted Moving Average (WMA)	29
3.3.1. Mô tả ý tưởng, công thức	29
3.3.2. Tìm bộ trọng số phù hợp	29

3.4. Phương pháp làm mượt hàm mũ cơ bản - Exponential Smoothing (ES)	32
3.4.1. Mô tả ý tưởng và công thức	32
3.4.2. Lựa chọn hệ số làm mượt α	33
3.4.3. Tính toán thủ công bằng Excel	33
3.4.4. Thực hành trên Stata	34
3.5. Phương pháp Linear Trend Regression (Hồi quy xu hướng tuyến tính)	39
3.5.1. Mô tả	39
3.5.2. Tính toán thủ công trên Excel	40
3.5.3. Thực hành trên Stata	40
3.6. Phương pháp Holt's Linear Exponential Smoothing	43
3.6.1. Mô tả	43
3.6.2. Tính toán thủ công trên Excel	44
3.6.3. Thực hành trên Stata	44
3.7. Phương pháp Seasonality and Trend (Hồi quy tuyến tính có yếu tố mùa vụ)	49
3.7.1. Mô tả	49
3.7.2. Tính toán thủ công bằng Excel	50
3.7.3. Thực hành trên Stata	50
3.8. Phân tích tách thành phần (Time Series Decomposition)	55
3.8.1. Phương pháp cộng tính (Additive decomposition)	55
3.8.2. Phương pháp nhân tính (Multiplicative decomposition)	56
CHƯƠNG 4. KẾT QUẢ SO SÁNH VÀ KẾT LUẬN	59
TÀI LIỆU THAM KHẢO	62

MỞ ĐẦU

Trong bối cảnh nền kinh tế ngày càng phát triển và môi trường kinh doanh không ngừng biến động, việc dự báo và phân tích xu hướng tương lai trở thành một nhu cầu thiết yếu trong nhiều lĩnh vực như tài chính, vận tải, thương mại, sản xuất, và quản lý chuỗi cung ứng. Một trong những công cụ quan trọng phục vụ cho mục tiêu này chính là phân tích chuỗi thời gian - phương pháp khai thác dữ liệu theo trình tự thời gian nhằm phát hiện các mẫu (patterns), xu hướng (trends), tính mùa vụ (seasonality), hay chu kỳ (cycles) có trong dữ liệu. Việc hiểu và dự báo được hành vi trong tương lai dựa trên chuỗi thời gian lịch sử không chỉ giúp các nhà quản lý đưa ra quyết định chính xác, mà còn tạo lợi thế cạnh tranh trong việc lập kế hoạch và điều chỉnh chiến lược kinh doanh.

Trong thực tiễn, phân tích chuỗi thời gian được ứng dụng rất đa dạng. Ví dụ, các hãng hàng không sử dụng nó để dự báo số lượng hành khách theo từng mùa; ngân hàng dùng để dự đoán xu hướng lãi suất hoặc biến động tỷ giá; các doanh nghiệp bán lẻ sử dụng để quản lý hàng tồn kho và tối ưu hóa chuỗi cung ứng. Việc áp dụng đúng phương pháp phân tích sẽ góp phần nâng cao độ chính xác của dự báo, từ đó tối ưu hóa hiệu suất hoạt động và giảm thiểu rủi ro.

Xuất phát từ nhu cầu thực tiễn đó, bài tiểu luận này tập trung phân tích một bộ dữ liệu chuỗi thời gian về số lượng hành khách hàng không trong giai đoạn từ năm 1951 đến 1960. Dữ liệu sẽ được xử lý và phân tích bằng các phương pháp phổ biến trong phân tích chuỗi thời gian như Naive, Trung bình trượt, San bằng mũ, Hồi quy tuyến tính và các mô hình có yếu tố mùa vụ. Mục tiêu chính là so sánh hiệu quả của từng phương pháp, đánh giá mức độ phù hợp của mô hình với dữ liệu thực tế, và từ đó đề xuất mô hình dự báo tốt nhất. Kết quả của nghiên cứu không chỉ mang ý nghĩa thực hành trong việc vận dụng các kỹ thuật phân tích dữ liệu, mà còn góp phần củng cố kiến thức lý thuyết và năng lực xử lý số liệu cho người học trong lĩnh vực khoa học dữ liệu và phân tích định lượng.

CHƯƠNG 1. TỔNG QUAN LÝ THUYẾT

1.1. Khái niệm chuỗi thời gian

Chuỗi thời gian (time series) là một dãy các quan sát thu thập được theo trình tự thời gian, thường cách đều nhau về mặt thời điểm, chẳng hạn như theo ngày, theo tháng, theo quý hoặc theo năm. Mỗi quan sát trong chuỗi thể hiện giá trị của một hiện tượng kinh tế, xã hội hoặc tự nhiên tại một thời điểm xác định. Điểm đặc trưng của chuỗi thời gian là tính liên kết chặt chẽ giữa các quan sát, tức là giá trị của biến tại một thời điểm nào đó thường chịu ảnh hưởng bởi giá trị của chính biến đó ở các thời điểm trước.

Phân tích chuỗi thời gian đóng vai trò quan trọng trong việc khám phá các quy luật vận động ẩn sau các dãy số liệu, từ đó đưa ra những mô hình phù hợp nhằm mô tả và dự báo hành vi tương lai của hiện tượng nghiên cứu. Khác với các dạng dữ liệu không có yếu tố thời gian, chuỗi thời gian yêu cầu phải quan tâm đến mối liên hệ giữa các thời điểm, điều này đòi hỏi việc sử dụng các kỹ thuật đặc thù để đảm bảo tính hiệu quả và chính xác của mô hình.

Trong thực tiễn, dữ liệu chuỗi thời gian được sử dụng rộng rãi trong nhiều lĩnh vực. Chẳng hạn, trong kinh tế học, người ta phân tích chuỗi GDP, chỉ số giá tiêu dùng hoặc tỷ lệ thất nghiệp qua các năm để đánh giá hiệu quả chính sách kinh tế; trong tài chính, việc dự báo giá cổ phiếu hay lãi suất dựa trên chuỗi dữ liệu lịch sử là công việc phổ biến; trong vận tải và logistics, chuỗi dữ liệu hành khách hay lượng hàng hóa vận chuyển theo tháng giúp xây dựng kế hoạch hoạt động hợp lý. Do đó, việc hiểu rõ khái niệm chuỗi thời gian không chỉ là bước nền tảng trong phân tích dữ liệu định lượng, mà còn là tiền đề để lựa chọn và áp dụng đúng phương pháp phân tích trong từng tình huống cụ thể.

1.2. Các thành phần của chuỗi thời gian:

Một chuỗi thời gian thực chất là sự tổng hợp của nhiều yếu tố ảnh hưởng đến hiện tượng được quan sát theo thời gian. Việc phân tích và tách biệt các thành phần này giúp nhà phân tích hiểu được bản chất của dữ liệu, từ đó chọn mô hình dự báo phù hợp. Thông thường, chuỗi thời gian có bốn thành phần chính: xu hướng (trend), mùa vụ (seasonality), chu kỳ (cycle), và thành phần ngẫu nhiên (irregular). Ngoài ra, một số mẫu hình đặc biệt

như dạng nằm ngang (horizontal) hoặc kết hợp xu hướng và mùa vụ (trend & seasonal) cũng cần được nhận diện riêng trong quá trình phân tích.

Xu hướng (Trend) phản ánh sự thay đổi dài hạn của chuỗi theo một chiều hướng nhất định, thường là tăng dần hoặc giảm dần. Sự thay đổi này thường bắt nguồn từ những yếu tố mang tính vĩ mô hoặc dài hạn như sự phát triển dân số, công nghệ hoặc thay đổi trong hành vi tiêu dùng. Ví dụ, xu hướng tăng trưởng về số lượng hành khách hàng không trong nhiều năm là điều dễ quan sát.

Mùa vụ (Seasonality) là những dao động có tính chu kỳ và lặp lại trong một khoảng thời gian cố định như tháng, quý hoặc năm. Những biến động này thường do yếu tố thời tiết, lễ tết, hoặc chu kỳ kinh doanh ngắn hạn gây ra. Trong dữ liệu vận tải hành khách, mùa cao điểm như mùa hè hoặc dịp lễ sẽ ghi nhận lượng hành khách cao hơn bình thường.

Chu kỳ (Cycle) là các dao động dài hạn và không đều, thường liên quan đến các giai đoạn phát triển – suy thoái trong nền kinh tế hoặc thị trường. Không giống như mùa vụ, chu kỳ không lặp lại theo một khung thời gian cố định và khó dự đoán. Đây là thành phần thường bị bỏ qua trong các mô hình đơn giản, nhưng lại rất quan trọng trong phân tích dài hạn.

Thành phần ngẫu nhiên (Irregular hoặc Residual) bao gồm các biến động không tuân theo bất kỳ quy luật nào rõ ràng. Đây có thể là những giá trị đột biến do sự kiện bất thường, sai số đo lường, hoặc các yếu tố không thể kiểm soát. Khi xây dựng mô hình, thành phần này thường được coi là nhiễu và cần được tách ra để nâng cao độ chính xác của dự báo.

Bên cạnh đó, trong quá trình quan sát đồ thị chuỗi thời gian, người ta có thể bắt gặp *mẫu hình nằm ngang (horizontal pattern)* – tức là khi chuỗi dao động xung quanh một giá trị trung bình tương đối ổn định, không có xu hướng tăng hoặc giảm rõ ràng. Đây thường là dấu hiệu cho thấy dữ liệu không có cấu trúc xu hướng hay mùa vụ rõ nét, và những mô hình dự báo đơn giản như trung bình cộng hoặc san bằng mũ có thể phù hợp.

Ngoài ra, nhiều chuỗi thời gian trong thực tế còn có sự kết hợp đồng thời cả xu hướng và mùa vụ, tạo thành *mẫu hình vừa có xu hướng vừa có tính mùa vụ (trend &*

seasonal pattern). Trong trường hợp này, các mô hình dự báo cần đủ linh hoạt để xử lý đồng thời cả hai yếu tố. Những mô hình như Holt-Winters hoặc phương pháp phân rã chuỗi thời gian thường được sử dụng để giải quyết tình huống phức tạp này.

1.3. Giới thiệu các phương pháp dự báo:

Dự báo trong chuỗi thời gian là quá trình xây dựng các mô hình định lượng nhằm dự đoán giá trị tương lai của một biến số dựa trên các quan sát quá khứ. Tùy vào tính chất của chuỗi - có hay không có xu hướng (trend), mùa vụ (seasonality), hay mức độ nhiễu động - mà người phân tích sẽ lựa chọn phương pháp dự báo phù hợp. Trong tiểu luận này, tám phương pháp phổ biến đã được lựa chọn để khảo sát, bao gồm từ các kỹ thuật đơn giản đến các mô hình có tính linh hoạt cao hơn, nhằm phục vụ cho việc đánh giá toàn diện hiệu quả của từng phương án.

Phương pháp đầu tiên là Naive - một phương pháp dự báo đơn giản trong đó giá trị dự báo ở kỳ tiếp theo chính là giá trị thực tế của kỳ hiện tại. Mặc dù không xem xét đến xu hướng hay mùa vụ, Naive lại thường được dùng làm mô hình “chuẩn nền” để so sánh với các mô hình phức tạp hơn, nhờ tính minh bạch và không cần giả định đầu vào.

Tiếp theo là nhóm các phương pháp dựa trên trung bình, bao gồm Trung bình trượt đơn giản (Moving Average - MA) và Trung bình trượt có trọng số (Weighted Moving Average - WMA). Với MA, giá trị dự báo được tính từ trung bình cộng của một số kỳ gần nhất, giúp làm mượt dữ liệu và giảm ảnh hưởng từ các dao động ngắn hạn. Trong khi đó, WMA cải tiến bằng cách gán trọng số khác nhau cho từng kỳ, thường ưu tiên cao hơn cho các quan sát gần hiện tại. Cách tiếp cận này giúp mô hình phản ứng nhanh hơn với xu thế thay đổi nhưng đồng thời cũng đòi hỏi sự chọn lọc cẩn thận các trọng số phù hợp.

Một phương pháp khác thường được sử dụng trong thực tiễn là San bằng mũ đơn giản (Exponential Smoothing - ES), dựa trên nguyên lý rằng các giá trị gần hiện tại mang thông tin hữu ích hơn so với các giá trị xa trong quá khứ. Trọng số trong ES được phân bổ giảm dần theo hàm mũ, giúp mô hình duy trì tính đơn giản nhưng vẫn phản ánh được xu hướng ngắn hạn của chuỗi. Phương pháp này đặc biệt hữu dụng với các chuỗi không có mùa vụ rõ rệt.

Đối với những chuỗi có xu hướng tăng hoặc giảm rõ nét, mô hình Hồi quy tuyến tính theo thời gian (Linear Trend Regression) được sử dụng để nắm bắt mối quan hệ giữa giá trị quan sát và thời gian. Khi chuỗi dữ liệu thể hiện sự thay đổi có hệ thống theo thời gian, phương pháp này giúp đưa ra dự báo tuyến tính hợp lý trong trung và dài hạn. Để xử lý đồng thời cả xu hướng và mức độ thay đổi theo thời gian của xu hướng đó, mô hình Sai mũ kép của Holt (Holt's Exponential Smoothing) được phát triển, kết hợp giữa san bằng mũ và thành phần xu hướng tuyến tính. Khi dữ liệu đồng thời có xu hướng và mùa vụ, mô hình này lại được mở rộng thành Holt–Winters (còn gọi là mô hình xu hướng kết hợp mùa vụ), trong đó cả ba yếu tố – mức trung bình, xu hướng và mùa vụ – đều được cập nhật linh hoạt bằng các tham số san bằng riêng biệt.

Cuối cùng, phương pháp phân tích tách thành phần (Decomposition) đóng vai trò quan trọng trong việc làm sáng tỏ cấu trúc nội tại của chuỗi. Phương pháp này chia chuỗi thành các thành phần riêng biệt: xu hướng (T), mùa vụ (S) và nhiễu (I), có thể theo dạng cộng (Additive) hoặc nhân (Multiplicative), tùy theo tính chất dao động. Đây không chỉ là công cụ hỗ trợ trực quan hóa dữ liệu mà còn giúp xác định loại mô hình phù hợp cho việc dự báo.

Nhìn chung, việc triển khai đồng thời nhiều phương pháp dự báo không chỉ nhằm tìm kiếm mô hình có sai số thấp nhất, mà còn giúp kiểm nghiệm xem chuỗi dữ liệu mang tính chất như thế nào – có xu hướng, có mùa vụ, hay chỉ biến động ngẫu nhiên. Điều này góp phần quan trọng vào việc đưa ra các dự báo đáng tin cậy, phục vụ cho phân tích định lượng và ra quyết định thực tiễn.

CHƯƠNG 2. DỮ LIỆU VÀ MÔ TẢ BAN ĐẦU

2.1. Nguồn dữ liệu và cách thu thập

Để nghiên cứu tính chất chuỗi thời gian có cả xu hướng và mùa vụ, tôi sử dụng bộ dữ liệu AirPassengers - tổng số hành khách quốc tế hàng tháng (tính theo nghìn người) của các hãng hàng không lớn - trong giai đoạn tháng 1/1949 đến tháng 12/1960. Dữ liệu gốc được thu thập từ báo cáo doanh thu hành khách nội địa và quốc tế do các hãng hàng không công bố, sau đó tổng hợp và chuẩn hóa bởi nhóm nghiên cứu tại Trung tâm Dữ liệu Thời gian (Time Series Data Center) để đảm bảo tính đồng nhất về đơn vị và phạm vi quan sát. Bộ dữ liệu gốc có hơn 1.440 quan sát (1949–1960) được lưu dưới dạng CSV trên GitHub tại địa chỉ:

<https://raw.githubusercontent.com/jbrownlee/Datasets/master/airline-passengers.csv>. File CSV này gồm hai cột “**Month**” (định dạng chuỗi YYYY-MM) và “**Passengers**” (số hành khách trung bình tháng đó, đơn vị nghìn người). Để tập trung phân tích đúng hướng của bài báo cáo, em đã trích xuất chính xác 120 quan sát từ 1951-01 đến 1960-12 để đưa vào phân tích, đây là file dữ liệu sau khi rút gọn: [airline-passengers](#).

Phiên bản cắt gọn vừa đủ này giúp quá trình nhập và tiền xử lý trong Stata diễn ra nhanh chóng, đồng thời cho phép ta tập trung vào so sánh hiệu quả dự báo của các mô hình mà không làm mất đi tính đại diện của chuỗi thời gian.

2.2. Thông tin biến số chính

Bộ dữ liệu AirPassengers (1951-1960) bao gồm hai biến then chốt, lần lượt là **Month** và **Passengers**, hoàn toàn đáp ứng yêu cầu phân tích chuỗi thời gian có cả mùa vụ hàng năm và xu hướng dài hạn. Biến **Month** ban đầu được lưu dưới dạng chuỗi ký tự (string) theo mẫu YYYY-MM - ví dụ “1951-01” cho tháng 1 năm 1951 - đảm bảo mỗi quan sát thể hiện đúng mốc thời gian từng tháng trong khoảng 120 tháng liên tiếp. Biến này không có giá trị thiếu (missing value) và đã được chọn kỹ lưỡng để loại bỏ bất cứ khoảng trống nào, từ đó tạo điều kiện cho việc sắp xếp tuần tự và tính toán khoảng cách đều đặn giữa các điểm dữ liệu.

Biến **Passengers** là số thực (float) biểu diễn tổng số hành khách quốc tế trung bình trong mỗi tháng (tính theo nghìn người). Qua kiểm tra tóm tắt, ta thấy giá trị **Passengers** dao động từ khoảng 112 nghìn (thời điểm thấp đầu những năm 1950) đến mức đỉnh trên 600 nghìn (cao điểm mùa hè cuối thập kỷ), phản ánh rõ xu hướng tăng đều và biên độ mùa vụ ngày càng lớn. Không tồn tại giá trị ngoại lai bất hợp lý hay missing value trong 120 quan sát này, cho thấy tính toàn vẹn của dữ liệu.

2.3. Chuyển đổi và tiền xử lý dữ liệu trong Stata

Trước khi tiến hành bất cứ phân tích hay mô hình dự báo nào, bước tiền xử lý và chuẩn hóa dữ liệu là vô cùng quan trọng, bởi chất lượng đầu vào quyết định độ tin cậy của kết quả sau này. Khi bắt đầu tiến hành chạy chương trình trên Stata, ta sẽ phải thực hiện từng bước như sau:

2.3.1. Nhập dữ liệu vào Stata và kiểm tra biến

- Đầu tiên, sử dụng lệnh **import delimited** để đọc file CSV vào bộ nhớ:

```
. import delimited "C:\Users\Hong Nhu\Downloads\airline-passengers.csv"  
(encoding automatically selected: ISO-8859-1)  
(2 vars, 120 obs)
```

- Kiểm tra và làm sạch dữ liệu:

```
. describe  
  
Contains data  
Observations:      120  
Variables:          2  
  
-----  
Variable      Storage   Display   Value  
  name         type     format   label      Variable label  
-----  
month          str7      %9s             Month  
passengers     int       %8.0g          Passengers  
  
Sorted by:  
Note: Dataset has changed since last saved.
```

Lệnh **describe** giúp liệt kê các tên biến hiện có, kiểu dữ liệu của từng biến và nhãn (nếu có), từ đó thuận tiện cho việc quan sát và ta có thể phát hiện rằng biến **month** đang là kiểu định dạng string và biến **passengers** là định dạng float.

```
. summarize
```

Variable	Obs	Mean	Std. dev.	Min	Max
month	0				
passengers	120	309.725	109.5254	145	622

Sau khi sử dụng câu lệnh **summarize**, kết quả hiển thị sẽ cho ta biết số quan sát (Obs), giá trị trung bình (Mean), độ lệch chuẩn (Std.dev), min - max, và từ đó kiểm tra xem có giá trị bất thường (outlier) hay missing value không. Trong bộ 120 quan sát này, không thấy missing value và phạm vi giá trị của biến **passengers** dao động một cách hợp lý từ 100 đến khoảng 650.

2.3.2. Chuyển chuỗi month sang biến thời gian mới Stata có thể nhận diện

Trước hết, vì dữ liệu ban đầu có cột biến thời gian gốc (**month**) là dưới dạng định dạng chuỗi (string), do đó đối với thực hiện phân tích Stata, khi tiếp cận dữ liệu thời gian có định dạng chuỗi, bước đầu tiên là biến đổi chúng thành giá trị thời gian có ý nghĩa toán học để Stata có thể nhận diện và sắp xếp theo trật tự. Các bước để chuyển đổi định dạng biến thời gian được thực hiện như sau:

- Bước 1: Tạo biến mới đại diện cho biến thời gian gốc

```
. gen monthly_date = monthly( month, "YM")
```

Lệnh này được sử dụng để tạo ra biến mới là **monthly_date**, trong đó hàm **monthly()** sẽ phân tích chuỗi thời gian tại biến **month** theo mẫu “Year-Month” (“YM”) và chuyển mỗi giá trị của biến **month** thành một số nguyên nội tại biểu diễn cho tháng tương ứng. Việc này không chỉ giúp máy tính phân biệt đâu là “tháng trước” và “tháng sau”, mà còn làm nền tảng cho mọi thao tác phân tích chuỗi thời gian về sau.

- Bước 2: Gán định dạng hiển thị

Dữ liệu tại biến mới (**monthly_date**) sau khi lưu ở dạng số nguyên sẽ hiển thị dưới con số vô nghĩa nếu không được format, ví dụ như sau:

Data Editor (Edit) - [Untitled]

File Edit View Data Tools

monthly_date[2] -107

	month	passengers	monthly_date
1	1951-01	145	-108
2	1951-02	150	-107
3	1951-03	178	-106
4	1951-04	163	-105
5	1951-05	172	-104
6	1951-06	178	-103
7	1951-07	199	-102
8	1951-08	199	-101
9	1951-09	184	-100
10	1951-10	162	-99
11	1951-11	146	-98
12	1951-12	166	-97
13	1952-01	171	-96
14	1952-02	180	-95
15	1952-03	193	-94
16	1952-04	181	-93
17	1952-05	183	-92
18	1952-06	218	-91
19	1952-07	230	-90
20	1952-08	242	-89
21	1952-09	209	-88
22	1952-10	191	-87
23	1952-11	172	-86
24	1952-12	194	-85
25	1953-01	196	-84
26	1953-02	196	-83

Vars: 3 Order: Dataset Obs: 120 Filter: Off Mode: Edit CAP NUM

Variables

Filter variables here

☒ Name ☐ Label

☒ month Month

☒ passengers Passengers

☒ monthly_date

Variables Snapshots

Properties

Variables

Name

Label

Type

Format

Value label

Notes

Data

Frame default

Filename

Label

Notes

Variables 3

Observations 120

Vì vậy ta buộc phải nhập thêm một dòng lệnh đi kèm nhằm format cho biến thời gian mới, chỉ khi đó thì dữ liệu của biến **monthly_date** sẽ được Stata hiển thị đúng dạng tháng và năm như kỳ vọng.

```
. format monthly_date %tm
```

Kết quả sau khi được format:

The screenshot shows the Stata Data Editor interface. The main window displays a dataset with the following columns: **month**, **passengers**, and **monthly_date**. The **monthly_date** column contains values in the format **YYMM** (e.g., 1951m1, 1951m2). The right sidebar shows the **Variables** list with **monthly_date** selected. The status bar at the bottom indicates **Vars: 3 Order: Dataset Obs: 120 Filter: Off Mode: Edit CAP NUM**.

	month	passengers	monthly_date
1	1951-01	145	1951m1
2	1951-02	150	1951m2
3	1951-03	178	1951m3
4	1951-04	163	1951m4
5	1951-05	172	1951m5
6	1951-06	178	1951m6
7	1951-07	199	1951m7
8	1951-08	199	1951m8
9	1951-09	184	1951m9
10	1951-10	162	1951m10
11	1951-11	146	1951m11
12	1951-12	166	1951m12
13	1952-01	171	1952m1
14	1952-02	180	1952m2
15	1952-03	193	1952m3
16	1952-04	181	1952m4
17	1952-05	183	1952m5
18	1952-06	218	1952m6
19	1952-07	230	1952m7
20	1952-08	242	1952m8
21	1952-09	209	1952m9
22	1952-10	191	1952m10
23	1952-11	172	1952m11
24	1952-12	194	1952m12
25	1953-01	196	1953m1
26	1953-02	196	1953m2

Có thể thấy rằng sau khi đi kèm lệnh `format` thì Stata sẽ tự động chuyển cách hiển thị dữ liệu ban đầu của biến **monthly_date** thành “1951m1”, “1951m2”..., giúp đồ thị và bảng báo cáo được trực quan hơn.

- Bước 3: Khai báo chuỗi thời gian

Cuối cùng, để Stata hiểu rằng biến **monthly_date** chính là trục thời gian, với khoảng cách giữa các giá trị liên tiếp đều bằng một tháng, ta sẽ dùng lệnh:

```
. tsset monthly_date

Time variable: monthly_date, 1951m1 to 1960m12
Delta: 1 month

.
```

Khi đó, mọi lệnh của Stata về sau có liên quan tới chuỗi thời gian (ví dụ như khi tiến hành vẽ biểu đồ `tsline`, thực hiện `forecast`, v.v.) thì sẽ tự động căn cứ vào biến **monthly_date** này để tính toán lag, lead, trượt trung bình hay mô hình dự báo.

2.3.3. Kiểm tra lại sau chuyển đổi

Sau khi thực hiện các câu lệnh xong, để đảm bảo ta sẽ kiểm tra một lần nữa để

chắc chắn rằng các kết quả hiển thị dữ liệu thời gian tương ứng đúng với mốc thời gian gốc ban đầu.

```
. tsset monthly_date  
  
Time variable: monthly_date, 1951m1 to 1960m12  
Delta: 1 month  
  
. list month monthly_date in 1/5
```

	month	monthly_date
1.	1951-01	1951m1
2.	1951-02	1951m2
3.	1951-03	1951m3
4.	1951-04	1951m4
5.	1951-05	1951m5

Đồng thời, dùng lệnh **tsreport** sẽ in ra tóm tắt thông tin chuỗi (bao gồm số quan sát, khoảng thời gian bắt đầu và kết thúc), đảm bảo không có missing time points.


```
. tsreport  
  
Time variable: monthly_date  
-----  
Starting period = 1951m1  
Ending period  = 1960m12  
Number of obs   =    120  
Number of gaps  =     0
```

2.4. Biểu đồ khám phá dữ liệu ban đầu

Sau khi hoàn tất việc khai báo chuỗi thời gian, bước tiếp theo là khám phá trực quan và thống kê sơ bộ để hiểu rõ cấu trúc dữ liệu – bao gồm xu hướng (trend), mùa vụ (seasonality) và thành phần nhiễu (noise) – trước khi áp dụng các mô hình dự báo.

2.4.1. Biểu đồ đường thời gian

```
. twoway (line passengers monthly_date)
```





Khi quan sát biểu đồ đường thời gian của bộ dữ liệu AirPassengers từ tháng 1/1951 đến tháng 12/1960, ta vẫn dễ dàng nhận thấy chuỗi dữ liệu mang hai đặc trưng nổi bật: một xu hướng tăng ổn định và một mẫu mùa vụ lặp lại hàng năm. Cụ thể, kể từ đầu năm 1951, tổng số hành khách quốc tế ghi nhận mỗi tháng liên tục đi lên, thể hiện qua việc các đỉnh và đáy của mỗi năm đều cao hơn so với năm trước đó. Điều này phản ánh sự mở rộng nhanh chóng của ngành hàng không dân dụng trong thập kỷ 1950. Bên cạnh xu hướng tăng, đồ thị còn cho thấy tính mùa vụ rất rõ: mỗi năm, số hành khách đạt đỉnh vào mùa hè - khoảng từ tháng 6 đến tháng 8 - và suy giảm về cuối năm, đặc biệt là dịp tháng 11 - 12. Không chỉ lặp lại định kỳ, biên độ giữa đỉnh và đáy của mùa cao điểm cũng ngày càng lớn, cho thấy mùa hè càng trở nên “mạnh” hơn khi lượng khách tăng dần qua các năm. Trên nền hai thành phần chính này vẫn tồn tại những dao động nhỏ không theo quy luật - có thể là do các biến cố bên ngoài như thời tiết bất lợi hoặc sự kiện kinh tế bất ngờ - tạo nên khối nhiễu nhẹ so với xu hướng và mùa vụ.

2.4.2. Biểu đồ phân phối và thống kê tóm tắt

Dưới đây là biểu đồ histogram thể hiện phân phối số lượng hành khách hàng tháng (đơn vị nghìn người) của bộ AirPassengers từ tháng 1/1951 đến tháng 12/1960:

```
. histogram passengers, width(50) percent  
(bin=10, start=145, width=50)
```



```
. summarize passengers , detail
```

Passengers				
	Percentiles	Smallest		
1%	146	145		
5%	168.5	146		
10%	180	150	Obs	120
25%	222.5	162	Sum of wgt.	120
50%	303.5		Mean	309.725
		Largest	Std. dev.	109.5254
75%	390.5	548		
90%	464	559	Variance	11995.81
95%	506.5	606	Skewness	.5935114
99%	606	622	Kurtosis	2.717176

Chuỗi phân phối mang xu hướng lệch phải rõ rệt: tần suất các giá trị thấp (khoảng 100-200 nghìn) chiếm tỷ lệ cao nhất, trong khi các giá trị cao (trên 500 nghìn) xuất hiện rất ít. Điều này phản ánh rằng trong suốt giai đoạn 1951-1960, phần lớn các tháng có lưu lượng hành khách ở mức vừa phải, còn những tháng có lưu lượng cực cao (đỉnh mùa hè vào những năm cuối thập kỷ) khá hiếm. Đồng thời, histogram ghi nhận rằng khối lượng quan sát phân bố đều dần theo các khoảng bin, cho thấy xu hướng tăng tổng thể - các bin giá trị trung gian (300-400 nghìn) chiếm tỷ lệ tương đối lớn, minh chứng cho việc lưu lượng hành khách tăng dần qua thời gian.

Ngoài ra, đỉnh tần suất không tập trung đột biến ở một giá trị duy nhất, mà trải đều trên khoảng 150-250 nghìn, cho thấy mặc dù có sự tăng trưởng, dữ liệu không quá “kẹt” vào một mốc cụ thể nào, mà sự phân bố khá đa dạng. Điều này phù hợp với quan sát về xu hướng tăng đều nhưng có sự biến động theo mùa: những tháng thấp điểm liên tục dịch chuyển lên cao hơn so với các năm trước.

Như vậy, chương 2 tập trung khái quát nguồn gốc, cấu trúc và đặc điểm của bộ dữ liệu sunspots (1974-1983), đồng thời hoàn thiện quy trình tiền xử lý trong Stata và khám phá sơ bộ các thành phần chuỗi thời gian. Những kết quả này chính là nền tảng quan trọng để lựa chọn và triển khai đúng đắn các phương pháp dự báo trong chương 3, bắt

đầu với phương pháp Naive Forecast đơn giản và lần lượt mở rộng tới các kỹ thuật phức tạp hơn.

CHƯƠNG 3. CÁC PHƯƠNG PHÁP THỰC NGHIỆM

3.1. Phương pháp Naive

3.1.1. Mô tả ý tưởng, công thức

Phương pháp Naive (phương pháp đơn giản nhất) là kỹ thuật dự báo cơ bản và trực quan nhất trong phân tích chuỗi thời gian. Ý tưởng của phương pháp này là: giá trị dự báo cho kỳ tiếp theo chính là giá trị quan sát thực tế gần nhất ($F_{t+1} = Y_t$).

Phương pháp này giả định rằng hiện tượng không có xu hướng rõ ràng, cũng không có tính mùa vụ, và do đó, dữ liệu trong quá khứ gần nhất sẽ phản ánh chính xác cho tương lai gần. Đây là cách tiếp cận thường được dùng để so sánh với các mô hình phức tạp hơn, nhằm kiểm tra mức độ cải thiện của mô hình. Phương pháp này tuy đơn giản, nhưng đôi khi mang lại kết quả không tệ trong những chuỗi thời gian ổn định hoặc có nhiễu cao - nơi mô hình hóa phức tạp không mang lại nhiều cải thiện.

3.1.2. Thực hiện bằng thủ công (tính toán trên excel)

Sau khi đã tìm hiểu nguyên lý của phương pháp Naive, bước tiếp theo là tiến hành áp dụng vào chuỗi dữ liệu thực tế nhằm đánh giá hiệu quả dự báo. Phương pháp này đặc biệt đơn giản khi triển khai trên Excel, vì giá trị dự báo tại mỗi thời điểm chỉ đơn thuần là giá trị thực tế của kỳ liền trước.

File tính toán Excel: [Phương pháp Naive](#)

Tổng hợp chú thích công thức:

- F_{t+1} (Naive Forecast tại $t+1$) = Actual Value in Period t
- Forecast Error (FE) = Actual Value – Naive Forecast
- Absolute Error (AE) = giá trị tuyệt đối của Forecast Error
- Squared Error (SE) = giá trị bình phương của Forecast Error
- Abs.% Error (APE) = Absolute Error / Actual Value*100
- $MAE = \sum AE / 119$
- $MSE = \sum SE / 119$
- $MAPE = \sum MAPE / 119$

Việc thực hiện trên Excel không chỉ giúp trực quan hóa kết quả, mà còn cho phép dễ dàng điều chỉnh, mở rộng và so sánh với các phương pháp dự báo khác về sau.

3.1.3. Thực hành trên Stata

Sau khi áp dụng phương pháp Naive trên chuỗi dữ liệu hành khách từ năm 1951 đến 1960, ta thu được các kết quả sai số dự báo như sau:

```
. *Phương pháp Naive:
```

```
. gen naive = passengers[_n-1]
(1 missing value generated)
```

```
. gen FE_naive = passengers - naive
(1 missing value generated)
```

```
. gen absFE_naive = abs( FE_naive)
(1 missing value generated)
```

```
. gen sqFE_naive = FE_naive^2
(1 missing value generated)
```

```
. gen absperFE_naive = absFE_naive/ passengers*100
(1 missing value generated)
```

```
. mean absFE_naive sqFE_naive absperFE_naive
```

Mean estimation

Number of obs = 119

	Mean	Std. err.	[95% conf. interval]	
absFE_naive	28.61345	2.070751	24.5128	32.7141
sqFE_naive	1324.714	177.7724	972.6766	1676.752
absperFE_naive	8.980184	.5209417	7.948578	10.01179

Data Editor (Edit) - [Untitled]

File Edit View Data Tools

month[1] 1951-01

	month	passengers	monthly_date	naive	FE_naive	absFE_naive	sqFE_naive	absperFE_naive
1	1951-01	145	1951m1	-	-	-	-	-
2	1951-02	150	1951m2	145	5	5	25	3.333333
3	1951-03	178	1951m3	150	28	28	784	15.73034
4	1951-04	163	1951m4	178	-15	15	225	9.202454
5	1951-05	172	1951m5	163	9	9	81	5.232558
6	1951-06	178	1951m6	172	6	6	36	3.370786
7	1951-07	199	1951m7	178	21	21	441	10.55276
8	1951-08	199	1951m8	199	0	0	0	0
9	1951-09	184	1951m9	199	-15	15	225	8.152174
10	1951-10	162	1951m10	184	-22	22	484	13.58025
11	1951-11	146	1951m11	162	-16	16	256	10.9589
12	1951-12	166	1951m12	146	20	20	400	12.04819
13	1952-01	171	1952m1	166	5	5	25	2.923977
14	1952-02	180	1952m2	171	9	9	81	5
15	1952-03	193	1952m3	180	13	13	169	6.735751
16	1952-04	181	1952m4	193	-12	12	144	6.629834
17	1952-05	183	1952m5	181	2	2	4	1.092896
18	1952-06	218	1952m6	183	35	35	1225	16.05505
19	1952-07	230	1952m7	218	12	12	144	5.217391
20	1952-08	242	1952m8	230	12	12	144	4.958678
21	1952-09	209	1952m9	242	-33	33	1089	15.78947
22	1952-10	191	1952m10	209	-18	18	324	9.424084
23	1952-11	172	1952m11	191	-19	19	361	11.04651
24	1952-12	194	1952m12	172	22	22	484	11.34021
25	1953-01	196	1953m1	194	2	2	4	1.020408
26	1953-02	196	1953m2	196	0	0	0	0

Variables

Filter variables here

☒ Name ☐ Label

☒ month Month

☒ passengers Passengers

☒ monthly_date

☒ naive

☒ FE_naive

☒ absFE_naive

☒ sqFE_naive

☒ absperFE_naive

Variables Snapshots

Properties

Variables

Name month

Label Month

Type str7

Format %9s

Value label

Notes

Data

Frame default

Filename

Label

Notes

Variables 8

Observations 120

Ready Length: 7 Vars: 8 Order: Dataset Obs: 120 Filter: Off Mode: Edit CAP NUM

Với giá trị MAE khoảng 28.6, ta có thể hiểu rằng trung bình mỗi tháng, dự báo lệch khoảng 28 hành khách so với thực tế. Đây là mức sai số tương đối dễ hiểu trong bối cảnh chuỗi dữ liệu có nhiều dao động. Giá trị MSE cao hơn, đạt 1324.7, phản ánh rằng có một số quan sát có sai số lớn (vì MSE bình phương sai số nên rất nhạy với outliers). Tuy nhiên, mức MAPE dưới 9% cho thấy phương pháp Naive mang lại độ chính xác khá tốt nếu xét về mặt tương đối (% lệch giữa dự báo và giá trị thật).

Phương pháp Naive có ưu điểm là đơn giản, không cần tham số hay giả định phức tạp, nhưng đồng thời cũng là hạn chế lớn nhất của nó: không khai thác được thông tin về xu hướng hay tính lặp lại theo mùa. Mặc dù sai số trung bình của mô hình là chấp nhận được trong ngắn hạn, song đối với một chuỗi thời gian có trend tăng rõ ràng và mùa vụ hàng năm lặp lại như AirPassengers, phương pháp này sẽ không còn là lựa chọn phù hợp trong các mô hình dự báo trung và dài hạn. Do đó, trong các phần tiếp theo, chúng ta sẽ thử nghiệm các mô hình nâng cao hơn như Moving Average, Exponential Smoothing và đặc biệt là Holt–Winters để kiểm tra xem liệu có thể cải thiện độ chính xác dự báo so với Naive hay không.

3.2. Phương pháp Trung bình trượt - Moving Average (MA)

3.2.1. Mô tả ý tưởng và công thức

Phương pháp Trung bình trượt (Moving Average - MA) là kỹ thuật dự báo phổ biến trong phân tích chuỗi thời gian. Mô hình này giả định rằng giá trị quan sát ở thời điểm hiện tại bị ảnh hưởng bởi một số kỳ gần nhất trong quá khứ, và vì vậy, giá trị dự báo có thể được tính bằng trung bình số học của các quan sát này.

Mục tiêu của phương pháp là làm mượt chuỗi dữ liệu, loại bỏ biến động ngắn hạn để làm nổi bật xu hướng dài hạn hơn. Phương pháp MA đặc biệt hữu ích khi chuỗi không có tính mùa vụ rõ ràng nhưng lại có nhiễu nhiễu.

Công thức của MA với số kỳ là k :

$$\hat{Y}_t = \frac{1}{k} \sum_{i=1}^k Y_{t-i}$$

Trong đó:

- $\hat{Y}_t$: giá trị dự báo tại thời điểm t
- Y_{t-i} : giá trị thực tế tại các kỳ trước đó
- k : số kỳ lấy trung bình (độ dài cửa sổ)

3.2.2. Lựa chọn độ dài cửa sổ (kỳ)

Trong phương pháp trung bình trượt, độ dài cửa sổ - tức số kỳ lấy trung bình - là yếu tố then chốt quyết định hiệu quả của mô hình dự báo. Độ dài cửa sổ nhỏ giúp mô hình phản ứng nhanh với biến động mới nhưng dễ bị nhiễu; ngược lại, cửa sổ lớn tạo ra sự mượt mà nhưng có thể làm chậm phản ứng với các xu hướng thay đổi đột ngột.

Để lựa chọn độ dài cửa sổ tối ưu cho bộ dữ liệu hành khách hàng không giai đoạn 1951-1960, ta thực hiện một loạt các thử nghiệm thực nghiệm với tất cả các giá trị từ 2 đến 12 kỳ. Với mỗi số kỳ, ta áp dụng mô hình MA tương ứng và tính toán các chỉ tiêu sai số bao gồm MAE, MSE, MAPE.

3.2.3. Tính toán thủ công bằng excel

Để kiểm chứng tính ứng dụng của phương pháp này, việc triển khai trực tiếp trên Excel sẽ được tiến hành với nhiều độ dài trung bình trượt khác nhau (MA2, MA3, MA4, v.v.).

Quá trình tính toán được thực hiện bằng cách sử dụng các hàm trung bình (AVERAGE) và tham chiếu vùng dữ liệu trong Excel. Tại mỗi thời điểm, giá trị dự báo được tính bằng trung bình cộng của một số kỳ quan sát gần nhất, tùy theo mức MA đang xét. Đối với các kỳ đầu tiên (chưa đủ số lượng quan sát), giá trị dự báo có thể để trống hoặc được xử lý riêng biệt để tránh sai sót trong thống kê.

Ngoài ra, các sai số tương ứng giữa giá trị thực tế và giá trị dự báo cũng được tính toán song song, bao gồm sai số tuyệt đối (AE), sai số bình phương (SE) và sai số phần trăm tuyệt đối (APE). Từ đó, các chỉ số tổng hợp như MAE, MSE và MAPE được sử dụng để đánh giá mức độ chính xác của từng mức MA.

File tính toán Excel: [Phương pháp MA](#)

Việc thực hiện trên Excel không chỉ giúp đơn giản hóa quá trình tính toán, mà còn cho phép trực quan hóa kết quả thông qua biểu đồ và dễ dàng so sánh giữa các mức trung bình khác nhau, từ đó lựa chọn mô hình phù hợp nhất cho chuỗi dữ liệu đang nghiên cứu.

3.2.4. Thực hành trên Stata

- Thử nghiệm với $k = 2$:

```

. *-Thử nghiệm với k = 2:

. gen MA2 = 1/2*(passengers[_n-2]+ passengers[_n-1])
(2 missing values generated)

. gen FE_MA2 = passengers - MA2
(2 missing values generated)

. gen absFE_MA2 = abs( FE_MA2)
(2 missing values generated)

. gen sqFE_MA2 = FE_MA2^2
(2 missing values generated)

. gen absperFE_MA2 = absFE_MA2/ passengers*100
(2 missing values generated)

. mean absFE_MA2 sqFE_MA2 absperFE_MA2

Mean estimation                                Number of obs = 118

```

	Mean	Std. err.	[95% conf. interval]	
absFE_MA2	35.43644	2.648936	30.19036	40.68252
sqFE_MA2	2076.714	271.7968	1538.435	2614.993
absperFE_MA2	10.98554	.6737729	9.651171	12.31992

- Thử nghiệm với k = 3:

```

. *-Thử nghiệm với k = 3

. gen MA3= 1/3*(passengers[_n-3]+passengers[_n-2]+passengers[_n-1])
(3 missing values generated)

. gen FE_MA3= passengers - MA3
(3 missing values generated)

. gen absFE_MA3 = abs( FE_MA3 )
(3 missing values generated)

. gen sqFE_MA3 = FE_MA3^2
(3 missing values generated)

. gen absperFE_MA3 = absFE_MA3/ passengers*100
(3 missing values generated)

. mean absFE_MA3 sqFE_MA3 absperFE_MA3

```

Mean estimation

Number of obs = 117

	Mean	Std. err.	[95% conf. interval]	
absFE_MA3	40.21083	3.111536	34.04804	46.37362
sqFE_MA3	2739.983	372.5946	2002.012	3477.953
absperFE_MA3	12.31557	.8339309	10.66386	13.96727

- Thử nghiệm với k = 4:

```

. *-Thử nghiệm với k = 4

. gen MA4 = 1/4*(passengers[_n-4]+passengers[_n-3]+passengers[_n-2]+passengers[_n-1])
(4 missing values generated)

. gen FE_MA4= passengers - MA4
(4 missing values generated)

. gen absFE_MA4 = abs( FE_MA4 )
(4 missing values generated)

. gen sqFE_MA4 = FE_MA4^2
(4 missing values generated)

. gen absperFE_MA4 = absFE_MA4/passengers*100
(4 missing values generated)

. mean absFE_MA4 sqFE_MA4 absperFE_MA4

```

Mean estimation

Number of obs = 116

	Mean	Std. err.	[95% conf. interval]	
absFE_MA4	44.09267	3.368281	37.42076	50.76459
sqFE_MA4	3248.876	446.0247	2365.386	4132.365
absperFE_MA4	13.48681	.9017552	11.70061	15.27302

- Thử nghiệm với k = 5:

```

. *-Thử nghiệm với k = 5

. gen MA5 = 1/5*(passengers[_n-5]+passengers[_n-4]+passengers[_n-3]+passengers[_n-2]+passengers[_n-1])
(5 missing values generated)

. gen FE_MA5= passengers - MA5
(5 missing values generated)

. gen absFE_MA5 = abs( FE_MA5 )
(5 missing values generated)

. gen sqFE_MA5 = FE_MA5^2
(5 missing values generated)

. gen absperFE_MA5 = absFE_MA5/passengers*100
(5 missing values generated)

. mean absFE_MA5 sqFE_MA5 absperFE_MA5

```

Mean estimation Number of obs = 115

	Mean	Std. err.	[95% conf. interval]	
absFE_MA5	46.7513	3.457993	39.90105	53.60156
sqFE_MA5	3548.864	480.0433	2597.902	4499.826
absperFE_MA5	14.19531	.8830043	12.44608	15.94453

- Thử nghiệm với k = 6:

```

. *-Thử nghiệm với k = 6

. gen MA6 = 1/6*(passengers[_n-6]+passengers[_n-5]+passengers[_n-4]+passengers[_n-3]+passengers[_n-2]+passengers[_n-1])
(6 missing values generated)

. gen FE_MA6= passengers - MA6
(6 missing values generated)

. gen absFE_MA6 = abs( FE_MA6 )
(6 missing values generated)

. gen sqFE_MA6 = FE_MA6^2
(6 missing values generated)

. gen absperFE_MA6 = absFE_MA6/passengers*100
(6 missing values generated)

. mean absFE_MA6 sqFE_MA6 absperFE_MA6

```

Mean estimation Number of obs = 114

	Mean	Std. err.	[95% conf. interval]	
absFE_MA6	48.80263	3.443496	41.98045	55.62482
sqFE_MA6	3721.613	493.3892	2744.12	4699.106
absperFE_MA6	14.74915	.8086195	13.14713	16.35117

- Thử nghiệm với k = 7:

Mean estimation		Number of obs = 113		
	Mean	Std. err.	[95% conf. interval]	
absFE_MA7	48.95575	3.551443	41.91902	55.99248
sqFE_MA7	3809.293	527.3075	2764.501	4854.085
absperFE_MA7	14.65865	.7965436	13.0804	16.2369

```
. *-Thử nghiệm với k = 8

. gen MA8 = 1/8*(passengers[_n-8]+passengers[_n-7]+passengers[_n-6]+passengers[_n-5]+passengers[_n-4]+passengers[_n-3]+passengers[_n-2]+passengers[_n-1])
(8 missing values generated)

. gen FE_MA8= passengers - MA8
(8 missing values generated)

. gen absFE_MA8 = abs( FE_MA8)
(8 missing values generated)

. gen sqFE_MA8 = FE_MA8^2
(8 missing values generated)

. gen absperFE_MA8 = absFE_MA8/passengers*100
(8 missing values generated)

. mean absFE_MA8 sqFE_MA8 absperFE_MA8
```

Mean estimation		Number of obs = 112	
	Mean	Std. err.	[95% conf. interval]
absFE_Ma8	47.91071	3.730938	40.51761 55.30382
sqFE_Ma8	3840.545	583.1515	2684.992 4996.099
absperFE_Ma8	14.14827	.8260774	12.51134 15.7852

```

. *-Thử nghiệm với k = 9

. gen MA9 = 1/9*(passengers[_n-9]+passengers[_n-8]+passengers[_n-7]+passengers[_n-6]+passengers[_n-5]+passengers[_n-4]+passengers[_n-3]+passengers[_n-2]+passengers[_n-1]
> )
(9 missing values generated)

. gen FE_MA9= passengers - MA9
(9 missing values generated)

. gen absFE_MA9 = abs( FE_MA9)
(9 missing values generated)

. gen sqFE_MA9 = FE_MA9^2
(9 missing values generated)

. gen absperFE_MA9 = absFE_MA9/passengers*100
(9 missing values generated)

. mean absFE_MA9 sqFE_MA9 absperFE_MA9

Mean estimation                                Number of obs = 111


```

	Mean	Std. err.	[95% conf. interval]	
absFE_MA9	46.04304	3.857084	38.39921	53.68688
sqFE_MA9	3756.443	615.9673	2535.74	4977.145
absperFE_MA9	13.42302	.8409296	11.75649	15.08954

- Thử nghiệm với k = 10:

```

. *-Thử nghiệm với k = 10

. gen MA10 = 1/10*(passengers[_n-10]+passengers[_n-9]+passengers[_n-8]+passengers[_n-7]+passengers[_n-6]+passengers[_n-5]+passengers[_n-4]+passengers[_n-3]+passengers[_n-2]+passengers[_n-1])
> )
(10 missing values generated)

. gen FE_MA10= passengers - MA10
(10 missing values generated)

. gen absFE_MA10 = abs( FE_MA10 )
(10 missing values generated)

. gen sqFE_MA10 = FE_MA10^2
(10 missing values generated)

. gen absperFE_MA10 = absFE_MA10/passengers*100
(10 missing values generated)

. mean absFE_MA10 sqFE_MA10 absperFE_MA10

Mean estimation                                Number of obs = 110


```

	Mean	Std. err.	[95% conf. interval]	
absFE_MA10	44.01909	3.844411	36.39959	51.63859
sqFE_MA10	3548.645	610.7976	2338.064	4759.226
absperFE_MA10	12.72088	.8356187	11.06471	14.37705

- Thử nghiệm với k = 11:

```
. *-Thử nghiệm với k = 11

. gen MA11 = 1/11*(passengers[_n-11]+passengers[_n-10]+passengers[_n-9]+passengers[_n-8]+passengers[_n-7]+passengers[_n-6]+passengers[_n-5]+passengers[_n-4]+passengers[_n-3]+passengers[_n-2]+passengers[_n-1])
(11 missing values generated)

. gen FE_MA11= passengers - MA11
(11 missing values generated)

. gen absFE_MA11 = abs( FE_MA11 )
(11 missing values generated)

. gen sqFE_MA11 = FE_MA11^2
(11 missing values generated)

. gen absperFE_MA11 = absFE_MA11/passengers*100
(11 missing values generated)

. mean absFE_MA11 sqFE_MA11 absperFE_MA11

Mean estimation      Number of obs = 109
```

	Mean	Std. err.	[95% conf. interval]	
absFE_MA11	41.38449	3.749219	33.95289	48.81609
sqFE_MA11	3230.793	566.4263	2108.038	4353.548
absperFE_MA11	11.81786	.8239332	10.18468	13.45104

• Thử nghiệm với k = 12:

```
. *-Thử nghiệm với k = 12

. gen MA12 = 1/12*(passengers[_n-12]+passengers[_n-11]+passengers[_n-10]+passengers[_n-9]+passengers[_n-8]+passengers[_n-7]+passengers[_n-6]+passengers[_n-5]+passengers[_n-4]+passengers[_n-3]+passengers[_n-2]+passengers[_n-1])
(12 missing values generated)

. gen FE_MA12= passengers - MA12
(12 missing values generated)

. gen absFE_MA12 = abs( FE_MA12 )
(12 missing values generated)

. gen sqFE_MA12 = FE_MA12^2
(12 missing values generated)

. gen absperFE_MA12 = absFE_MA12/passengers*100
(12 missing values generated)

. mean absFE_MA12 sqFE_MA12 absperFE_MA12

Mean estimation      Number of obs = 108
```

	Mean	Std. err.	[95% conf. interval]	
absFE_MA12	39.14815	3.589871	32.03165	46.26465
sqFE_MA12	2911.505	512.7184	1895.101	3927.91
absperFE_MA12	11.13362	.789044	9.569437	12.69781

Bảng tóm tắt kết quả sai số cho từng k:

Số kỳ	MAE	MSE	MAPE
MA(2)	35.44	2076.71	10.99
MA(3)	40.21	2739.98	12.32
MA(4)	44.09	3248.88	13.49
MA(5)	46.75	3584.86	14.20
MA(6)	48.80	3721.61	14.75
MA(7)	48.96	3809.29	14.66

MA(8)	47.91	3840.55	14.15
MA(9)	46.04	3756.44	13.42
MA(10)	44.02	3548.65	12.72
MA(11)	41.38	3230.79	11.82
MA(12)	39.15	2911.51	11.13

Các kết quả sai số được tổng hợp cho thấy xu hướng biến động khá rõ ràng, cụ thể, ở các mô hình có số kỳ như MA(2), MA(3), sai số còn ở mức thấp, trong đó MA(2) cho sai số nhỏ nhất trên cả ba tiêu chí: MAE = 35.44, MSE = 2076.71 và MAPE = 10.99%. Tuy nhiên, từ MA(4) đến MA(7), các chỉ số sai số bắt đầu tăng mạnh, cho thấy khi độ dài cửa sổ tăng mà chưa đủ để bao phủ chu kỳ mùa vụ, dự báo có xu hướng kém chính xác hơn. Mức sai số cao nhất được ghi nhận ở MA(7), với MAE lên tới 48.96 và MAPE là 14.66%.

Từ MA(8) trở đi, mô hình bắt đầu cải thiện trở lại khi các cửa sổ đủ dài để làm mượt chuỗi và giảm nhiễu ngắn hạn. Đặc biệt, từ MA(10) đến MA(12), các chỉ số sai số giảm rõ rệt, trong đó MA(11) và MA(12) là hai mô hình có hiệu suất dự báo tốt nhất trong nhóm này.

Tuy nhiên, nếu giới hạn phân tích vào nhóm các kỳ thường được chọn tham khảo thực tế như MA(4), MA(5), MA(10) và MA(11) thì sự chênh lệch về sai số càng trở nên rõ rệt hơn. Trong nhóm này, MA(11) nổi bật là mô hình có hiệu quả dự báo cao nhất, với các chỉ số sai số đều thấp hơn hẳn ba mô hình còn lại. MA(5) là phương án kém hiệu quả nhất với MAPE lên tới 14.20%, trong khi MA(4) và MA(10) có sai số ở mức trung bình, nhưng vẫn thua xa MA(11).

Từ những phân tích trên, có thể rút ra kết luận rằng nếu xét tất cả các kỳ thì MA(2) sẽ cho kết quả tốt nhất về các chỉ số MAE, MSE, MAPE nhưng vì độ dài cửa sổ quá ngắn, mô hình dễ bị nhiễu và khó làm nổi bật xu hướng ổn định của chuỗi. Tuy nhiên, nếu chỉ xét riêng trong phạm vi số kỳ bao gồm $k = 4, 5, 10, 11$ thì MA(11) lại là mô hình có khả năng làm mượt chuỗi tốt nhất, giữ được tính ổn định và đạt hiệu quả dự báo cao nếu cân nhắc tổng thể. Do đó, trong trường hợp này, MA(11) là lựa chọn phù hợp nhất

giữa các phương án thử nghiệm, xét cả về số liệu sai số lẫn đặc điểm cấu trúc của chuỗi dữ liệu theo tháng.

3.3. Phương pháp Trọng số trung bình trượt - Weighted Moving Average (WMA)

3.3.1. Mô tả ý tưởng, công thức

Phương pháp trung bình trượt có trọng số (Weighted Moving Average - WMA) là một mở rộng của mô hình trung bình trượt đơn giản (MA), trong đó các giá trị quá khứ được gán trọng số khác nhau thay vì hệ số bằng nhau. Ý tưởng cốt lõi là những quan sát gần hiện tại hơn có thể chứa thông tin dự báo quan trọng hơn, vì vậy nên được gán trọng số cao hơn so với các quan sát xa hơn trong quá khứ.

Công thức tổng quát của mô hình WMA với độ dài cửa sổ k:

$$\hat{Y}_t = \sum_{i=1}^k w_i \cdot Y_{t-i}$$

Trong đó:

- w_i : là trọng số gán cho quan sát ở thời điểm $t - i$, thỏa mãn $\sum_{i=1}^k w_i = 1$
- Y_{t-i} : giá trị thực tế tại các kỳ trước
- $\hat{Y}_t$: giá trị dự báo tại thời điểm t

Phương pháp WMA cho phép linh hoạt hơn trong mô hình hóa chuỗi, đặc biệt khi dữ liệu có tính biến động cao, giúp làm nổi bật các xu hướng gần nhất.

3.3.2. Tìm bộ trọng số phù hợp

Khác với MA, phương pháp WMA đòi hỏi phải tự xác định bộ trọng số phù hợp. Tuy nhiên, đây cũng là cơ hội để tối ưu hóa khả năng dự báo của mô hình. Trọng số càng sát với quy luật biến động thực tế thì mô hình càng chính xác.

Trong nghiên cứu này, để đảm bảo tính khách quan, ta sẽ tiến hành thử nghiệm nhiều bộ trọng số khác nhau với tổng trọng số luôn bằng 1. Các bộ trọng số được lựa chọn theo hướng:

- Trọng số giảm dần từ quan sát gần nhất.
- Phân bố đồng đều có điều chỉnh nhẹ (ví dụ: 0.5 - 0.3 - 0.2, 0.4 - 0.4 - 0.2,...).
- Kiểm tra nhiều phương án để tìm ra bộ trọng số cho kết quả dự báo tốt nhất, dựa trên các chỉ số MAE, MSE và MAPE.

3.3.3. Tính toán thủ công bằng excel

Do kết quả từ phương pháp trung bình trượt đơn (MA) cho thấy MA(11) là mô hình phù hợp nhất, nên khi chuyển sang phương pháp trung bình trượt có trọng số (WMA), bài nghiên cứu tiếp tục giữ nguyên độ dài cửa sổ trượt tương ứng là 11 để đảm bảo tính nhất quán trong phân tích. Việc áp dụng trọng số trong cùng độ dài cửa sổ giúp kiểm chứng liệu WMA có thể cải thiện độ chính xác dự báo so với MA tương ứng hay không.

File Excel: [Phương pháp WMA\(11\)](#)

3.3.4. Thực hành trên Stata

- Bộ 1: Trọng số giảm dần đều $w = [\frac{11}{66}, \frac{10}{66}, \frac{9}{66}, \dots, \frac{3}{66}, \frac{2}{66}, \frac{1}{66}]$:

```
. *- Bộ 1: Trọng số giảm dần đều
. gen WMA11_1 = 11/66*passengers[_n-11]+10/66*passengers[_n-10]+9/66*passengers[_n-9]+8/66*passengers[_n-8]+7/66*passengers[_n-7]+6/66*passengers[_n-6]+5/66*passengers[_n-5]+4/66*passengers[_n-4]+3/66*passengers[_n-3]+2/66*passengers[_n-2]+1/66*passengers[_n-1]
(11 missing values generated)

. gen FE_WMA11_1 = passengers - WMA11_1
(11 missing values generated)

. gen absFE_WMA11_1 = abs(FE_WMA11_1)
(11 missing values generated)

. gen sqFE_WMA11_1 = FE_WMA11_1^2
(11 missing values generated)

. gen absperFE_WMA11_1 = absFE_WMA11_1/passengers*100
(11 missing values generated)

. mean absFE_WMA11_1 sqFE_WMA11_1 absperFE_WMA11_1

Mean estimation                                Number of obs = 109
```

	Mean	Std. err.	[95% conf. interval]	
absFE_WMA11_1	42.25424	4.155783	34.01676	50.49172
sqFE_WMA11_1	3650.638	671.0175	2320.565	4980.711
absperFE_WMA11_1	11.8996	.9124835	10.0909	13.7083

- Bộ 2: Trọng số nhấn mạnh cực mạnh vào kỳ gần nhất $w = [0.4, 0.2, 0.1, 0.08, 0.06, 0.05, 0.04, 0.03, 0.02, 0.01, 0.01]$:

```

. *- Bộ 2: Trọng số nhấn mạnh cực mạnh vào kỳ gần nhất:

. gen WMA11_2 = 0.4*passengers[_n-11]+0.2*passengers[_n-10]+0.1*passengers[_n-9]+0.08*passengers[_n-8]+0.06*passengers[_n-7]+0.05*passengers[_n-6]+0.04*passengers[_n-5]+
> 0.03*passengers[_n-4]+0.02*passengers[_n-3]+0.01*passengers[_n-2]+0.01*passengers[_n-1]
(11 missing values generated)

. gen FE_WMA11_2 = passengers - WMA11_2
(11 missing values generated)

. gen absFE_WMA11_2 = abs( FE_WMA11_2 )
(11 missing values generated)

. gen sqFE_WMA11_2 = FE_WMA11_2 ^2
(11 missing values generated)

. gen absperFE_WMA11_2 = absFE_WMA11_2 /passengers*100
(11 missing values generated)

. mean absFE_WMA11_2 sqFE_WMA11_2 absperFE_WMA11_2

Mean estimation                                Number of obs = 109

+-----+-----+-----+-----+
|               |      Mean      | Std. err.    | [95% conf. interval] |
+-----+-----+-----+-----+
| absFE_WMA11_2 |      38.47037   |   3.765526   |      31.00644   45.93429 |
| sqFE_WMA11_2  |     3011.321   |   559.6899   |     1901.919   4120.724 |
| absperFE_WMA11_2 |     11.0014    |   .838946    |      9.338464   12.66434 |
+-----+-----+-----+-----+

```

- Bộ 3: Trọng số giảm chậm hơn $w = [0.2, 0.16, 0.13, 0.11, 0.09, 0.08, 0.07, 0.06, 0.05, 0.03, 0.02]$:

```

. *- Bộ 3: Trọng số giảm chậm hơn:

. gen WMA11_3 = 0.2*passengers[_n-11]+0.16*passengers[_n-10]+0.13*passengers[_n-9]+0.11*passengers[_n-8]+0.09*passengers[_n-7]+0.08*passengers[_n-6]+0.07*passengers[_n-5]
> +0.06*passengers[_n-4]+0.05*passengers[_n-3]+0.03*passengers[_n-2]+0.02*passengers[_n-1]
(11 missing values generated)

. gen FE_WMA11_3 = passengers - WMA11_3
(11 missing values generated)

. gen absFE_WMA11_3 = abs( FE_WMA11_3 )
(11 missing values generated)

. gen sqFE_WMA11_3 = FE_WMA11_3 ^2
(11 missing values generated)

. gen absperFE_WMA11_3 = absFE_WMA11_3 /passengers*100
(11 missing values generated)

. mean absFE_WMA11_3 sqFE_WMA11_3 absperFE_WMA11_3

Mean estimation                                Number of obs = 109

+-----+-----+-----+-----+
|               |      Mean      | Std. err.    | [95% conf. interval] |
+-----+-----+-----+-----+
| absFE_WMA11_3 |     40.77624    |   4.04253    |      32.76324   48.78923 |
| sqFE_WMA11_3  |    3427.643    |   636.7847   |    2165.425   4689.861 |
| absperFE_WMA11_3 |     11.49942    |   .8898255   |      9.735634   13.26321 |
+-----+-----+-----+-----+

```

Bảng tóm tắt kết quả các chỉ số của từng bộ trọng số:

Các bộ trọng số	MAE	MSE	MAPE
Bộ 1	42.25	3650.64	11.90
Bộ 2	38.47	3011.32	11.00
Bộ 3	40.78	3427.64	11.50

Sau khi tiến hành thử nghiệm ba bộ trọng số khác nhau trong mô hình trung bình trượt có trọng số WMA(11), kết quả cho thấy sự khác biệt đáng kể về độ chính xác giữa

các bộ trọng số được sử dụng. Trong đó, bộ trọng số thứ hai - với trọng số tập trung mạnh vào kỳ gần nhất - đạt hiệu quả dự báo tốt nhất trên cả ba chỉ số đánh giá. Cụ thể, bộ này cho giá trị MAE là 38.47, MSE là 3011.32 và MAPE là 11.00, đều thấp hơn rõ rệt so với hai bộ còn lại. Điều này phản ánh rằng việc nhấn mạnh vào các quan sát gần hiện tại hơn đã giúp mô hình bắt kịp với xu hướng biến động của chuỗi dữ liệu tốt hơn, từ đó làm giảm sai số dự báo.

Ngược lại, bộ trọng số thứ nhất - với các trọng số chia đều - cho kết quả kém nhất, với MAE đạt 42.25 và MAPE lên đến 11.90. Điều này cho thấy rằng việc xem tất cả các quan sát trong quá khứ quan trọng như nhau là yếu tố không phải lúc nào cũng phù hợp, đặc biệt là trong bối cảnh dữ liệu có sự thay đổi theo thời gian. Bộ trọng số thứ ba, với mức giảm trọng số chậm hơn, mang lại kết quả ở mức trung bình, phần nào cải thiện được độ chính xác so với mô hình MA(11), nhưng vẫn kém hiệu quả hơn so với bộ trọng số nhấn mạnh vào kỳ gần nhất.

Từ các kết quả này, có thể rút ra nhận định rằng trong phương pháp WMA, không chỉ riêng số kỳ quan sát mà cả cách phân bổ trọng số giữa các kỳ cũng đóng vai trò quyết định đến chất lượng dự báo. Việc thiết kế trọng số phù hợp - cụ thể là ưu tiên dữ liệu gần hơn - là yếu tố then chốt giúp cải thiện độ chính xác của mô hình, đặc biệt trong những chuỗi thời gian có tính biến động hoặc xu hướng ngắn hạn rõ rệt.

3.4. Phương pháp làm mượt hàm mũ cơ bản - Exponential Smoothing (ES)

3.4.1. Mô tả ý tưởng và công thức

Phương pháp làm mượt hàm mũ cơ bản (còn gọi là phương pháp hàm mũ đơn, hay Simple Exponential Smoothing - SES) là một trong những kỹ thuật dự báo phổ biến và đơn giản, được áp dụng hiệu quả cho các chuỗi thời gian không có xu hướng rõ ràng hoặc tính mùa vụ. Khác với phương pháp trung bình trượt, trong đó mỗi điểm dữ liệu chỉ ảnh hưởng đến một vài dự báo trong phạm vi cửa sổ trượt, phương pháp hàm mũ đơn sử dụng tất cả các quan sát trong quá khứ, nhưng gán trọng số giảm dần theo cấp số nhân cho các giá trị càng xa hiện tại.

Công thức dự báo của ES cơ bản được xác định như sau:

$$\hat{Y}_t = \alpha Y_{t-1} + (1 - \alpha) \hat{Y}_{t-1}$$

Trong đó:

- $\hat{Y}_t$ là giá trị dự báo tại thời điểm t .
- Y_{t-1} là giá trị thực tế tại thời điểm $t-1$.
- $\hat{Y}_{t-1}$ là giá trị dự báo tại thời điểm trước đó,
- α là hệ số làm mượt (smoothing constant), thỏa mãn $0 < \alpha < 1$.

3.4.2. Lựa chọn hệ số làm mượt α

Hệ số α đóng vai trò quyết định trong việc phân bổ trọng số giữa giá trị thực tế gần nhất và toàn bộ quá khứ đã được "tóm tắt" vào giá trị dự báo trước đó. Khi α càng lớn (gần 1), mô hình càng phản ứng nhạy với các biến động gần hiện tại, tương tự như trọng số cao trong WMA. Ngược lại, khi α nhỏ (gần 0), mô hình trở nên trơn tru và phản ứng chậm hơn, tương tự như việc làm mượt mạnh chuỗi dữ liệu.

Trong quá trình thử nghiệm, nhiều giá trị α khác nhau sẽ được sử dụng, chẳng hạn như 0.1, 0.3, 0.5, 0.7 và 0.9, để đánh giá mức độ phản ứng của mô hình đối với dữ liệu. Khi α nhỏ, mô hình tạo ra chuỗi dự báo trơn tru hơn nhưng phản ứng chậm với thay đổi. Khi α lớn, mô hình theo sát các dao động của chuỗi thực tế nhưng có thể dễ bị nhiễu trong dữ liệu có biến động ngẫu nhiên.

3.4.3. Tính toán thủ công bằng Excel

Sau khi đã trình bày nguyên lý của phương pháp làm mượt hàm mũ cơ bản, bước tiếp theo là triển khai tính toán dự báo trên Excel nhằm kiểm chứng hiệu quả của phương pháp này đối với chuỗi dữ liệu thực tế. Việc thực hiện trên Excel giúp theo dõi trực quan quá trình cập nhật dự báo theo từng thời điểm, đồng thời dễ dàng điều chỉnh hệ số làm mượt α để so sánh các mô hình.

Do công thức của phương pháp SES có tính đệ quy - nghĩa là dự báo tại thời điểm hiện tại phụ thuộc vào giá trị dự báo của kỳ trước đó - nên bước khởi đầu của quá trình tính toán rất quan trọng. Thông thường, giá trị dự báo đầu tiên $\hat{Y}_1$ sẽ được gán bằng chính giá trị thực tế đầu tiên Y_1 , hoặc bằng trung bình của vài kỳ đầu nếu muốn làm mượt hơn.

Sau khi thiết lập giá trị ban đầu, các giá trị dự báo tiếp theo được tính lần lượt theo công thức $\hat{Y}_t = \alpha Y_{t-1} + (1 - \alpha)\hat{Y}_{t-1}$.

Việc tính toán trong Excel được thực hiện dễ dàng bằng cách sử dụng tham chiếu ô, kết hợp với thao tác kéo công thức để áp dụng cho toàn bộ chuỗi thời gian. Đồng thời, các sai số tương ứng giữa giá trị thực tế và giá trị dự báo cũng được tính song song nhằm phục vụ việc đánh giá hiệu suất của mô hình. Các chỉ số như MAE, MSE, và MAPE tiếp tục được sử dụng để làm cơ sở so sánh giữa các mô hình sử dụng các giá trị α khác nhau.

File Excel: [Phương pháp ES Simple](#)

Việc thực hiện trên Excel không chỉ thuận tiện trong thao tác mà còn giúp trực quan hóa kết quả thông qua biểu đồ so sánh giữa giá trị thực tế và giá trị dự báo, từ đó hỗ trợ chọn ra mô hình dự báo tối ưu nhất.

3.4.4. Thực hành trên Stata

- Thử nghiệm với $\alpha = 0.1$:

```
. tsset monthly_date

Time variable: monthly_date, 1951m1 to 1960m12
Delta: 1 month

. tssmooth exponential ES = passengers, parms(0.1) s0(5)

exponential coefficient =      0.1000
sum-of-squared residuals =    533566
root mean squared error =    66.681

. gen FE = passengers - ES

. gen absFE = abs( FE)

. gen sqFE = FE^2

. gen absperFE = absFE/ passengers*100

. mean absFE sqFE absperFE

Mean estimation                                Number of obs = 120
```

	Mean	Std. err.	[95% conf. interval]	
absFE	51.433	3.890334	43.72975	59.13625
sqFE	4446.382	600.1076	3258.109	5634.655
absperFE	18.26494	1.621669	15.05388	21.47601

- Thử nghiệm với $\alpha = 0.3$:

```
. tssmooth exponential ES = passengers, parms(0.3) s0(5)
```

```
exponential coefficient =      0.3000
sum-of-squared residuals =    340859
root mean squared error =    53.296
```

```
. gen FE = passengers - ES
```

```
. gen absFE = abs( FE)
```

```
. gen sqFE = FE^2
```

```
. gen absperFE = absFE/ passengers*100
```

```
. mean absFE sqFE absperFE
```

Mean estimation

Number of obs = 120

	Mean	Std. err.	[95% conf. interval]	
absFE	41.06847	3.113904	34.90263	47.23431
sqFE	2840.491	388.3177	2071.583	3609.399
absperFE	13.6703	1.190662	11.31267	16.02793

- Thử nghiệm với $\alpha = 0.5$:


```
. tssmooth exponential ES = passengers, parms(0.5) s0(5)
```

```
exponential coefficient =      0.5000
sum-of-squared residuals =    271923
root mean squared error =    47.603
```

```
. gen FE = passengers - ES
```

```
. gen absFE = abs( FE)
```

```
. gen sqFE = FE^2
```

```
. gen absperFE = absFE/ passengers*100
```

```
. mean absFE sqFE absperFE
```

Mean estimation Number of obs = 120

	Mean	Std. err.	[95% conf. interval]	
absFE	36.57339	2.793164	31.04265	42.10413
sqFE	2266.023	307.3539	1657.431	2874.614
absperFE	12.02451	1.057112	9.931327	14.1177

- Thử nghiệm với $\alpha = 0.7$:

```
. tssmooth exponential ES = passengers, parms(0.7) s0(5)
```

```
exponential coefficient =      0.7000
sum-of-squared residuals =    221872
root mean squared error =    42.999
```

```
. gen FE = passengers - ES
```

```
. gen absFE = abs( FE)
```

```
. gen sqFE = FE^2
```

```
. gen absperFE = absFE/ passengers*100
```

```
. mean absFE sqFE absperFE
```

Mean estimation

Number of obs = 120

	Mean	Std. err.	[95% conf. interval]	
absFE	33.00364	2.526647	28.00063	38.00665
sqFE	1848.929	261.3458	1331.439	2366.42
absperFE	10.85113	.9620114	8.94625	12.75601

- Thử nghiệm với $\alpha = 0.9$:

```
. tssmooth exponential ES = passengers, parms(0.9) s0(5)
```

```
exponential coefficient =      0.9000
sum-of-squared residuals =    188652
root mean squared error =      39.65
```

```
. gen FE = passengers - ES
```

```
. gen absFE = abs( FE)
```

```
. gen sqFE = FE^2
```

```
. gen absperFE = absFE/ passengers*100
```

```
. mean absFE sqFE absperFE
```

Mean estimation Number of obs = 120

	Mean	Std. err.	[95% conf. interval]	
absFE	30.45767	2.3271	25.84978	35.06555
sqFE	1572.101	239.382	1098.101	2046.101
absperFE	10.02865	.9048984	8.236858	11.82044

Bảng tóm tắt các chỉ số:

Các chỉ số	MAE	MSE	MAPE
$\alpha = 0.1$	51.433	4446.382	18.26494
$\alpha = 0.3$	41.06847	2840.491	13.6703
$\alpha = 0.5$	36.57339	2266.023	12.02451
$\alpha = 0.7$	33.00364	1848.929	10.85113
$\alpha = 0.9$	30.45767	1572.101	10.02865

Trong quá trình triển khai phương pháp làm mượt hàm mũ đơn giản (Exponential Smoothing – ES) trên cả hai công cụ là Excel và Stata, ta nhận thấy rằng có một sự khác biệt nhỏ trong cách khởi tạo giá trị dự báo tại thời điểm đầu tiên.

Cụ thể, khi thực hiện trên Excel, nhóm chủ động thiết lập giá trị dự báo tại thời điểm $t=2$ là bằng với giá trị thực tại $t=1$, tức là $\hat{Y}_2 = Y_1$, và để trống ô dự báo tại $t=1$ vì tại thời điểm này chưa có đủ thông tin để tính dự báo theo công thức hàm mũ.

Ngược lại, khi sử dụng Stata, phần mềm tự động ước lượng và gán một giá trị khởi đầu cho dự báo tại $t=1$. Cơ chế này có thể dựa vào nội suy nội bộ, tối ưu hóa hoặc quy tắc mặc định trong thuật toán smoothing exponential. Việc khởi tạo tự động giúp đảm bảo chuỗi dự báo được tính đầy đủ từ thời điểm đầu tiên, thuận tiện cho các phân tích thống kê liên tục mà không bị thiếu giá trị.

Chính sự khác biệt trong cách khởi tạo điểm đầu này là nguyên nhân dẫn đến việc các giá trị dự báo trong hai công cụ có sai lệch nhẹ ở những thời điểm đầu chuỗi. Tuy nhiên, về tổng thể, mô hình vẫn duy trì được cấu trúc logic và sai số toàn chuỗi là tương đương, nên không ảnh hưởng đáng kể đến độ tin cậy của kết quả dự báo.

Kết quả cho thấy, khi tăng giá trị α , tức là mô hình trở nên nhạy hơn với các giá trị thực tế gần nhất, thì các chỉ số sai số đều giảm rõ rệt. Cụ thể:

- Khi $\alpha=0.1$, MAPE vẫn còn cao (18.26%), cho thấy mô hình phản ứng quá chậm và không bắt kịp xu hướng dữ liệu.
- Các giá trị trung gian như $\alpha=0.5$ hay 0.7 giúp mô hình dự báo chính xác hơn, với MAPE giảm dần.
- Đặc biệt, khi $\alpha=0.9$, mô hình đạt kết quả tốt nhất, với MAPE = 10.03%, đồng thời MAE và MSE cũng là thấp nhất.

Từ các kết quả trên, có thể khẳng định rằng mô hình với $\alpha=0.9$ là lựa chọn tối ưu nhất trong số các phiên bản ES giản đơn đã thử nghiệm. Mô hình với hệ số này giúp dự báo bám sát thực tế, phản ứng linh hoạt với biến động ngắn hạn trong chuỗi, và phù hợp với đặc điểm chuỗi dữ liệu hành khách có xu hướng tăng đều và không ổn định tuyệt đối.

3.5. Phương pháp Linear Trend Regression (Hồi quy xu hướng tuyến tính)

3.5.1. Mô tả

Phương pháp Linear Trend Regression là một trong những kỹ thuật cơ bản và phổ biến nhất trong phân tích chuỗi thời gian. Mục tiêu của phương pháp này là xác định xu hướng chung (trend) của dữ liệu theo thời gian, thông qua việc ước lượng một mô hình hồi quy tuyến tính đơn giản giữa biến phụ thuộc (thường là biến số lượng như doanh số, sản lượng, hành khách...) và thời gian.

Phương trình tổng quát của mô hình được biểu diễn dưới dạng:

$$Y_t = b_0 + b_1t + \varepsilon_t$$

Trong đó:

- Y_t : giá trị quan sát tại thời điểm t .
- t : biến thời gian (1, 2, 3, ..., n),
- b_0 : hệ số chặn (intercept), thể hiện giá trị khởi điểm của chuỗi,
- b_1 : hệ số xu hướng tuyến tính, biểu diễn tốc độ tăng hoặc giảm của chuỗi qua thời gian,
- ε_t : sai số ngẫu nhiên tại thời điểm t .

Phương pháp này được ưa chuộng vì sự đơn giản, dễ triển khai và dễ diễn giải. Khi hệ số $b_1 > 0$, chuỗi được xác định có xu hướng tăng đều; ngược lại, nếu $b_1 < 0$, chuỗi có xu hướng giảm. Trường hợp b_1 không có ý nghĩa thống kê, chuỗi có thể được xem là không có xu hướng rõ ràng.

Sau khi mô hình được ước lượng, giá trị dự báo tại thời điểm t được tính bằng:

$$\hat{Y}_t = \hat{b}_0 + \hat{b}_1 \cdot t$$

3.5.2. Tính toán thủ công trên Excel

File Excel: [Phương pháp Linear Trend Regression](#)

3.5.3. Thực hành trên Stata

Sau khi thực hiện hồi quy tuyến tính giữa biến số lượng hành khách theo thời gian (biến t), ta thu được phương trình hồi quy có dạng:

$$\hat{Y}_t = b_0 + b_1t$$

Để kiểm định xem xu hướng thời gian có ảnh hưởng đáng kể đến biến phụ thuộc hay không, ta sử dụng kiểm định giả thuyết cho hệ số b_1 như sau:

$$\begin{cases} H_0: b_1 = 0 \text{ (không tồn tại xu hướng tuyến tính theo thời gian)} \\ H_1: b_1 \neq 0 \text{ (tồn tại xu hướng tuyến tính theo thời gian)} \end{cases}$$

```
. gen t = _n
```

```
. reg passengers t
```


Source	SS	df	MS	Number of obs	=	120
Model	1143649.18	1	1143649.18	F(1, 118)	=	475.42
Residual	283852.742	118	2405.53172	Prob > F	=	0.0000
				R-squared	=	0.8012
				Adj R-squared	=	0.7995
Total	1427501.93	119	11995.8145	Root MSE	=	49.046

passengers	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
t	2.818255	.1292526	21.80	0.000	2.562299	3.07421
_cons	139.2206	9.010833	15.45	0.000	121.3767	157.0645

```
. predict Ft, xb
```

Kết quả hồi quy cho thấy giá trị p-value tương ứng với hệ số b_1 là rất nhỏ ($p = 0.000$). Điều này cho phép bác bỏ giả thuyết H_0 ở mức ý nghĩa thông thường ($\alpha = 5\%$), và có thể kết luận rằng có mối quan hệ giữa thời gian và số lượng hành khách. Nói cách khác, xu hướng theo thời gian là một yếu tố quan trọng ảnh hưởng đến sự thay đổi của chuỗi dữ liệu.

```
. scatter passengers t
```



Ngoài ra, hệ số b_1 dương và có giá trị đáng kể cho thấy xu hướng của chuỗi là tăng đều qua các kỳ. Điều này phù hợp với trực quan từ biểu đồ chuỗi, đồng thời cũng phản ánh đúng đặc điểm thực tiễn là lưu lượng hành khách tăng trưởng ổn định qua thời gian.

```

. gen FE = passengers - Ft

. gen absFE = abs( FE)

. gen sqFE = FE^2

. gen absperFE = absFE/ passengers*100

. mean absFE sqFE absperFE

```

Mean estimation

Number of obs = 120

	Mean	Std. err.	[95% conf. interval]	
absFE	37.39101	2.851141	31.74546	43.03655
sqFE	2365.44	361.8459	1648.948	3081.931
absperFE	11.77837	.7226332	10.34748	13.20925

Từ các kết quả trên, có thể nhận thấy rằng mô hình Linear Trend Regression dù đơn giản và có ý nghĩa thống kê về xu hướng, nhưng chưa mô tả tốt các biến động ngắn hạn và mùa vụ trong chuỗi dữ liệu. Mức sai số cao, đặc biệt là MAPE vượt ngưỡng 10%, cho thấy mô hình này thiếu độ chính xác trong dự báo thực tiễn, và chủ yếu phù hợp khi mục tiêu chỉ là kiểm định xu hướng dài hạn, chứ không nhằm mục đích dự báo chi tiết theo từng tháng.

3.6. Phương pháp Holt's Linear Exponential Smoothing

3.6.1. Mô tả

Phương pháp Holt's Linear Exponential Smoothing, hay còn gọi là phương pháp làm mượt hàm mũ tuyến tính hoặc phương pháp hàm mũ kép (double exponential smoothing), được Charles Holt phát triển nhằm khắc phục hạn chế của phương pháp Exponential Smoothing cơ bản - đó là không xử lý được chuỗi có xu hướng tuyến tính. Holt đề xuất một mô hình sử dụng hai hệ số làm mượt, cho phép đồng thời cập nhật cả mức độ hiện tại và xu hướng của chuỗi thời gian.

Công thức của mô hình Holt như sau:

$$L_t = \alpha Y_t + (1-\alpha)(L_{t-1} + b_{t-1})$$

$$b_t = \beta(L_t - L_{t-1}) + (1-\beta)b_{t-1}$$

$$F_{t+k} = L_t + k.b_t$$

Trong đó:

- L_t : thành phần mức độ tại thời điểm t .
- b_t : thành phần xu hướng tại thời điểm t .
- F_{t+k} : giá trị dự báo tại thời điểm $t+kt + kt+k$.
- α : hệ số làm mượt mức độ ($0 < \alpha < 1$).
- β : hệ số làm mượt xu hướng ($0 < \beta < 1$).
- Y_t : giá trị thực tế tại thời điểm t .

Việc khởi tạo ban đầu là một bước quan trọng: L_1 thường được lấy bằng giá trị đầu tiên của chuỗi, còn b_1 là sai khác giữa hai giá trị đầu tiên – xem như một ước lượng xu hướng ban đầu. Sau đó, các giá trị tiếp theo của L_t , b_t và F_t được cập nhật liên tục theo từng thời điểm.

3.6.2. Tính toán thủ công trên Excel

File Excel: [Phương pháp Holt' s Linear Exponential Smoothing](#)

3.6.3. Thực hành trên Stata

- $\alpha = 0.2$ và $\beta = 0.1$:

```
. tsset monthly_date

Time variable: monthly_date, 1951m1 to 1960m12
Delta: 1 month

. tssmooth hwinters holt = passengers, parms(0.2 0.1) s0(140 5)

Specified weights:
                alpha = 0.2000
                beta  = 0.1000
sum-of-squared residuals = 334638.7
root mean squared error = 52.80772
```

```

. gen FE = passengers - holt

. gen absFE = abs( FE)

. gen sqFE = FE^2

. gen absperFE = absFE/ passengers*100

. mean absFE sqFE absperFE

```

Mean estimation

Number of obs = 120

	Mean	Std. err.	[95% conf. interval]	
absFE	40.4365	3.113464	34.27153	46.60147
sqFE	2788.655	393.0936	2010.291	3567.02
absperFE	12.5702	.8257419	10.93515	14.20525

- $\alpha = 0.2$ và $\beta = 0.3$:

```

. tssmooth hwinters holt = passengers, parms(0.2 0.3) s0(140 5)

```

Specified weights:

alpha = 0.2000

beta = 0.3000

sum-of-squared residuals = 427304.5

root mean squared error = 59.67303

```

. gen FE = passengers - holt

. gen absFE = abs( FE)

. gen sqFE = FE^2

. gen absperFE = absFE/ passengers*100

. mean absFE sqFE absperFE

```

Mean estimation

Number of obs = 120

	Mean	Std. err.	[95% conf. interval]	
absFE	46.48637	3.429834	39.69496	53.27779
sqFE	3560.871	477.1931	2615.981	4505.761
absperFE	14.33499	.9178736	12.51751	16.15247

- $\alpha = 0.7$ và $\beta = 0.6$:

```
. tssmooth hwinters holt = passengers, parms(0.7 0.6) s0(140 5)

Specified weights:
                alpha = 0.7000
                beta  = 0.6000
sum-of-squared residuals = 258614.7
root mean squared error = 46.4233

. gen FE = passengers - holt

. gen absFE = abs( FE)

. gen sqFE = FE^2

. gen absperFE = absFE/ passengers*100

. mean absFE sqFE absperFE

Mean estimation                                Number of obs = 120
```

	Mean	Std. err.	[95% conf. interval]	
absFE	35.07913	2.787392	29.55982	40.59845
sqFE	2155.123	361.3928	1439.529	2870.716
absperFE	11.03742	.7297267	9.592483	12.48235

- $\alpha = 0.8$ và $\beta = 0.3$:

```
. tssmooth hwinters holt = passengers, parms(0.8 0.3) s0(140 5)
```

Specified weights:

alpha = 0.8000

beta = 0.3000

sum-of-squared residuals = 223106.6

root mean squared error = 43.1187

```
. gen FE = passengers - holt
```

```
. gen absFE = abs( FE)
```

```
. gen sqFE = FE^2
```

```
. gen absperFE = absFE/ passengers*100
```

```
. mean absFE sqFE absperFE
```

Mean estimation

Number of obs = 120

	Mean	Std. err.	[95% conf. interval]	
absFE	33.048	2.538861	28.0208	38.07519
sqFE	1859.222	287.3399	1290.26	2428.184
absperFE	10.36819	.6578102	9.065656	11.67072

- $\alpha = 0.9$ và $\beta = 0.5$:

```
. tssmooth hwinters holt = passengers, parms(0.9 0.5) s0(140 5)
```

Specified weights:

```
alpha = 0.9000
beta = 0.5000
sum-of-squared residuals = 207974.2
root mean squared error = 41.63073
```

```
. gen FE = passengers - holt
```

```
. gen absFE = abs( FE)
```

```
. gen sqFE = FE^2
```

```
. gen absperFE = absFE/ passengers*100
```

```
. mean absFE sqFE absperFE
```

Mean estimation

Number of obs = 120

	Mean	Std. err.	[95% conf. interval]	
absFE	31.48448	2.496797	26.54057	36.42839
sqFE	1733.118	296.1612	1146.689	2319.547
absperFE	9.821473	.6585951	8.517389	11.12556

Bảng tóm tắt các chỉ số:

Các chỉ số	MAE	MSE	MAPE
$\alpha = 0.2, \beta = 0.1$	40.4365	2788.655	12.5702
$\alpha = 0.2, \beta = 0.3$	46.48637	3560.871	14.33499
$\alpha = 0.7, \beta = 0.6$	35.07913	2155.123	11.03742
$\alpha = 0.8, \beta = 0.3$	33.048	1859.222	10.36819
$\alpha = 0.9, \beta = 0.5$	31.48448	1733.118	9.821473

Trong quá trình áp dụng phương pháp Holt's Linear Exponential Smoothing nhằm dự báo số lượng hành khách theo chuỗi thời gian nên đã tiến hành thử nghiệm với nhiều tổ hợp hệ số làm mượt khác nhau. Cụ thể, các giá trị α (hệ số làm mượt mức độ) và β (hệ

số làm mượt xu hướng) được thay đổi linh hoạt từ 0.2 đến 0.9 nhằm kiểm tra mức độ phản ứng của mô hình với biến động dữ liệu.

Đối với mỗi cặp (α, β) , mô hình dự báo được thực hiện và các sai số bao gồm MAE (sai số tuyệt đối trung bình), MSE (sai số bình phương trung bình) và MAPE (sai số phần trăm tuyệt đối trung bình) được tính toán để so sánh hiệu quả giữa các cặp hệ số. Trong ba chỉ số, MAPE được xem là tiêu chí chính do phản ánh sai số dự báo dưới dạng phần trăm – giúp so sánh khách quan giữa các mô hình.

Kết quả phân tích cho thấy cặp hệ số $(\alpha = 0.9, \beta = 0.5)$ là tổ hợp đem lại hiệu quả dự báo cao nhất, thể hiện qua giá trị MAPE thấp nhất trong toàn bộ các mô hình đã thử nghiệm. Việc sử dụng hệ số $\alpha = 0.9$ cho thấy mô hình rất nhạy với dữ liệu mới, phản ánh nhanh những biến động gần nhất của chuỗi. Đồng thời, với $\beta = 0.5$, xu hướng được cập nhật ở mức độ vừa phải, giúp mô hình duy trì được sự ổn định cần thiết mà vẫn không bỏ lỡ xu hướng dài hạn.

Ngược lại, các cặp có α hoặc β quá nhỏ tỏ ra kém hiệu quả hơn do mô hình phản ứng chậm, không theo kịp sự thay đổi nhanh của chuỗi dữ liệu thực tế. Điều này càng được khẳng định rõ hơn trong bối cảnh chuỗi số liệu hành khách có xu hướng tăng mạnh và không đều theo thời gian.

Từ các kết quả đã phân tích, có thể kết luận rằng cặp hệ số làm mượt (0.9, 0.5) là lựa chọn tối ưu cho phương pháp Holt's Linear ES trong bộ dữ liệu này. Mô hình này vừa đảm bảo phản ứng linh hoạt với xu thế tăng, vừa duy trì được tính mượt mà và ổn định trong dự báo ngắn hạn.

3.7. Phương pháp Seasonality and Trend (Hồi quy tuyến tính có yếu tố mùa vụ)

3.7.1. Mô tả

Phương pháp Seasonality and Trend là một cách tiếp cận đơn giản nhưng hiệu quả nhằm mô hình hóa chuỗi thời gian có chứa đồng thời yếu tố xu hướng và mùa vụ. Khác với các phương pháp làm mượt hàm mũ như Holt–Winters, phương pháp này dựa trên mô hình hồi quy tuyến tính trong đó xu hướng được thể hiện thông qua biến thời gian t , và yếu tố mùa vụ được đưa vào dưới dạng các *biến giả* (dummy variables).

Ý tưởng cơ bản của mô hình là tách rời phần xu hướng tuyến tính và ảnh hưởng mùa vụ bằng cách xây dựng phương trình hồi quy có dạng:

$$\hat{Y}_t = b_0 + b_1.x_1 + b_2.x_2 + \dots + b_n.x_n + b_{n+1}.t$$

Trong đó:

- $\hat{Y}_t$ là giá trị dự báo tại thời điểm t.
- b_0 là hằng số chặn (intercept),
- $x_1, x_2, \dots, x_n$ là các biến giả đại diện cho các mùa (ví dụ nếu có 3 mùa thì chỉ cần 2 biến giả),
- $b_1, b_2, \dots, b_n$ là hệ số phản ánh ảnh hưởng riêng của từng mùa,
- b_{n+1} là hệ số xu hướng – thể hiện tốc độ tăng/giảm của chuỗi theo thời gian.

Để xây dựng mô hình này, dữ liệu được mã hóa thêm các cột biến giả tương ứng với các mùa, sau đó đưa vào mô hình hồi quy tuyến tính cùng với biến thời gian. Mùa bị loại trừ (thường là mùa cuối cùng) sẽ được coi là biến cơ sở và được phản ánh gián tiếp thông qua hệ số chặn b_0 .

Ưu điểm của mô hình là đơn giản, dễ hiểu, và cho phép tách biệt rõ ràng ảnh hưởng của từng yếu tố cấu thành. Đồng thời, do dựa trên hồi quy tuyến tính, phương pháp này có thể được thực hiện dễ dàng trên Excel hoặc Stata. Tuy nhiên, mô hình giả định rằng xu hướng là tuyến tính và ảnh hưởng mùa vụ là cố định theo từng chu kỳ, do đó không phù hợp với những chuỗi có biến động phức tạp hơn hoặc phi tuyến.

3.7.2. Tính toán thủ công bằng Excel

File Excel: [Phương pháp Seasonality and Trend](#)

3.7.3. Thực hành trên Stata

```

. gen month_num = month(dofm(monthly_date))

. gen t = _n

. gen January = .
(120 missing values generated)

. replace January = 1 if month_num ==1
(10 real changes made)

. replace January = 0 if month_num !=1
(110 real changes made)

. gen Feburary = .
(120 missing values generated)

. replace Feburary = 1 if month_num ==2
(10 real changes made)

. replace Feburary = 0 if month_num !=2
(110 real changes made)

. gen March = .
(120 missing values generated)

. replace March = 1 if month_num ==3
(10 real changes made)

. replace March = 0 if month_num !=3
(110 real changes made)

. gen April = .
(120 missing values generated)

. replace April = 1 if month_num ==4
(10 real changes made)

. replace April = 0 if month_num !=4
(110 real changes made)

```



```
. gen May = .  
(120 missing values generated)  
  
. replace May = 1 if month_num ==5  
(10 real changes made)  
  
. replace May = 0 if month_num !=5  
(110 real changes made)  
  
. gen June = .  
(120 missing values generated)  
  
. replace June = 1 if month_num ==6  
(10 real changes made)  
  
. replace June = 0 if month_num !=6  
(110 real changes made)  
  
. gen July = .  
(120 missing values generated)  
  
. replace July = 1 if month_num ==7  
(10 real changes made)  
  
. replace July = 0 if month_num !=7  
(110 real changes made)
```

```

. gen August = .
(120 missing values generated)

. replace August = 1 if month_num ==8
(10 real changes made)

. replace August = 0 if month_num !=8
(110 real changes made)

. gen September = .
(120 missing values generated)

. replace September = 1 if month_num ==9
(10 real changes made)

. replace September = 0 if month_num !=9
(110 real changes made)

. gen October = .
(120 missing values generated)

. replace October = 1 if month_num ==10
(10 real changes made)

. replace October = 0 if month_num !=10
(110 real changes made)

. gen November = .
(120 missing values generated)

. replace November = 1 if month_num ==11
(10 real changes made)

. replace November = 0 if month_num !=11
(110 real changes made)

```

```
. reg passengers t January February March April May June July August September October November
```

Source	SS	df	MS	Number of obs	=	120
Model	1364791.83	12	113732.652	F(12, 107)	=	194.06
Residual	62710.0997	107	586.075699	Prob > F	=	0.0000
				R-squared	=	0.9561
				Adj R-squared	=	0.9511
Total	1427501.93	119	11995.8145	Root MSE	=	24.209

passengers	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
t	2.821254	.0641177	44.00	0.000	2.694148	2.94836
January	10.0338	10.84954	0.92	0.357	-11.47416	31.54175
February	-2.587458	10.84556	-0.24	0.812	-24.08752	18.91261
March	33.89129	10.84196	3.13	0.002	12.39836	55.38421
April	28.27003	10.83874	2.61	0.010	6.783499	49.75657
May	32.94878	10.83589	3.04	0.003	11.46788	54.42967
June	74.12753	10.83343	6.84	0.000	52.65152	95.60353
July	115.5063	10.83134	10.66	0.000	94.0344	136.9781
August	112.385	10.82963	10.38	0.000	90.91654	133.8535
September	53.56376	10.8283	4.95	0.000	32.09792	75.02961
October	11.94251	10.82735	1.10	0.273	-9.521457	33.40647
November	-27.97875	10.82678	-2.58	0.011	-49.44158	-6.515909
_cons	102.1972	8.74731	11.68	0.000	84.8567	119.5377

```
. predict Ft, xb
```

```
. gen FE = passengers - Ft
```

```
. gen abs = abs( FE)
```

```
. gen sq = FE^2
```

```
. gen absperFE = abs/ passengers*100
```

```
. mean abs sq absperFE
```

Mean estimation

Number of obs = 120

	Mean	Std. err.	[95% conf. interval]	
abs	17.77331	1.317924	15.16369	20.38293
sq	522.5843	76.2872	371.528	673.6406
absperFE	6.532044	.5505467	5.441906	7.622181

Sau khi thực hiện phương pháp Seasonality and Trend bằng hồi quy tuyến tính có biến giả mùa vụ, mô hình dự báo thu được có ý nghĩa thống kê ($p\text{-value} = 0.00 < \alpha = 0.05$) và phản ánh tương đối tốt đặc điểm của chuỗi dữ liệu.

Cụ thể, mô hình bao gồm biến thời gian t thể hiện xu hướng tuyến tính, kết hợp với các biến giả đại diện cho các tháng trong năm (từ January đến November, với December làm biến cơ sở). Kết quả hồi quy cho thấy hệ số xu hướng $b_t=2.82$ có ý nghĩa thống kê cao ($p = 0.000$), phản ánh rõ ràng xu hướng tăng đều của lượng hành khách theo thời gian. Ngoài ra, một số tháng như March, April, May, July và September có hệ số mùa vụ dương và có ý nghĩa thống kê, cho thấy mức độ dao động mùa vụ là đáng kể trong chuỗi dữ liệu.

Dự báo từ mô hình được so sánh với dữ liệu thực tế thông qua ba chỉ số sai số: $MAE = 17.77$, $MSE = 522.58$ và $MAPE = 6.53\%$. Đây là mức sai số thấp trong bối cảnh dự báo chuỗi theo tháng, cho thấy mô hình có độ chính xác tương đối cao. Đặc biệt, $MAPE$ dưới 10% thường được xem là chấp nhận được trong thực tiễn dự báo kinh tế - xã hội.

Tổng thể, phương pháp Seasonality and Trend không chỉ cung cấp một mô hình đơn giản, dễ hiểu, mà còn cho phép bóc tách rõ ảnh hưởng riêng biệt của xu hướng và mùa vụ. Mô hình cũng cho kết quả giải thích tốt ($R\text{-squared} = 0.9561$). Nhìn chung, đây là một lựa chọn hợp lý trong trường hợp chuỗi có mùa vụ cố định và xu hướng tuyến tính ổn định theo thời gian.

3.8. Phân tích tách thành phần (Time Series Decomposition)

3.8.1. Phương pháp cộng tính (Additive decomposition)

Phân tích chuỗi thời gian theo phương pháp cộng tính (Additive decomposition) là một trong những kỹ thuật cơ bản giúp tách một chuỗi thời gian thành các thành phần riêng biệt để phân tích sâu hơn về cấu trúc biến động của chuỗi. Phương pháp này giả định rằng chuỗi dữ liệu được hình thành bởi sự cộng gộp tuyến tính của ba yếu tố chính: xu hướng (trend), mùa vụ (seasonality) và nhiễu ngẫu nhiên (irregular/random).

Mô hình tổng quát của phương pháp cộng tính được viết dưới dạng:

$$Y_t = T_t + S_t + I_t$$

Trong đó:

- Y_t : giá trị thực tế của chuỗi tại thời điểm t .
- T_t : thành phần xu hướng - phản ánh xu hướng dài hạn của chuỗi.
- S_t : thành phần mùa vụ - lặp lại theo chu kỳ cố định (tháng, quý, năm...).
- I_t : thành phần nhiễu ngẫu nhiên - phần còn lại sau khi đã loại bỏ xu hướng và mùa vụ.

Phương pháp này phù hợp với những chuỗi thời gian mà biên độ dao động của yếu tố mùa vụ không thay đổi theo mức độ của chuỗi (tức là biến động có tính tuyến tính).

Đây là điểm khác biệt quan trọng so với phương pháp phân tích nhân tính.

File Excel: [Phương pháp Cộng tính](#)

Kết quả bảng chỉ số:

MAE	MSE	MAPE
76.40071529	8945.11204	25.47476442

Sau khi mô hình cộng tính được xây dựng, giá trị dự báo tại mỗi thời điểm được tính bằng tổng của thành phần xu hướng và thành phần mùa vụ. Độ chính xác của mô hình được đánh giá thông qua các chỉ số MAE, MSE và MAPE. Các chỉ số này lần lượt đo lường sai số tuyệt đối trung bình, sai số bình phương trung bình và tỷ lệ phần trăm sai số tuyệt đối trung bình, cho phép đánh giá toàn diện khả năng dự báo của mô hình.

3.8.2. Phương pháp nhân tính (Multiplicative decomposition)

Phương pháp nhân tính (Multiplicative decomposition) là một biến thể của kỹ thuật phân tích chuỗi thời gian, trong đó chuỗi được giả định là kết quả của sự kết hợp theo dạng nhân giữa các thành phần cấu thành: xu hướng (trend), mùa vụ (seasonality) và yếu tố ngẫu nhiên (irregular). Mô hình này đặc biệt phù hợp khi biên độ dao động trong chuỗi thời gian có xu hướng tăng hoặc giảm tỷ lệ thuận theo mức độ của chuỗi.

Dạng tổng quát của mô hình nhân tính được biểu diễn như sau:

$$Y_t = T_t \times S_t \times I_t$$

Trong đó:

- Y_t : giá trị thực tế tại thời điểm t ,
- T_t : thành phần xu hướng dài hạn,
- S_t : thành phần mùa vụ – dao động có tính chu kỳ,
- I_t : thành phần nhiễu ngẫu nhiên (bất quy tắc).

Điểm khác biệt cốt lõi so với phương pháp cộng tính là: trong khi cộng tính giả định ảnh hưởng của mùa vụ là mức độ tuyệt đối không đổi, thì phương pháp nhân tính lại giả định rằng ảnh hưởng của mùa vụ và nhiễu là tương đối - tỷ lệ so với quy mô tổng thể của chuỗi. Do đó, phương pháp này thường được sử dụng trong các chuỗi có tính chất tăng trưởng theo cấp số nhân, hoặc khi độ lớn của dao động thay đổi rõ rệt theo thời gian.

So với mô hình cộng tính, mô hình nhân tính thường mang lại kết quả chính xác hơn đối với các chuỗi có sự thay đổi quy mô lớn hoặc chuỗi thể hiện tính tỷ lệ rõ rệt trong mùa vụ. Tuy nhiên, việc xử lý và kiểm tra độ tin cậy của các thành phần nhân tính đòi hỏi tính toán cẩn thận hơn, đặc biệt trong các trường hợp có giá trị bằng 0 hoặc gần 0.

File Excel: [Phương pháp Nhân tính](#)

Kết quả bảng chỉ số:

MAE	MSE	MAPE
12.00532149	226.2474522	4.255723191

Sau khi thực hiện phân tích chuỗi thời gian theo phương pháp nhân tính, các thành phần xu hướng, mùa vụ và nhiễu đã được tách riêng và sử dụng để xây dựng mô hình dự báo. Thành phần xu hướng được xác định thông qua trung bình trượt 12 kỳ kết hợp với trung bình hai điểm nhằm điều chỉnh vị trí tâm. Thành phần mùa vụ được tính bằng cách chia giá trị thực tế cho xu hướng, sau đó được chuẩn hóa để đảm bảo tính cân bằng theo chu kỳ. Dự báo được thực hiện bằng công thức $\hat{Y}_t = S_t \times T_t$, trong đó T_t được biểu diễn dưới dạng tuyến tính thông qua hồi quy thời gian.

Sau khi hoàn thiện mô hình, các sai số dự báo bao gồm sai số tuyệt đối (AE), sai số bình phương (SE) và tỷ lệ sai số phần trăm (APE) đã được tính toán cho từng thời điểm. Từ đó, ba chỉ số MAE, MSE và MAPE được tính trung bình để đánh giá tổng thể độ chính xác của mô hình.

Kết quả cho thấy mô hình nhân tính phản ánh tốt đặc điểm của chuỗi dữ liệu với mức độ dao động tỷ lệ thuận theo xu hướng. Cụ thể, khi quan sát cột MAPE, giá trị sai số phần trăm trung bình nằm trong giới hạn chấp nhận được cho các mô hình dự báo thực tế. Điều này cho thấy mô hình không chỉ phù hợp về mặt lý thuyết mà còn cho kết quả dự báo đáng tin cậy. Đồng thời, sự ổn định của các chỉ số sai số cũng cho thấy khả năng tổng quát hóa mô hình khi áp dụng cho các giai đoạn tiếp theo của chuỗi.

So với phương pháp cộng tính, mô hình nhân tính thể hiện ưu thế trong việc mô phỏng các dao động có biên độ tăng dần - một đặc trưng phổ biến của các chuỗi thời gian trong thực tế như doanh số, lưu lượng hành khách, hoặc sản lượng sản xuất. Tuy nhiên, việc lựa chọn giữa hai mô hình vẫn cần dựa trên so sánh định lượng các chỉ số sai số, cũng như đánh giá bằng trực quan qua biểu đồ thực tế và dự báo.

CHƯƠNG 4. KẾT QUẢ SO SÁNH VÀ KẾT LUẬN

Sau khi lần lượt triển khai các phương pháp dự báo chuỗi thời gian từ đơn giản đến phức tạp, các kết quả dự báo đã được tổng hợp dựa trên ba chỉ số sai số quan trọng nhất: MAE (Mean Absolute Error), MSE (Mean Squared Error) và MAPE (Mean Absolute Percentage Error). Việc sử dụng đồng thời cả ba chỉ số nhằm đánh giá toàn diện khả năng dự báo của mỗi mô hình, trong đó MAPE được ưu tiên làm tiêu chí chính vì thể hiện sai số dưới dạng phần trăm – dễ so sánh giữa các chuỗi có quy mô khác nhau.

Phương pháp	MAE	MSE	MAPE (%)
Naive	28.61344538	1324.714286	8.980184546
MA(11)	41.38	3230.79	11.82
WMA(11) với bộ trọng số tốt nhất	38.47	3011.32	11.00
ES giản đơn ($\alpha=0.9$)	30.45767	1572.101	10.02865
Linear Trend Regression	37.39101	2365.44	11.77837
Holt's ES (0.9, 0.5)	31.48448	1733.118	9.821473
Seasonality & Trend	17.77331	522.5843	6.532044
Decomposition (cộng tính)	76.40071529	8945.11204	25.47476442
Decomposition (nhân tính)	12.00532149	226.2474522	4.255723191

Kết quả cho thấy, phương pháp Naive, dù đơn giản, vẫn đạt được mức MAPE tương đối tốt (8.98%), và đóng vai trò như một chuẩn nền để so sánh với các phương pháp phức tạp hơn. Tuy nhiên, do không khai thác được xu hướng hay mùa vụ trong

chuỗi, phương pháp này chỉ thích hợp cho dự báo rất ngắn hạn hoặc trong các chuỗi không có cấu trúc rõ ràng.

Trong nhóm các mô hình trung bình, WMA(11) (trọng số nhấn mạnh kỳ gần nhất) cho kết quả tốt hơn MA(11), với MAPE giảm từ 11.82% xuống còn 11.00%. Tuy nhiên, cả hai vẫn kém hơn rõ rệt so với các mô hình có khả năng mô phỏng xu hướng hoặc mùa vụ.

Phương pháp ES giản đơn với $\alpha = 0.9$ đạt được mức MAPE khá thấp (10.03%), chứng tỏ khả năng phản ứng linh hoạt với các biến động gần hiện tại, tuy nhiên vẫn chưa đủ để nắm bắt toàn bộ đặc điểm chuỗi có xu hướng tăng đều và mùa vụ rõ nét như dữ liệu hành khách.

Trong các mô hình có tính xu hướng, Holt's ES với cặp hệ số (0.9, 0.5) tiếp tục cải thiện độ chính xác (MAPE = 9.82%), phản ánh rõ việc bổ sung yếu tố xu hướng giúp nâng cao khả năng dự báo. Dù vậy, sự thiếu vắng thành phần mùa vụ vẫn khiến sai số chưa thể tối thiểu hóa hoàn toàn.

Tiếp đến các mô hình có khả năng mô hình hóa cả xu hướng và mùa vụ, hai phương pháp nổi bật là Seasonality & Trend (hồi quy tuyến tính có biến giả) và Decomposition (nhân tính). Trong đó, phương pháp Seasonality & Trend mang lại kết quả MAPE là 6.53%, trong khi Decomposition theo nhân tính đạt MAPE thấp nhất toàn bộ (4.26%). Điều này chứng tỏ phương pháp nhân tính rất phù hợp với dữ liệu có xu hướng tăng theo cấp số nhân và biến động theo mùa vụ ổn định.

Tuy nhiên, phương pháp Decomposition không xây dựng công thức dự báo chung như các mô hình hồi quy hay hàm mũ; thay vào đó, nó dựa vào việc tách riêng các thành phần xu hướng, mùa vụ và nhiễu, rồi kết hợp lại bằng phép nhân. Điều này khiến mô hình khó ứng dụng hơn nếu muốn cập nhật dữ liệu mới theo thời gian thực hoặc dùng để ngoại suy dài hạn. Mặt khác, mô hình Seasonality & Trend, dù có MAPE cao hơn một chút (6.53%), lại mang tính cấu trúc rõ ràng, dễ dàng kiểm định thống kê (qua p-value, R^2 ...), và có thể nội suy/ngoại suy trực tiếp bằng công thức hồi quy. Mô hình này đặc biệt phù hợp khi người dùng cần hiểu rõ vai trò của từng yếu tố (thời gian, mùa vụ), hoặc khi triển khai trên phần mềm thống kê chuẩn.

Dù vậy, theo mục tiêu của tiểu luận này là tìm ra mô hình dự báo chính xác nhất, chính vì vậy Decomposition (Multiplicative) là mô hình phù hợp nhất, dựa trên hiệu quả vượt trội về tất cả các chỉ số sai số. Dù mô hình này có một số hạn chế về mặt cơ chế toán học hoặc tự động hóa, kết quả thực nghiệm cho thấy đây là lựa chọn tối ưu trong bối cảnh dữ liệu hành khách có xu hướng nhân tăng và chu kỳ mùa vụ rõ rệt.

TÀI LIỆU THAM KHẢO

1. Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and Practice* (2nd ed.). OTexts. Retrieved from <https://otexts.com/fpp2/>
2. Makridakis, S., Wheelwright, S. C., & Hyndman, R. J. (1998). *Forecasting: Methods and Applications* (3rd ed.). Wiley.
3. Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control* (5th ed.). Wiley.
4. Brownlee, J. (n.d.). *Airline passengers dataset*. Retrieved from <https://raw.githubusercontent.com/jbrownlee/Datasets/master/airline-passengers.csv>
5. Lương Thanh Quỳnh. (2025). *Bài giảng Phân tích Dữ liệu Lớn*. Trường Đại học Kinh tế - Luật, ĐHQG TP.HCM.