



G04 NLP Report - hihihih

Marketing căn bản (Trường Đại học Phenikaa)



messages.pdf_cover_qr_code_label

ĐẠI HỌC PHENIKAA
TRƯỜNG CÔNG NGHỆ THÔNG TIN PHENIKAA



BÀI TẬP LỚN
XÂY DỰNG MÔ HÌNH DỊCH MÁY ANH - VIỆT

Giảng viên hướng dẫn: *PGS.TS. Phạm Tiến Lâm*
Sinh viên thực hiện: Ngô Quốc Anh - 22014051
Ninh Thị Phương Mai - 22010074
Đặng Hồng Nhung - 22010022
Nghiêm Diệu Linh - 22014066
Khóa: K16 – 2022 – 2026
Lớp tín chỉ: CSE703014
Chương trình đào tạo: ICT

Hà Nội, tháng 11 năm 2025

MỤC LỤC

LỜI CẢM ƠN.....	1
LỜI NÓI ĐẦU.....	2
CHƯƠNG I. GIỚI THIỆU VỀ XỬ LÝ NGÔN NGỮ TỰ NHIÊN.....	3
1.1 Tổng quan.....	3
1.2. Cơ sở khoa học.....	4
1.3 Một số khái niệm cơ bản.....	5
1.3.1 Ngôn ngữ tự nhiên.....	5
1.3.2 Nhập nhằng.....	6
1.3.3 Dịch máy.....	7
1.4 Quy trình xử lý ngôn ngữ tự nhiên.....	8
1.4.1 Tiền xử lý	8
1.4.2 Phân tích cú pháp và ngữ nghĩa	9
1.4.3 Mô hình hóa ngữ nghĩa.....	10
1.4.4 Sinh câu đích.....	11
1.4.5 Hậu xử lý.....	12
1.5 Ứng dụng của NLP trong đời sống.....	13
1.5.1 Dịch máy	13
1.5.2 Truy xuất thông tin.....	14
1.5.3 Tóm tắt và trích xuất thông tin.....	14
1.5.4 Phân tích và phân loại văn bản.....	14
CHƯƠNG II. MÔ TẢ BÀI TOÁN.....	15
2.1 Vì sao Dịch máy quan trọng?.....	15
2.2 Ứng dụng cụ thể của mô hình dịch máy Anh - Việt.....	15
2.3 Mô tả bài toán.....	17
2.4 Các bước triển khai bài toán.....	17
2.5 Phương thức đánh giá chất lượng bản dịch.....	19
2.5.1 Chỉ số BLEU.....	19
2.5.2 Chỉ số METEOR.....	20
2.5.3 Chỉ số TER.....	21
2.5.4 Đánh giá thủ công.....	21
2.6 So sánh các phương pháp dịch máy.....	22
2.6.1 SMT - statistical machine translation.....	22
2.6.2 Seq2seq + LSTM - Sequence-to-sequence with LSTM.....	23
2.6.3 Attention mechanism.....	24

2.6.4 Transformer.....	26
CHƯƠNG III. THU THẬP DỮ LIỆU.....	28
3.1. Nguồn dữ liệu.....	28
3.2. Phân tích và tiền xử lý dữ liệu.....	28
3.2.1. Độ dài trung bình câu.....	28
3.2.2. Từ phổ biến.....	29
3.2.3. Độ che phủ từ vựng.....	31
3.2.4. Tiền xử lý dữ liệu.....	32
3.2.5. Chia dữ liệu huấn luyện và kiểm thử.....	32
CHƯƠNG IV. PHÁT TRIỂN PHƯƠNG ÁN CHO BÀI TOÁN.....	33
4.1. Cơ sở lựa chọn hướng tiếp cận và Mô hình.....	34
4.2. Mô hình MarianMT.....	34
4.3. Phân tích dữ liệu đầu vào và chiến lược xử lý ngôn ngữ.....	35
4.4.1. Mã hóa (Encoding).....	35
4.4.2. Giải mã (Decoding) với Beam Search.....	36
CHƯƠNG V. TRIỂN KHAI VÀ ĐÁNH GIÁ.....	39
5.1. Xây dựng Giao diện Demo.....	39
5.2.Đánh giá chất lượng mô hình dịch.....	40
5.2.1. Đánh giá Định lượng.....	40
5.2.2. Đánh giá Định tính.....	40
5.2.3. Phân tích lỗi.....	41
CHƯƠNG VI. TÀI LIỆU THAM KHẢO.....	42

DANH MỤC PHÂN CÔNG CÔNG VIỆC

STT	Tên thành viên	Công việc	Đánh giá
1	Ngô Quốc Anh	Thiết kế mô hình; xây dựng training pipeline; tinh chỉnh hyperparameter; viết phần <i>Mô hình – Kết quả</i> .	10/10
2	Ninh Thị Phương Mai	Tiền xử lý dữ liệu; xây dựng BPE; viết BLEU evaluator; thống kê số liệu; viết phần <i>Đánh giá</i> .	10/10
3	Nghiêm Diệu Linh	Thu thập dữ liệu Anh–Việt; kiểm tra chất lượng; viết phần <i>Giới thiệu – Tổng quan – Dữ liệu</i> .	10/10
4	Đặng Hồng Nhung	Thu thập bổ sung; lọc thủ công; tạo testset; phân tích lỗi; viết phần <i>Thực nghiệm – Đánh giá định tính</i> .	10/10

LỜI CẢM ƠN

Trên hành trình hoàn thành bài tập lớn môn Xử lý Ngôn ngữ Tự nhiên với đề tài "Xây dựng mô hình dịch máy Anh - Việt", nhóm chúng em may mắn nhận được rất nhiều sự quan tâm, hỗ trợ, chỉ bảo và động viên từ các thầy cô, gia đình và bạn bè.

Lời đầu tiên, chúng em xin được bày tỏ lòng biết ơn sâu sắc và chân thành nhất đến **PGS.TS. Phạm Tiến Lâm**. Là những người trực tiếp hướng dẫn, thầy cô đã dành rất nhiều thời gian và tâm huyết cho nhóm chúng em. Thầy cô không chỉ truyền đạt những kiến thức nền tảng quý báu về lĩnh vực Xử lý Ngôn ngữ Tự nhiên, mà còn tận tình chỉ dẫn, định hướng phương pháp nghiên cứu, và đưa ra những góp ý vô cùng xác đáng để nhóm có thể tháo gỡ những khó khăn, vướng mắc trong suốt quá trình thực hiện đề tài. Sự kiên nhẫn, nhiệt tình và chuyên môn sâu rộng của thầy cô chính là nguồn động lực lớn nhất giúp chúng em có thể hoàn thành tốt bài báo cáo này.

Chúng em cũng xin trân trọng gửi lời cảm ơn đến Ban Giám hiệu **Đại học Phenikaa** cùng Ban Lãnh đạo **Trường Công nghệ Thông tin Phenikaa**. Nhà trường và Khoa đã luôn tạo điều kiện học tập, nghiên cứu tốt nhất, cung cấp cơ sở vật chất hiện đại và một môi trường học thuật năng động, sáng tạo để chúng em có thể phát huy tối đa khả năng của mình.

Nhân dịp này, chúng em cũng xin bày tỏ lòng biết ơn đến gia đình và bạn bè, những người đã luôn ở bên cạnh động viên, chia sẻ và tạo mọi điều kiện thuận lợi về cả vật chất lẫn tinh thần để chúng em có thể yên tâm học tập và nghiên cứu.

Cuối cùng, một lời cảm ơn không thể thiếu dành cho các thành viên trong nhóm. Cảm ơn tinh thần đoàn kết, sự nỗ lực không ngừng, tinh thần trách nhiệm cao và những buổi thảo luận sôi nổi để cùng nhau vượt qua mọi thử thách. Đề tài này chính là thành quả cho sự cố gắng chung của cả một tập thể.

Mặc dù nhóm đã đầu tư nhiều thời gian và công sức, nhưng do kiến thức chuyên môn và kinh nghiệm thực tiễn còn có hạn, bài báo cáo chắc chắn không thể tránh khỏi những thiếu sót. Chúng em rất mong nhận được những ý kiến đóng góp và chỉ bảo thêm từ thầy cô để đề tài được hoàn thiện hơn.

Chúng em xin chân thành cảm ơn!

LỜI NÓI ĐẦU

Trong kỷ nguyên của toàn cầu hóa và hội nhập quốc tế, nhu cầu trao đổi thông tin và tri thức trở nên cấp thiết hơn bao giờ hết. Tuy nhiên, rào cản ngôn ngữ vẫn là một trong những thách thức lớn nhất, ngăn cản sự giao thoa văn hóa và hợp tác toàn diện. Để giải quyết vấn đề này, lĩnh vực Trí tuệ Nhân tạo, đặc biệt là Xử lý Ngôn ngữ Tự nhiên (NLP), đã đạt được những bước tiến vượt bậc. Trong đó, Dịch máy (Machine Translation - MT) nổi lên như một công cụ thiết yếu, giúp xóa nhòa khoảng cách ngôn ngữ.

Tại Việt Nam, với sự hội nhập sâu rộng, tiếng Anh đã trở thành ngôn ngữ quan trọng bậc nhất trong hầu hết các lĩnh vực từ giáo dục, khoa học kỹ thuật đến kinh tế. Nhu cầu dịch thuật Anh-Việt và Việt-Anh chất lượng cao là rất lớn. Nhận thức được tầm quan trọng đó, và với mong muốn vận dụng kiến thức đã học từ môn Xử lý Ngôn ngữ Tự nhiên, nhóm chúng em đã quyết định thực hiện đề tài: **"Xây dựng mô hình dịch máy Anh - Việt"**.

Sự ra đời của Dịch máy Thần kinh (NMT) và đặc biệt là kiến trúc Transformer đã mang tính cách mạng, cho phép tạo ra các bản dịch có độ chính xác và trôi chảy vượt trội so với các phương pháp truyền thống. Mục tiêu của đề tài này là tập trung nghiên cứu, triển khai một mô hình NMT hiện đại (như MarianMT) cho cặp ngôn ngữ Anh-Việt. Nhóm đã tiến hành các bước từ tiền xử lý dữ liệu, huấn luyện mô hình, và cuối cùng là đánh giá hiệu suất của mô hình thông qua các thước đo tiêu chuẩn như BLEU, METEOR và TER.

Báo cáo này sẽ trình bày chi tiết quá trình thực hiện đề tài, bao gồm các phần chính: cơ sở lý thuyết về NLP và dịch máy, mô tả phương pháp thực hiện, và cuối cùng là phân tích, đánh giá các kết quả thực nghiệm đã đạt được.

Dù đã rất nỗ lực, nhưng do hạn chế về thời gian và kiến thức, bài báo cáo không thể tránh khỏi thiếu sót. Chúng em rất mong nhận được những ý kiến đóng góp quý báu từ thầy cô để đề tài được hoàn thiện hơn.

Chúng em xin chân thành cảm ơn!

CHƯƠNG I. GIỚI THIỆU VỀ XỬ LÝ NGÔN NGỮ TỰ NHIÊN

1.1 Tổng quan

Xử lý ngôn ngữ tự nhiên (*Natural Language Processing – NLP*) là một lĩnh vực đầy tiềm năng trong nghiên cứu và ứng dụng trí tuệ nhân tạo. Lĩnh vực này tập trung vào việc xây dựng các hệ thống có khả năng tương tác với con người thông qua ngôn ngữ tự nhiên. Mục tiêu chính của *NLP* là phát triển các mô hình giúp máy tính không chỉ hiểu và diễn giải, mà còn có thể tự động tạo ra ngôn ngữ tự nhiên, từ đó nâng cao trải nghiệm giao tiếp tự nhiên và hiệu quả cho người dùng.

NLP bao gồm nhiều yếu tố và công nghệ then chốt. Xử lý ngôn ngữ tự nhiên là quá trình phân tích và xử lý văn bản nhằm bóc tách từ, phân tích cú pháp, phân loại ngữ nghĩa, trích xuất thông tin và thực hiện truy vấn ngôn ngữ. Hiểu ngôn ngữ tự nhiên là một phần quan trọng của *NLP*, giúp hệ thống nhận diện và hiểu nội dung của câu, xác định ngữ cảnh, phân tích ý nghĩa cũng như nhận diện các thực thể như người, địa điểm hoặc tổ chức. Bên cạnh đó, tạo ngôn ngữ tự nhiên là quá trình mà máy tính sinh ra câu từ ngôn ngữ tự nhiên dựa trên dữ liệu, phục vụ cho việc trả lời câu hỏi, viết bài tự động hoặc tóm tắt nội dung.

Dịch máy, một ứng dụng phổ biến trong *NLP*, là quá trình tự động chuyển đổi văn bản từ một ngôn ngữ sang ngôn ngữ khác. Sự phát triển mạnh mẽ của các mô hình như *Transformer* đã mang lại những cải tiến đáng kể trong lĩnh vực này. Học máy (*Machine Learning*) trong *NLP* đóng vai trò quan trọng, với các phương pháp có giám sát và không giám sát, giúp hệ thống học hỏi và hiểu ngôn ngữ một cách linh hoạt, hiệu quả.

Ứng dụng của *NLP* hiện nay rất phong phú và đa dạng, từ hệ thống tìm kiếm thông tin, chatbot, đến các hệ thống phân tích cảm xúc và tóm tắt văn bản. Những tiến bộ vượt bậc trong *NLP*, đặc biệt nhờ vào học sâu (*Deep Learning*) và dữ liệu lớn, đã mở ra những khả năng mới cho lĩnh vực này, đồng thời mở rộng phạm vi ứng dụng trong nhiều ngành công nghiệp và dịch vụ.

Tuy nhiên, *NLP* cũng đang đối mặt với nhiều thách thức, đặc biệt là trong việc hiểu ngữ nghĩa sâu sắc, chuẩn hóa dữ liệu, và đảm bảo tính công bằng và đạo đức trong các ứng dụng. Các vấn đề như sự thiên vị trong dữ liệu, sự hiểu nhầm ngữ cảnh, và các vấn đề đạo đức liên quan đến việc sử dụng *NLP* (ví dụ như quyền riêng tư, bảo mật thông tin) cần được giải quyết để đảm bảo sự phát triển bền vững. Ngoài ra, tương lai của *NLP* hứa hẹn sẽ chứng kiến sự phát triển của các mô hình mới như *BERT*, *GPT*, hay các phương pháp

học sâu khác, giúp cải thiện độ chính xác và tính linh hoạt trong việc xử lý và tạo ngôn ngữ tự nhiên.

Sự phát triển của *NLP* phụ thuộc vào khả năng giải quyết những vấn đề này, nhằm mang lại lợi ích tối ưu cho người dùng và xã hội.

1.2. Cơ sở khoa học

Cơ sở khoa học của Xử lý Ngôn ngữ Tự nhiên (*Natural Language Processing – NLP*) được xây dựng trên nền tảng vững chắc từ nhiều lĩnh vực và nguyên tắc trong khoa học máy tính và ngôn ngữ học. Các yếu tố quan trọng tạo nên nền tảng của *NLP* bao gồm ngôn ngữ học, các phương pháp xử lý ngôn ngữ, học máy, thống kê và xác suất, cũng như khả năng xử lý dữ liệu lớn.

Ngôn ngữ học là nền tảng chủ yếu của *NLP*. Ngôn ngữ học nghiên cứu cấu trúc và chức năng của ngôn ngữ, bao gồm cú pháp, ngữ nghĩa và ngữ âm. Các khái niệm và phương pháp từ ngôn ngữ học cung cấp các công cụ phân tích và hiểu biết sâu sắc về ngôn ngữ tự nhiên. Thông qua việc áp dụng các lý thuyết ngôn ngữ học vào các mô hình *NLP*, các hệ thống có thể phân tích và hiểu cấu trúc ngữ pháp, nghĩa của từ và các mối quan hệ giữa các thành phần trong câu.

NLP áp dụng những phương pháp và thuật toán tiên tiến để xử lý và phân tích ngôn ngữ tự nhiên. Các phương pháp này bao gồm tách từ, phân tích cú pháp, phân loại ngữ nghĩa, trích xuất thông tin và dịch máy. Sự kết hợp giữa ngôn ngữ học và khoa học máy tính đã dẫn đến việc phát triển các công cụ và ứng dụng mạnh mẽ trong lĩnh vực ngôn ngữ, mở rộng khả năng của các hệ thống máy tính trong việc hiểu và tạo ra ngôn ngữ tự nhiên.

Học máy (*Machine Learning*) là một lĩnh vực quan trọng trong *NLP*, cho phép xây dựng và huấn luyện các mô hình máy tính tự động học từ dữ liệu. Học sâu (*Deep Learning*), đặc biệt là thông qua các mạng nơ-ron nhân tạo sâu, đã mang lại những tiến bộ vượt bậc cho *NLP*. Các mô hình như *BERT* và *GPT* đã giúp cải thiện hiệu suất cho nhiều ứng dụng ngôn ngữ, từ nhận dạng giọng nói đến phân tích văn bản, làm tăng độ chính xác và hiệu quả của các hệ thống xử lý ngôn ngữ.

Các khái niệm trong thống kê và xác suất đóng vai trò then chốt trong *NLP*. Mô hình ngôn ngữ dựa trên xác suất, như mô hình *Markov* và *n*-gram, được sử dụng để ước lượng xác suất cho các câu hoặc từ, từ đó tạo nền tảng cho nhiều thuật toán phân tích dữ liệu ngôn ngữ. Những mô hình này giúp các hệ thống *NLP* dự đoán và sinh ra các câu hoặc từ ngữ một cách hợp lý dựa trên xác suất.

Khả năng xử lý dữ liệu lớn là yếu tố quyết định cho sự phát triển của *NLP* hiện đại. Các mô hình *NLP* cần huấn luyện trên những tập dữ liệu khổng lồ, bao gồm các *corpus* văn bản và dữ liệu từ mạng xã hội. Công nghệ xử lý dữ liệu lớn, từ phân tán đến tính toán đám mây, đã đóng vai trò quan trọng trong việc tối ưu hóa quá trình huấn luyện các mô hình *NLP*. Các kỹ thuật này không chỉ giúp tăng cường hiệu quả xử lý mà còn mở rộng khả năng ứng dụng của *NLP* trong nhiều lĩnh vực.

Những cơ sở khoa học này, cùng với sự phát triển không ngừng của công nghệ và tính toán, đã mang đến những bước tiến đáng kể trong lĩnh vực *NLP*, làm cho các ứng dụng trở nên phổ biến và hữu ích hơn bao giờ hết trong cuộc sống thực tế.

1.3 Một số khái niệm cơ bản

1.3.1 Ngôn ngữ tự nhiên

Ngôn ngữ tự nhiên (*Natural Language*) là cách thức giao tiếp và truyền đạt thông tin giữa con người thông qua các yếu tố ngôn ngữ như từ vựng, ngữ pháp và ngữ cảnh. Đây là hệ thống ngôn ngữ mà con người sử dụng để diễn đạt suy nghĩ, chia sẻ thông tin, thể hiện cảm xúc và tương tác với nhau. Một đặc điểm nổi bật của ngôn ngữ tự nhiên là nó phản ánh cách con người truyền tải ý nghĩa và quan điểm thông qua việc sử dụng từ ngữ, cấu trúc ngữ pháp, ngữ cảnh và ngữ nghĩa.

Ngôn ngữ tự nhiên không chỉ là công cụ để giao tiếp mà còn là phương tiện để hình thành và truyền đạt những tư tưởng, khái niệm trừu tượng và phản ánh văn hóa, lịch sử của mỗi cộng đồng. Các yếu tố như từ vựng, ngữ pháp và ngữ cảnh đóng vai trò quan trọng trong việc xây dựng ý nghĩa trong giao tiếp. *Vocabulary* (từ vựng) giúp xác định đối tượng và khái niệm mà người nói hoặc người viết muốn truyền tải, trong khi *syntax* (ngữ pháp) quy định cách các từ được kết hợp để tạo thành câu. *Semantics* (ngữ nghĩa) giúp người nghe hoặc người đọc hiểu được ý nghĩa của câu, và *pragmatics* (ngữ cảnh) điều chỉnh cách thức sử dụng ngôn ngữ trong các tình huống khác nhau để đảm bảo giao tiếp hiệu quả.

Một trong những đặc điểm phức tạp và thú vị của ngôn ngữ tự nhiên là tính linh hoạt và thay đổi liên tục của nó. Các từ và cấu trúc ngữ pháp có thể mang nhiều ý nghĩa khác nhau tùy thuộc vào ngữ cảnh sử dụng, điều này làm cho ngôn ngữ tự nhiên trở thành một công cụ giao tiếp đa dạng và phong phú. Điều này cũng là lý do tại sao việc xử lý ngôn ngữ tự nhiên (*Natural Language Processing – NLP*) trong khoa học máy tính lại là một thách thức lớn. Các mô hình *NLP* cần phải hiểu được sự thay đổi linh hoạt này để có thể xử lý và tạo ra ngôn ngữ một cách tự động, điều này đòi hỏi sự phát triển liên tục của các thuật toán và công nghệ hiện đại như *deep learning* (học sâu) và *machine learning* (học máy).

Ngoài ra, ngôn ngữ tự nhiên còn phản ánh đặc điểm của các nền văn hóa khác nhau. Các cấu trúc ngữ pháp, từ vựng và cách thức tổ chức thông tin trong ngôn ngữ có thể khác nhau giữa các ngôn ngữ, điều này dẫn đến sự đa dạng trong cách thức diễn đạt và hiểu thông tin. Do đó, việc phát triển các hệ thống *NLP* cần phải xem xét sự khác biệt này để đảm bảo rằng các công cụ và ứng dụng có thể hoạt động hiệu quả trong nhiều ngữ cảnh văn hóa và ngôn ngữ khác nhau.

1.3.2 Nhập nhằng

Nhập nhằng trong ngôn ngữ học là hiện tượng phổ biến, nhưng trong giao tiếp hàng ngày, con người thường không chú ý đến nó vì họ xử lý hiện tượng này một cách tự nhiên. Tuy nhiên, trong các ứng dụng liên quan đến xử lý ngôn ngữ tự nhiên (*Natural Language Processing – NLP*), đặc biệt là dịch tự động, vấn đề nhập nhằng trở thành một thách thức nghiêm trọng. Sự nhập nhằng này xuất phát từ tính đa nghĩa của các từ, ngữ pháp và cấu trúc câu trong ngôn ngữ tự nhiên.

Một ví dụ điển hình của vấn đề này có thể thấy trong câu "Cô ấy thích chơi bóng". Từ "bóng" trong câu có thể ám chỉ đến *football* (bóng đá) hoặc *basketball* (bóng rổ), tùy thuộc vào ngữ cảnh sử dụng. Con người dễ dàng xác định nghĩa đúng của từ "bóng" dựa trên các yếu tố xung quanh và tình huống cụ thể. Ví dụ, nếu cuộc trò chuyện đang diễn ra trong một môi trường thể thao, người nghe sẽ có khả năng đoán được nghĩa của từ "bóng". Tuy nhiên, đối với máy móc, việc phân tích ngữ cảnh và quyết định nghĩa của từ trong những trường hợp này lại trở thành một nhiệm vụ vô cùng khó khăn.

Trong các hệ thống *NLP* hiện đại, việc giải quyết vấn đề nhập nhằng này đòi hỏi các thuật toán tiên tiến có khả năng phân tích ngữ nghĩa và xác định ngữ cảnh. Các mô hình học sâu (*deep learning*) và học máy (*machine learning*) đã được áp dụng để giúp máy tính học cách phân tích ngữ nghĩa từ các tập dữ liệu lớn và nhận diện các từ đa nghĩa trong các ngữ cảnh khác nhau. Một trong những phương pháp phổ biến để giải quyết vấn đề này là *word sense disambiguation* (WSD), một kỹ thuật nhằm xác định nghĩa chính xác của từ trong mỗi ngữ cảnh.

Ngoài ra, sự phát triển của các mô hình ngôn ngữ như *BERT* (Bidirectional Encoder Representations from Transformers) và *GPT* (Generative Pretrained Transformer) đã giúp cải thiện khả năng hiểu ngữ nghĩa trong các câu văn phức tạp. Các mô hình này có thể dựa vào ngữ cảnh xung quanh để phân biệt các nghĩa khác nhau của từ, từ đó nâng cao hiệu quả trong các ứng dụng dịch tự động và các hệ thống tìm kiếm thông tin.

Tìm ra các thuật toán hiệu quả để giải quyết vấn đề nhập nhằng này là một thách thức lớn đối với các nhà nghiên cứu và lập trình viên trong lĩnh vực *NLP*. Việc cải thiện khả năng

phân tích ngữ nghĩa sẽ giúp các hệ thống xử lý ngôn ngữ tự nhiên hoạt động hiệu quả hơn, mang lại nhiều ứng dụng thiết thực trong các công nghệ như dịch máy (*machine translation*), nhận diện giọng nói (*speech recognition*), và trợ lý ảo (*virtual assistants*).

1.3.3 Dịch máy

Dịch máy (*Machine Translation – MT*) là một trong những ứng dụng quan trọng của xử lý ngôn ngữ tự nhiên (*Natural Language Processing – NLP*), sử dụng máy tính để chuyển đổi văn bản từ ngôn ngữ này sang ngôn ngữ khác. Mặc dù lĩnh vực này đã được nghiên cứu và phát triển trong nhiều thập kỷ, vẫn còn tồn tại nhiều vấn đề cần giải quyết. Các hệ thống dịch máy hiện tại vẫn gặp khó khăn trong việc chuyển ngữ chính xác, đặc biệt là trong các ngữ cảnh phức tạp và các ngôn ngữ có cấu trúc khác biệt.

Tại Việt Nam, nghiên cứu về dịch máy đã diễn ra trong một khoảng thời gian dài, với nhiều công trình nghiên cứu tập trung vào việc cải thiện chất lượng dịch giữa tiếng Việt và các ngôn ngữ khác, đặc biệt là tiếng Anh. Tuy nhiên, chất lượng của các sản phẩm dịch máy hiện nay vẫn còn nhiều hạn chế. Các hệ thống dịch máy hiện tại vẫn gặp khó khăn trong việc xử lý các từ đa nghĩa, các cấu trúc ngữ pháp phức tạp và sự khác biệt trong văn hóa và ngữ nghĩa giữa các ngôn ngữ.

Dịch máy hiện nay được phân chia thành một số phương pháp chính, bao gồm dịch máy dựa trên luật, dịch máy thống kê và dịch máy dựa trên ví dụ. Mỗi phương pháp có những ưu điểm và hạn chế riêng.

1. Dịch máy dựa trên luật (*Rule-Based Machine Translation – RBMT*): Phương pháp này sử dụng các quy tắc ngữ pháp và từ vựng của cả hai ngôn ngữ để chuyển đổi văn bản. Mặc dù phương pháp này có thể tạo ra các bản dịch chính xác trong một số trường hợp, nhưng nó yêu cầu bộ quy tắc rất phức tạp và không thể xử lý tốt các trường hợp có sự thay đổi ngữ nghĩa tùy thuộc vào ngữ cảnh.
2. Dịch máy thống kê (*Statistical Machine Translation – SMT*): Phương pháp này sử dụng các mô hình thống kê để dự đoán từ hoặc cụm từ trong ngôn ngữ đích dựa trên sự xuất hiện của chúng trong các tập dữ liệu song ngữ. Dịch máy thống kê đã giúp cải thiện chất lượng dịch, nhưng vẫn gặp phải khó khăn khi xử lý các cấu trúc ngữ pháp phức tạp hoặc khi dữ liệu huấn luyện không đủ đa dạng.
3. Dịch máy dựa trên ví dụ (*Example-Based Machine Translation – EBMT*): Phương pháp này sử dụng các ví dụ dịch đã được huấn luyện để tạo ra các bản dịch mới. Mặc dù phương pháp này có thể mang lại kết quả tốt trong các trường hợp có sẵn dữ liệu huấn luyện phong phú, nhưng nó vẫn chưa thể xử lý tốt các ngữ cảnh mới hoặc các ngôn ngữ ít phổ biến.

Tuy nhiên, một bước đột phá lớn trong lĩnh vực dịch máy là sự xuất hiện của dịch máy dựa trên mạng nơ-ron (*Neural Machine Translation – NMT*), đặc biệt là các mô hình dựa trên *Transformer*. Các mô hình này, như *BERT (Bidirectional Encoder Representations from Transformers)* và *GPT (Generative Pretrained Transformer)*, đã mang lại sự cải thiện đáng kể trong khả năng hiểu và chuyển ngữ các văn bản. Với *NMT*, thay vì xử lý từng từ một cách độc lập, các mô hình học sâu học cách mô hình hóa ngữ cảnh toàn bộ câu, điều này giúp tạo ra bản dịch tự nhiên và chính xác hơn. Tuy nhiên, dịch máy vẫn gặp phải các thách thức khi dịch giữa các ngôn ngữ có cấu trúc ngữ pháp và cú pháp rất khác biệt, đặc biệt là khi dịch các từ ngữ hoặc cụm từ mang tính chất văn hóa đặc thù.

Một thách thức khác trong dịch máy là khả năng xử lý các từ đa nghĩa, điều này đặc biệt quan trọng khi dịch các ngôn ngữ có nhiều từ đồng âm hoặc có nghĩa khác nhau tùy vào ngữ cảnh. Việc áp dụng các mô hình học máy hiện đại và cải tiến thuật toán sẽ tiếp tục là hướng đi quan trọng để nâng cao chất lượng dịch máy trong tương lai.

1.4 Quy trình xử lý ngôn ngữ tự nhiên

Trong lĩnh vực xử lý ngôn ngữ tự nhiên (*Natural Language Processing – NLP*), để máy tính có thể hiểu và tạo ra ngôn ngữ con người, cần một quy trình gồm nhiều bước xử lý nhằm chuyển đổi dữ liệu ngôn ngữ đầu vào (thường là văn bản hoặc lời nói) thành dạng biểu diễn mà máy có thể phân tích, suy luận và phản hồi. Quy trình này bao gồm các giai đoạn cơ bản như tách từ (*tokenization*), phân tích cú pháp (*parsing*), nhận dạng thực thể có tên (*Named Entity Recognition – NER*), phân loại cảm xúc (*sentiment analysis*), và dịch ngôn ngữ (*machine translation*).

Với bài toán dịch máy Anh - Việt, hệ thống cần thực hiện một chuỗi các giai đoạn xử lý từ đầu vào là câu tiếng Anh, đến đầu ra là câu tiếng Việt tương ứng. Quá trình này không chỉ bao gồm việc chuyển ngữ từ ngữ nghĩa của từ và cụm từ, mà còn phải chú trọng đến các yếu tố ngữ pháp và ngữ cảnh để tạo ra câu văn mượt mà và dễ hiểu trong ngôn ngữ đích.

1.4.1 Tiền xử lý (*pre-processing*)

Giai đoạn tiền xử lý (*Preprocessing*) trong xử lý ngôn ngữ tự nhiên (*Natural Language Processing – NLP*) là một bước quan trọng để chuẩn bị dữ liệu đầu vào trước khi thực hiện các thao tác xử lý phức tạp hơn. Quá trình này bao gồm một loạt các bước chuẩn hóa văn bản nhằm đảm bảo rằng dữ liệu được xử lý ở dạng có thể phân tích được. Những bước chuẩn hóa này giúp loại bỏ nhiễu và sự phức tạp không cần thiết, đồng thời chuẩn bị dữ liệu cho các bước xử lý sau. Các bước chính trong giai đoạn tiền xử lý bao gồm:

1. *Chuyển văn bản về chữ thường (lowercasing)*: Một trong những bước cơ bản trong tiền xử lý là chuyển tất cả các ký tự trong văn bản thành chữ thường. Việc này giúp giảm bớt sự phức tạp do phân biệt chữ hoa và chữ thường trong các thuật toán phân tích ngôn ngữ, giúp máy tính xử lý và phân tích văn bản hiệu quả hơn, nhất là khi văn bản có sự pha trộn giữa các ký tự viết hoa và viết thường.
2. *Loại bỏ ký tự đặc biệt (removing special characters)*: Ký tự đặc biệt như dấu câu, các ký tự không phải là chữ cái hay số thường không mang ý nghĩa quan trọng trong các ứng dụng phân tích ngôn ngữ, đặc biệt là trong các bài toán như phân loại văn bản và dịch máy. Việc loại bỏ chúng giúp giảm bớt sự phức tạp và làm sạch dữ liệu đầu vào.
3. *Tách từ (tokenization)*: Tách từ là quá trình chia một đoạn văn bản thành các đơn vị nhỏ hơn gọi là "tokens" (các từ hoặc cụm từ). Đây là một bước quan trọng trong xử lý ngôn ngữ tự nhiên, giúp máy tính hiểu được các đơn vị cơ bản của ngôn ngữ. Tách từ có thể được thực hiện theo các cách khác nhau tùy thuộc vào ngôn ngữ và ứng dụng cụ thể. Đối với tiếng Anh, việc tách từ khá đơn giản nhờ vào dấu cách phân tách các từ, nhưng đối với các ngôn ngữ như tiếng Việt, việc tách từ có thể phức tạp hơn.
4. *Gán nhãn từ loại (POS tagging)*: Gán nhãn từ loại là quá trình xác định từ loại của từng từ trong câu, chẳng hạn như danh từ, động từ, tính từ, v.v. Việc gán nhãn từ loại giúp hệ thống hiểu được vai trò của từng từ trong câu và tạo nền tảng cho các bước phân tích ngữ pháp phức tạp hơn. Các mô hình học máy và học sâu hiện nay có thể thực hiện bước này rất chính xác, đặc biệt khi sử dụng các mô hình *Recurrent Neural Networks (RNN)* và *Long Short-Term Memory Networks (LSTM)*.

Đối với tiếng Việt, giai đoạn này có thể cần thêm bước **tách từ** vì tiếng Việt không có khoảng trắng phân tách từ như tiếng Anh. Việc tách từ trong tiếng Việt đòi hỏi các kỹ thuật đặc biệt, chẳng hạn như sử dụng các công cụ phân tích ngữ nghĩa và thống kê hoặc các mô hình học máy được huấn luyện với bộ dữ liệu tiếng Việt. Điều này gây ra một số thách thức trong xử lý ngôn ngữ tự nhiên cho tiếng Việt, nhưng cũng đã có một số tiến bộ trong việc phát triển các công cụ tách từ cho ngôn ngữ này, ví dụ như các công cụ *VnTokenizer* hay các mô hình *word2vec* đã được điều chỉnh cho tiếng Việt.

1.4.2 Phân tích cú pháp và ngữ nghĩa (*syntax & semantic analysis*)

Phân tích cú pháp và ngữ nghĩa (*Parsing & Semantic Analysis*) là các bước quan trọng trong xử lý ngôn ngữ tự nhiên (*Natural Language Processing – NLP*), giúp hệ thống hiểu cấu trúc và ý nghĩa của câu đầu vào. Trong giai đoạn phân tích cú pháp (*syntactic parsing*), hệ thống xây dựng cấu trúc cú pháp của câu để hiểu mối quan hệ giữa các thành

phần trong câu, chẳng hạn như chủ ngữ, động từ, tân ngữ, và các thành phần khác. Điều này giúp máy tính hiểu được cấu trúc ngữ pháp và các mối quan hệ ngữ nghĩa cơ bản trong câu, từ đó phục vụ cho các nhiệm vụ phức tạp hơn như dịch máy (*machine translation*), phân tích cảm xúc (*sentiment analysis*), hay trích xuất thông tin (*information extraction*).

Trong khi phân tích cú pháp tập trung vào việc xác định cấu trúc ngữ pháp, phân tích ngữ nghĩa (*semantic analysis*) nhằm mục đích hiểu ý nghĩa thực sự của câu. Quá trình này bao gồm việc xác định các thực thể trong câu và mối quan hệ giữa chúng, cũng như giải thích ý nghĩa của các từ và cụm từ trong ngữ cảnh cụ thể. Việc phân tích ngữ nghĩa đóng vai trò quan trọng trong các ứng dụng như dịch máy và chatbot, giúp hệ thống hiểu được ý định của người dùng và phản hồi một cách chính xác.

Cấu trúc cú pháp của câu được xây dựng qua các bước phân tích, bao gồm các kỹ thuật như phân tích cú pháp phụ thuộc (*dependency parsing*) và phân tích cú pháp cây (*constituency parsing*). Các mô hình học máy (*machine learning models*) như *Hidden Markov Models (HMM)* và *Conditional Random Fields (CRF)* đã được sử dụng trong các bước phân tích cú pháp để nhận diện các mối quan hệ giữa các thành phần ngữ pháp. Tuy nhiên, các mô hình học sâu (*deep learning*) hiện đại, đặc biệt là các mô hình *Transformer*, đã cách mạng hóa cách thức thực hiện phân tích cú pháp và ngữ nghĩa.

Với các mô hình học sâu như *Transformer*, cú pháp không còn được xây dựng qua các quy tắc và thuật toán tĩnh, mà được học ngầm bên trong các lớp của mô hình thông qua việc xử lý các mối quan hệ giữa các từ trong câu. Các mô hình như *BERT (Bidirectional Encoder Representations from Transformers)* và *GPT (Generative Pretrained Transformer)* đã làm cho việc phân tích cú pháp và ngữ nghĩa trở nên hiệu quả hơn nhiều. Thay vì sử dụng các quy tắc cứng, những mô hình này có thể học được cấu trúc cú pháp và ý nghĩa từ một lượng lớn dữ liệu huấn luyện, giúp cải thiện độ chính xác trong các nhiệm vụ như dịch máy và tóm tắt văn bản.

Các phương pháp học sâu đã giúp giảm bớt sự phụ thuộc vào các quy tắc ngữ pháp tĩnh và mang lại những cải tiến vượt bậc trong khả năng hiểu ngữ nghĩa của các hệ thống xử lý ngôn ngữ tự nhiên. Tuy nhiên, việc hiểu sâu sắc ngữ nghĩa và ngữ cảnh vẫn là một thách thức lớn đối với các hệ thống *NLP*, đặc biệt là khi xử lý các ngôn ngữ có cấu trúc phức tạp hoặc khi cần phải xác định ý nghĩa trong các ngữ cảnh mơ hồ.

1.4.3 Mô hình hóa ngữ nghĩa (*representation*)

Sau khi câu tiếng Anh được xử lý qua các bước tiền xử lý và phân tích cú pháp, bước tiếp theo là mô hình hóa ngữ nghĩa (*semantic representation*), trong đó câu được ánh xạ thành

một dạng biểu diễn nội bộ có thể hiểu và xử lý bởi hệ thống máy tính. Dạng biểu diễn này thường được sử dụng để "hiểu" nội dung và ngữ nghĩa của câu trong các ứng dụng như dịch máy (*machine translation*), phân tích cảm xúc (*sentiment analysis*), và các hệ thống trả lời câu hỏi (*question answering*).

Một trong những phương pháp phổ biến trong mô hình hóa ngữ nghĩa là sử dụng vector ngữ nghĩa (*semantic vector embeddings*). Đây là một phương pháp đại diện cho từ hoặc câu dưới dạng các vector số học trong không gian đa chiều. Các vector này được học thông qua các mô hình học sâu (*deep learning*), chẳng hạn như *Word2Vec*, *GloVe*, hoặc các mô hình gần đây như *BERT* và *GPT*. Mỗi từ hoặc câu được ánh xạ thành một vector, và các vector này phản ánh mối quan hệ ngữ nghĩa giữa các từ và các câu.

Ví dụ, trong mô hình *Word2Vec*, các từ có ngữ nghĩa tương tự sẽ có các vector gần nhau trong không gian. Điều này cho phép máy tính nhận diện và so sánh ngữ nghĩa của các từ trong một ngữ cảnh nhất định. Các mô hình *transformer-based* như *BERT* (*Bidirectional Encoder Representations from Transformers*) hay *GPT* (*Generative Pretrained Transformer*) đã mang lại sự tiến bộ vượt bậc trong mô hình hóa ngữ nghĩa. Các mô hình này không chỉ học được các vector đại diện cho các từ mà còn có thể học được ngữ nghĩa của các câu phức tạp thông qua việc sử dụng các lớp encoder để mã hóa các mối quan hệ giữa các từ và cụm từ trong một câu.

Quá trình mô hình hóa ngữ nghĩa không chỉ bao gồm việc chuyển đổi các từ thành các vector mà còn liên quan đến việc hiểu mối quan hệ giữa các từ, cụm từ và câu trong ngữ cảnh cụ thể. Điều này có thể được thực hiện thông qua các mô hình học sâu, trong đó mỗi từ hoặc câu được ánh xạ vào một không gian vector cao chiều, nơi mối quan hệ giữa các từ được học và tối ưu hóa. Các mô hình như *BERT* và *GPT* không chỉ học các đại diện từ mà còn học các mối quan hệ ngữ nghĩa giữa các câu và giữa các câu trong văn bản lớn, điều này làm cho chúng trở nên mạnh mẽ trong các tác vụ như dịch máy và trả lời câu hỏi.

Bước mô hình hóa ngữ nghĩa này đóng vai trò quan trọng trong việc giúp hệ thống "hiểu" nội dung của câu và thực hiện các tác vụ ngôn ngữ phức tạp một cách chính xác hơn. Các vector ngữ nghĩa cũng là cơ sở cho nhiều ứng dụng của *NLP*, bao gồm tìm kiếm thông tin (*information retrieval*), phân loại văn bản (*text classification*), và tạo văn bản tự động (*text generation*).

1.4.4 Sinh câu đích (*target sentence generation*)

Biểu diễn ngữ nghĩa (*semantic representation*) được sử dụng để tạo ra câu tiếng Việt tương ứng thông qua cơ chế giải mã (*decoder*). Quá trình này đóng vai trò quan trọng

trong các hệ thống dịch máy (*machine translation*), nơi hệ thống cần chuyển đổi từ một ngôn ngữ đầu vào (như tiếng Anh) thành ngôn ngữ đích (như tiếng Việt). Các mô hình hiện đại như *MarianMT*, *Transformer*, hay *mBART* đều thực hiện quá trình này thông qua các lớp mạng học sâu (*deep learning networks*), học từ dữ liệu song ngữ huấn luyện.

Trong các mô hình như *Transformer* và *mBART*, quá trình sinh câu đích được thực hiện thông qua một cơ chế gọi là **giải mã** (*decoding*), nơi các biểu diễn ngữ nghĩa của câu đầu vào được chuyển thành câu văn mượt mà và chính xác trong ngôn ngữ đích. Các mô hình này sử dụng các lớp học sâu để học cách tạo ra câu từ các biểu diễn ngữ nghĩa, giúp cải thiện chất lượng dịch máy và khả năng tạo câu tự động.

Quá trình giải mã (*decoding*) thường bao gồm việc chuyển các vector ngữ nghĩa thành các từ trong ngôn ngữ đích thông qua các lớp mạng học sâu, bao gồm cả việc tính toán xác suất của mỗi từ trong câu đích. Các mô hình như *Transformer* sử dụng cơ chế *self-attention*, cho phép hệ thống học được mối quan hệ giữa các từ trong câu và đồng thời tạo ra các từ mới theo ngữ cảnh. Điều này giúp hệ thống dịch máy không chỉ sao chép lại các từ từ ngôn ngữ nguồn mà còn tạo ra câu đích tự nhiên, phù hợp với ngữ cảnh.

Các mô hình như *MarianMT* và *mBART* (*Multilingual BART*) là các phiên bản cải tiến của *Transformer*, được huấn luyện trên dữ liệu song ngữ đa ngôn ngữ, giúp xử lý nhiều ngôn ngữ và cải thiện khả năng dịch giữa các ngôn ngữ khác nhau, bao gồm cả những ngôn ngữ ít tài liệu huấn luyện. Điều này làm cho các mô hình này rất mạnh mẽ trong việc sinh câu đích, đặc biệt trong các ngữ cảnh phức tạp và các bài toán dịch ngữ nghĩa giữa các ngôn ngữ có sự khác biệt lớn về cấu trúc và ngữ pháp.

Quá trình sinh câu đích không chỉ giúp tạo ra câu đích chính xác mà còn đảm bảo rằng câu đích phù hợp với ngữ cảnh, có ngữ pháp đúng và dễ hiểu. Các mô hình học sâu hiện đại này đang dần thay thế các phương pháp dịch máy truyền thống, mang lại sự cải thiện rõ rệt về chất lượng dịch và khả năng tự động tạo văn bản.

1.4.5 Hậu xử lý (*post-processing*)

Sau khi sinh câu tiếng Việt từ quá trình dịch, hệ thống có thể cần thực hiện các bước hậu xử lý (*postprocessing*) để đảm bảo rằng bản dịch cuối cùng là chính xác, tự nhiên và dễ hiểu đối với người dùng. Hậu xử lý là một giai đoạn quan trọng trong quy trình dịch máy (*machine translation*), nhằm cải thiện chất lượng của đầu ra và đảm bảo rằng các văn bản được tạo ra phù hợp với ngữ cảnh và yêu cầu của người sử dụng. Các bước hậu xử lý thường bao gồm:

1. *Chỉnh sửa lại chính tả và dấu câu (spelling and punctuation correction)*: Trong quá trình dịch, có thể xảy ra các lỗi chính tả hoặc sử dụng dấu câu không đúng, do hệ thống dịch không nhận diện được các quy tắc chính tả hoặc cấu trúc dấu câu trong ngôn ngữ đích. Hệ thống hậu xử lý sẽ sửa các lỗi này để đảm bảo câu dịch dễ đọc và tuân thủ các quy tắc ngữ pháp của ngôn ngữ đích. Đặc biệt, đối với tiếng Việt, việc sử dụng dấu câu chính xác và tách biệt giữa các từ có thể rất quan trọng để đảm bảo nghĩa của câu không bị sai lệch.
2. *Ghép từ lại (rejoining words)*: Trong các ngôn ngữ như tiếng Việt, quá trình tách từ (*tokenization*) có thể gây khó khăn do thiếu khoảng trắng phân tách giữa các từ. Nếu trong quá trình tiền xử lý hệ thống đã tách từ, bước hậu xử lý sẽ cần phải ghép các từ lại với nhau để đảm bảo tính hợp lý và mượt mà của câu dịch. Điều này đặc biệt quan trọng khi dịch các câu dài hoặc các từ ghép trong tiếng Việt, nơi các từ có thể bị tách rời nhưng lại cần phải được ghép lại để tạo thành từ ngữ có nghĩa.
3. *Chuẩn hóa đầu ra (output normalization)*: Sau khi hoàn thành các bước chỉnh sửa và ghép từ, hệ thống sẽ cần chuẩn hóa đầu ra để phù hợp với ngữ cảnh và yêu cầu của người dùng. Quá trình chuẩn hóa có thể bao gồm việc điều chỉnh phong cách viết, sử dụng các từ ngữ hoặc cách diễn đạt phù hợp với đối tượng người dùng mục tiêu. Ví dụ, trong một ứng dụng dịch máy phục vụ cho khách hàng, đầu ra cần phải có ngữ điệu trang trọng, trong khi với các hệ thống dịch máy không chính thức, ngữ điệu có thể thoải mái và dễ hiểu hơn. Hệ thống cũng cần điều chỉnh các thuật ngữ chuyên ngành hoặc địa phương sao cho chính xác và phù hợp.

Các bước hậu xử lý này giúp nâng cao chất lượng của hệ thống dịch máy, đảm bảo rằng câu dịch cuối cùng không chỉ chính xác về mặt ngữ nghĩa mà còn mượt mà và tự nhiên như một văn bản được viết trực tiếp bằng ngôn ngữ đích. Hệ thống hậu xử lý cũng có thể áp dụng các công cụ kiểm tra chính tả và ngữ pháp tự động, các thuật toán học máy (*machine learning algorithms*) để tối ưu hóa đầu ra cuối cùng.

1.5 Ứng dụng của NLP trong đời sống

Xử lý ngôn ngữ tự nhiên (*Natural Language Processing – NLP*) là lĩnh vực kết hợp giữa ngôn ngữ học và trí tuệ nhân tạo, nhằm giúp máy tính hiểu, phân tích và tạo ra ngôn ngữ của con người. Trong những năm gần đây, *NLP* đã đạt được nhiều tiến bộ vượt bậc và được ứng dụng rộng rãi trong nhiều lĩnh vực thực tiễn.

1.5.1 Dịch máy (*machine translation*)

Dịch máy là một trong những ứng dụng tiêu biểu và quan trọng nhất của *NLP*. Hệ thống dịch tự động cho phép chuyển đổi văn bản từ một ngôn ngữ sang một ngôn ngữ khác một

cách nhanh chóng và tiện lợi. Các mô hình hiện đại như *Transformer*, *MarianMT*, *mBART* đã giúp cải thiện đáng kể chất lượng dịch, đặc biệt trong các ứng dụng dịch đa ngôn ngữ, hỗ trợ giao tiếp toàn cầu trong học tập, làm việc và trao đổi thông tin. Các mô hình này sử dụng các kỹ thuật học sâu (*deep learning*) và *neural machine translation* (NMT), mang lại khả năng dịch chính xác và tự nhiên hơn, đặc biệt trong các ngữ cảnh phức tạp.

1.5.2 Truy xuất thông tin (*information retrieval*)

NLP cũng đóng vai trò quan trọng trong các công cụ tìm kiếm như Google, Bing và các công cụ tìm kiếm khác, giúp hiểu rõ hơn ý định người dùng và trả về các kết quả chính xác, phù hợp về ngữ nghĩa. Các kỹ thuật như phân tích từ khóa, truy vấn ngữ nghĩa (*semantic search*) và xếp hạng kết quả dựa trên ngữ cảnh đều dựa vào *NLP*. Công nghệ này giúp cải thiện chất lượng tìm kiếm, mang lại trải nghiệm tìm kiếm hiệu quả và chính xác hơn, đồng thời giúp người dùng tìm thấy thông tin nhanh chóng và dễ dàng.

1.5.3 Tóm tắt và trích xuất thông tin (*text summarisation & information extraction*)

NLP có thể được sử dụng để tự động tóm tắt văn bản dài thành các đoạn ngắn hơn, giữ nguyên ý chính. Điều này đặc biệt hữu ích khi xử lý các tập dữ liệu lớn hoặc báo cáo dài. Các hệ thống tóm tắt văn bản sử dụng các kỹ thuật học máy để lựa chọn những phần quan trọng nhất của văn bản và tạo ra bản tóm tắt ngắn gọn nhưng vẫn giữ nguyên ý nghĩa.

Ngoài ra, *NLP* cũng được sử dụng trong **trích xuất thông tin (*information extraction*)**, như trích xuất tên người, địa điểm, ngày tháng, sự kiện, v.v., từ các tài liệu không có cấu trúc. Điều này giúp tự động hóa quá trình phân tích văn bản và trích xuất dữ liệu quan trọng từ các nguồn tài liệu lớn.

1.5.4 Phân tích và phân loại văn bản (*text analysis & classification*)

NLP cho phép phân tích cảm xúc (*sentiment analysis*), phân loại văn bản (*text classification*) như tin tức, email, đánh giá sản phẩm, phát hiện thư rác (*spam detection*), và nhận dạng thực thể có tên (*Named Entity Recognition – NER*). Điều này đặc biệt hữu ích trong các lĩnh vực như marketing, dịch vụ khách hàng, và các ứng dụng liên quan đến phân tích dữ liệu.

NLP cũng có ứng dụng trong y tế, như trích xuất thông tin lâm sàng từ hồ sơ bệnh án, giúp cải thiện quá trình chăm sóc sức khỏe và hỗ trợ các chuyên gia y tế trong việc đưa ra quyết định chính xác.

CHƯƠNG II. MÔ TẢ BÀI TOÁN

2.1 Vì sao Dịch máy (*machine translation*) quan trọng?

Trong bối cảnh giao tiếp và hợp tác toàn cầu ngày càng mở rộng, nhu cầu sử dụng ngôn ngữ trong giao tiếp hằng ngày, học tập, làm việc, du lịch, họp trực tuyến, viết email hoặc báo cáo song ngữ ngày càng tăng cao. Tuy nhiên, rào cản ngôn ngữ vẫn là thách thức lớn, đặc biệt với những người không thông thạo ngoại ngữ. Dịch máy (*Machine Translation – MT*) là công nghệ cho phép chuyển đổi tự động văn bản từ ngôn ngữ này sang ngôn ngữ khác, góp phần xóa bỏ rào cản ngôn ngữ trong nhiều tình huống thực tế.

Dịch máy không chỉ giúp vượt qua các khó khăn ngôn ngữ trong giao tiếp hằng ngày, mà còn có thể giúp kết nối các nền văn hóa khác nhau, từ đó thúc đẩy hợp tác quốc tế và tạo ra các cơ hội mới trong công việc, học tập và giao lưu văn hóa. Các mô hình hiện đại như *Transformer*, *MarianMT*, và *BERT* đã giúp cải thiện đáng kể chất lượng dịch, giúp quá trình dịch trở nên mượt mà và tự nhiên hơn.

Một trong những lợi ích quan trọng nhất của dịch máy là tiết kiệm thời gian và chi phí so với phương pháp dịch thủ công. Người dùng có thể nhanh chóng dịch các tài liệu kỹ thuật, văn bản học thuật, thông tin sản phẩm, hoặc nội dung hội thoại thường ngày mà không cần phải thuê phiên dịch viên hay mất thời gian tra cứu. Điều này đặc biệt quan trọng trong các lĩnh vực như kinh doanh, y tế, giáo dục và công nghệ, nơi mà việc truy cập nhanh chóng vào thông tin từ các ngôn ngữ khác nhau là cần thiết.

Ngoài ra, dịch máy còn là nền tảng quan trọng cho nhiều ứng dụng trí tuệ nhân tạo (*artificial intelligence*) hiện đại như chatbot, trợ lý ảo, hệ thống hỏi đáp thông minh, tạo ra trải nghiệm tương tác linh hoạt và thuận tiện hơn với công nghệ thông minh trong đời sống thường ngày. Các ứng dụng này không chỉ giúp cải thiện khả năng giao tiếp giữa các cá nhân và tổ chức mà còn giúp giảm thiểu khối lượng công việc cho các nhân viên hỗ trợ và cung cấp phản hồi nhanh chóng và chính xác.

Chẳng hạn, trong các nền tảng hỗ trợ khách hàng, dịch máy giúp trả lời câu hỏi của khách hàng từ nhiều ngôn ngữ khác nhau một cách nhanh chóng, cải thiện trải nghiệm người dùng và gia tăng sự hài lòng của khách hàng. Các hệ thống trợ lý ảo (*virtual assistants*) như Siri, Google Assistant, và Alexa cũng sử dụng dịch máy để giao tiếp với người dùng từ các nền tảng ngôn ngữ khác nhau, từ đó mang lại sự thuận tiện và dễ dàng trong việc tương tác với các thiết bị thông minh.

2.2 Ứng dụng cụ thể của mô hình dịch máy Anh - Việt

Việc lựa chọn xây dựng hệ thống dịch máy giữa tiếng Anh và tiếng Việt là hoàn toàn phù hợp với nhu cầu thực tế hiện nay. Tiếng Anh là ngôn ngữ phổ biến nhất thế giới, được sử dụng trong hầu hết các tài liệu học thuật, kỹ thuật, hợp tác quốc tế và truyền thông toàn cầu. Tiếng Việt là ngôn ngữ chính thức được sử dụng tại Việt Nam, với nhu cầu tiếp cận các tài liệu tiếng Anh trong học tập, nghiên cứu và đời sống ngày càng trở nên cấp thiết.

Một hệ thống dịch Anh - Việt chất lượng sẽ có những ứng dụng quan trọng, bao gồm:

1. Hỗ trợ dịch các tài liệu học tập, kỹ thuật, hợp đồng, hướng dẫn sử dụng từ tiếng Anh sang tiếng Việt hoặc ngược lại. Điều này giúp người Việt tiếp cận tri thức quốc tế và ngược lại, đồng thời hỗ trợ việc học tập và nghiên cứu trong các lĩnh vực chuyên môn, từ khoa học kỹ thuật đến các nghiên cứu xã hội và nhân văn.
2. Phục vụ cho nhu cầu hội họp trực tuyến, báo cáo song ngữ, trao đổi thông tin trong môi trường học thuật và doanh nghiệp quốc tế. Dịch máy Anh - Việt sẽ giúp rút ngắn khoảng cách ngôn ngữ, tạo điều kiện thuận lợi cho việc trao đổi thông tin nhanh chóng và hiệu quả, đặc biệt trong các cuộc họp, hội thảo và các sự kiện trực tuyến mang tính quốc tế.
3. Tăng cường trải nghiệm người dùng trong các nền tảng dịch vụ AI, như trợ lý ảo (*virtual assistants*) và *chatbots* có thể hiểu và phản hồi bằng cả tiếng Anh và tiếng Việt. Việc tích hợp dịch máy vào các hệ thống trợ lý ảo và *chatbots* sẽ giúp tạo ra trải nghiệm người dùng phong phú, thuận tiện hơn trong việc giao tiếp và tương tác với các công nghệ hiện đại trong đời sống thường ngày.
4. Góp phần phát triển công cụ xử lý ngôn ngữ tiếng Việt, một ngôn ngữ còn ít được nghiên cứu hơn so với các ngôn ngữ phổ biến khác như tiếng Anh hay tiếng Trung. Việc xây dựng các công cụ dịch máy chất lượng cao cho tiếng Việt sẽ thúc đẩy nghiên cứu và phát triển các ứng dụng trí tuệ nhân tạo (AI) cho ngôn ngữ Việt, từ đó hỗ trợ các công nghệ học máy và xử lý ngôn ngữ tự nhiên (*Natural Language Processing – NLP*) trong việc phát triển phần mềm, các dịch vụ trực tuyến và các ứng dụng khác.

Từ những ứng dụng thiết thực trên, có thể thấy rằng bài toán dịch máy Anh - Việt không chỉ mang tính học thuật mà còn giải quyết nhu cầu thực tiễn cấp thiết, đồng thời góp phần thúc đẩy ứng dụng công nghệ AI vào ngôn ngữ Việt một cách mạnh mẽ và bền vững hơn. Hệ thống dịch máy Anh - Việt chất lượng sẽ đóng vai trò quan trọng trong việc thu hẹp khoảng cách ngôn ngữ, nâng cao hiệu quả giao tiếp và hỗ trợ sự phát triển của nền kinh tế số và công nghệ thông tin ở Việt Nam.

2.3 Mô tả bài toán

Bài toán đặt ra là xây dựng một hệ thống dịch máy (*Machine Translation – MT*) có khả năng chuyển đổi chính xác và tự nhiên các câu hoặc đoạn văn từ tiếng Anh sang tiếng Việt. Dữ liệu đầu vào có thể là các câu mang tính đa dạng về cấu trúc ngữ pháp, giàu ngữ nghĩa, chứa từ vựng chuyên ngành hoặc các biểu đạt ngôn ngữ không phổ biến, đòi hỏi hệ thống phải có khả năng hiểu ngữ cảnh và xử lý linh hoạt.

1. *Đầu vào (Input)*: Một câu hoặc đoạn văn bản tiếng Anh có thể chứa các yếu tố phức tạp như cấu trúc ngữ pháp đặc biệt, từ đa nghĩa, thành ngữ, hoặc các biểu thức ẩn dụ. Việc xử lý các yếu tố này đòi hỏi hệ thống dịch máy phải có khả năng nhận diện và phân tích chính xác từng phần của câu, đồng thời hiểu được ngữ cảnh rộng hơn để có thể chuyển ngữ chính xác và tự nhiên.
2. *Đầu ra (Output)*: Một câu hoặc đoạn văn bản tương đương bằng tiếng Việt, đảm bảo chính xác về nội dung, đúng ngữ pháp, và diễn đạt tự nhiên, dễ hiểu đối với người bản ngữ tiếng Việt. Việc dịch không chỉ cần phải giữ đúng ý nghĩa của câu mà còn phải đảm bảo rằng bản dịch mượt mà và tự nhiên trong tiếng Việt, với sự phù hợp về ngữ pháp và cách diễn đạt. Điều này là một thách thức lớn trong các hệ thống dịch máy, đặc biệt khi ngữ pháp và cấu trúc câu giữa tiếng Anh và tiếng Việt có sự khác biệt rõ rệt.
3. *Mục tiêu*: Phát triển một mô hình dịch tự động có khả năng chuyển ngữ chính xác và mượt mà giữa tiếng Anh và tiếng Việt. Bản dịch cần không chỉ truyền tải đúng nội dung mà còn giữ được sắc thái và cách diễn đạt phù hợp với văn phong tiếng Việt. Mục tiêu này có thể đạt được thông qua việc sử dụng các mô hình học sâu (*deep learning models*) như *Transformer* và các kỹ thuật như *neural machine translation* (NMT), giúp cải thiện chất lượng dịch, đặc biệt trong các ngữ cảnh phức tạp.

Mô hình dịch máy này cần phải được huấn luyện trên các tập dữ liệu song ngữ lớn, bao gồm các tài liệu học thuật, văn bản kỹ thuật, văn bản văn hóa, và các dạng ngôn ngữ không chính thức, để có thể hiểu và dịch các kiểu văn bản đa dạng. Sự phát triển của các mô hình như *Transformer* đã giúp nâng cao hiệu quả và độ chính xác trong việc dịch giữa các ngôn ngữ có cấu trúc ngữ pháp và từ vựng khác biệt như tiếng Anh và tiếng Việt.

2.4 Các bước triển khai bài toán

Để hiện thực hóa hệ thống dịch máy Anh–Việt, bài toán được triển khai theo các bước chính sau:

1. *Tiền xử lý dữ liệu (Data Preprocessing)*: Đây là bước đầu tiên và rất quan trọng trong quá trình xây dựng hệ thống dịch máy. Tiền xử lý dữ liệu bao gồm các công đoạn làm sạch (*cleaning*), chuẩn hóa (*normalization*) và xử lý dữ liệu song ngữ (Anh - Việt). Các công việc chính trong bước này bao gồm loại bỏ nhiễu (*noise removal*), chuẩn hóa dấu câu (*punctuation normalization*), tách từ (*tokenization* – đặc biệt là đối với tiếng Việt, nơi không có khoảng trắng phân tách từ), và cân bằng tập dữ liệu (*data balancing*). Quá trình tiền xử lý này giúp tạo ra dữ liệu sạch và đồng nhất, sẵn sàng cho các bước tiếp theo trong việc huấn luyện mô hình dịch máy.
2. *Xây dựng mô hình (Model Building)*: Sau khi chuẩn bị xong dữ liệu, bước tiếp theo là lựa chọn và thiết kế mô hình học sâu (*deep learning model*) phù hợp với bài toán dịch ngôn ngữ. Các mô hình như *Transformer*, *seq2seq* với *attention*, hoặc các biến thể tiên tiến như *MarianMT* và *mBART* có thể được sử dụng để xây dựng mô hình dịch máy. Mô hình *Transformer* đã chứng minh hiệu quả vượt trội trong các bài toán dịch ngôn ngữ nhờ vào cơ chế *self-attention* giúp nắm bắt mối quan hệ giữa các từ trong câu, ngay cả khi khoảng cách giữa chúng là xa. Các mô hình như *MarianMT* và *mBART* đã cải thiện khả năng dịch giữa nhiều ngôn ngữ và giúp việc dịch máy trở nên linh hoạt hơn.
3. *Huấn luyện mô hình (Model Training)*: Trong bước này, dữ liệu đã được xử lý sẽ được sử dụng để huấn luyện mô hình. Mô hình học sâu sẽ học các biểu diễn ngữ nghĩa của các câu và các mối quan hệ giữa các từ trong ngữ cảnh của ngôn ngữ nguồn và ngôn ngữ đích. Đồng thời, việc tối ưu hóa các siêu tham số (*hyperparameter tuning*) nhằm đạt được hiệu suất tốt nhất trên tập kiểm tra (*test set*) là rất quan trọng. Các kỹ thuật như *gradient descent*, *Adam optimizer*, hoặc các phương pháp tối ưu hóa khác có thể được áp dụng để điều chỉnh các trọng số của mô hình.
4. *Đánh giá và hiệu chỉnh (Evaluation and Fine-tuning)*: Sau khi huấn luyện mô hình, bước tiếp theo là đánh giá chất lượng bản dịch. Các chỉ số đánh giá phổ biến trong lĩnh vực dịch máy như *BLEU* (Bilingual Evaluation Understudy), *METEOR*, và các chỉ số khác sẽ được sử dụng để đo lường độ chính xác và chất lượng của bản dịch. Ngoài ra, cần có sự kiểm tra thủ công đối với một số trường hợp đặc biệt, để đảm bảo rằng bản dịch không chỉ chính xác về mặt ngữ nghĩa mà còn tự nhiên và dễ hiểu trong ngữ cảnh sử dụng. Từ đó, mô hình có thể được điều chỉnh và cải thiện để đạt được chất lượng dịch tối ưu.

Mỗi bước trong quy trình này đóng một vai trò quan trọng trong việc xây dựng một hệ thống dịch máy chất lượng. Đặc biệt, việc đánh giá và điều chỉnh mô hình là một quá trình liên tục, nhằm cải thiện khả năng dịch qua các vòng huấn luyện và kiểm tra.

2.5 Phương thức đánh giá chất lượng bản dịch

Để đánh giá hiệu quả của mô hình dịch máy Anh - Việt, cần áp dụng nhiều phương pháp đánh giá định lượng (*quantitative evaluation*) và định tính (*qualitative evaluation*) nhằm đảm bảo kết quả dịch không chỉ chính xác về nội dung mà còn mượt mà về ngữ pháp và ngữ nghĩa.

2.5.1 Chỉ số BLEU (*bilingual evaluation understudy*)

BLEU là một trong những thước đo chuẩn đầu tiên và phổ biến nhất trong lĩnh vực đánh giá dịch máy. Chỉ số này đo mức độ tương đồng giữa bản dịch do mô hình sinh ra và bản dịch tham chiếu (do con người dịch) dựa trên tần suất xuất hiện của các cụm từ liên tiếp (*n-gram*). Cụ thể, *BLEU* tính toán sự trùng khớp giữa các *n-gram* trong bản dịch tự động và bản dịch tham chiếu, từ đó đưa ra một chỉ số cho biết mức độ tương đồng giữa hai bản dịch này.

Chỉ số *BLEU* thường được tính cho các *n-gram* có độ dài từ 1 đến 4, với 1-gram đại diện cho các từ đơn, 2-gram cho các cặp từ, và tương tự cho 3-gram và 4-gram. Bằng cách này, *BLEU* có thể đánh giá được mức độ trùng khớp giữa các phần tử nhỏ trong câu. Tuy nhiên, *BLEU* cũng có một số hạn chế. Mặc dù *BLEU* rất hiệu quả trong việc đo lường sự trùng khớp bề mặt giữa các *n-gram*, nhưng nó không đánh giá được ngữ nghĩa sâu sắc hơn hoặc sự chính xác của bản dịch đối với các yếu tố ngữ cảnh và cấu trúc ngữ pháp.

Một trong những yếu tố quan trọng trong tính toán *BLEU* là việc sử dụng một *penalty* cho độ dài câu. Điều này giúp giảm thiểu khả năng mô hình chỉ dịch các đoạn văn bản ngắn và lặp lại nhiều lần mà không quan tâm đến sự đầy đủ của bản dịch. Chỉ số *BLEU* càng cao thì bản dịch càng gần với bản dịch tham chiếu, cho thấy mô hình hoạt động hiệu quả hơn trong việc sao chép các *n-gram* từ bản dịch tham chiếu.

Tuy nhiên, *BLEU* chủ yếu đánh giá sự trùng khớp bề mặt và có thể bỏ sót các yếu tố ngữ nghĩa sâu hơn. Ví dụ, hai câu dịch có thể có chỉ số *BLEU* tương đương nhưng lại khác nhau về mức độ chính xác ngữ nghĩa hoặc sự tự nhiên trong ngữ cảnh. Vì lý do này, *BLEU* không phải là chỉ số hoàn hảo để đánh giá tất cả các khía cạnh của một bản dịch,

đặc biệt khi xét đến các trường hợp dịch các thành ngữ, từ đồng nghĩa, hoặc cấu trúc câu phức tạp.

Do đó, ngoài *BLEU*, các chỉ số khác như *METEOR*, *TER* (Translation Edit Rate), và đánh giá thủ công cũng cần được kết hợp để có cái nhìn toàn diện về chất lượng dịch máy.

2.5.2 Chỉ số *METEOR*

METEOR được thiết kế nhằm khắc phục một số hạn chế của *BLEU*. Trong khi *BLEU* chủ yếu đánh giá sự trùng khớp chính xác giữa các từ và cụm từ (n-grams) trong bản dịch tự động và bản dịch tham chiếu, *METEOR* cung cấp một cách tiếp cận toàn diện hơn. Chỉ số này không chỉ xét đến sự trùng khớp chính xác giữa từ và cụm từ, mà còn tính đến sự thay thế từ đồng nghĩa (*synonymy*), dạng gốc của từ (*stemming*), và trật tự từ trong câu (*word order*).

Việc tính đến các yếu tố như *stemming* và *synonymy* giúp *METEOR* đánh giá tốt hơn những trường hợp mà cách diễn đạt giữa bản dịch và bản tham chiếu khác nhau nhưng ý nghĩa lại tương đương. Ví dụ, nếu bản dịch tự động sử dụng từ đồng nghĩa hoặc thay đổi cấu trúc câu nhưng vẫn giữ nguyên ý nghĩa, *METEOR* sẽ có khả năng đánh giá bản dịch cao hơn so với *BLEU*, vốn chỉ tập trung vào việc so sánh các n-gram chính xác.

METEOR tính toán điểm số dựa trên ba yếu tố chính:

1. Sự trùng khớp giữa các từ (*exact match*): Đây là phần đánh giá sự khớp chính xác giữa các từ trong bản dịch tự động và bản tham chiếu.
2. Từ đồng nghĩa (*synonymy*): Các từ đồng nghĩa sẽ được xem xét để tính vào điểm số, giúp giảm thiểu sự trừ điểm cho các từ thay thế có nghĩa tương đương.
3. Dạng gốc của từ (*stemming*): Việc tính đến các dạng gốc của từ giúp *METEOR* có thể đánh giá cao hơn các bản dịch sử dụng từ có dạng khác nhau nhưng cùng một nghĩa (ví dụ: "run" và "running").

Ngoài ra, *METEOR* còn tính đến trật tự từ trong câu, điều này giúp đánh giá cao hơn các bản dịch có cấu trúc câu tự nhiên và chính xác. Điểm số cuối cùng của *METEOR* được tính dựa trên một công thức kết hợp giữa các yếu tố này, với một phép tính phạt cho độ dài câu không khớp, nhằm khuyến khích các bản dịch có độ dài tương đương với bản dịch tham chiếu.

Nhờ vào việc đánh giá nhiều yếu tố ngữ nghĩa hơn so với *BLEU*, *METEOR* thường được coi là chỉ số tốt hơn trong việc đánh giá các bản dịch có sự thay đổi cấu trúc câu hoặc sử dụng từ đồng nghĩa. Tuy nhiên, *METEOR* cũng có một số hạn chế, chẳng hạn như việc

không hoàn toàn phản ánh được sự chính xác ngữ nghĩa trong các trường hợp phức tạp hoặc khi bản dịch có sự khác biệt sâu về ngữ pháp.

2.5.3 Chỉ số *TER* (*translation edit rate*)

TER (*Translation Edit Rate*) là một chỉ số được sử dụng để đánh giá chất lượng dịch máy bằng cách đo số lượng chỉnh sửa cần thiết để biến bản dịch của mô hình thành bản dịch tham chiếu. Các thao tác chỉnh sửa bao gồm thêm (*insertion*), xóa (*deletion*), thay thế (*substitution*), hoặc hoán đổi vị trí từ ngữ (*word reordering*). Đây là một thước đo trực quan giúp đánh giá mức độ khác biệt giữa hai câu dịch ở cấp độ thao tác chỉnh sửa.

Cách tính *TER* rất đơn giản: nó tính số lượng thao tác chỉnh sửa cần thiết để biến bản dịch tự động thành bản dịch tham chiếu và chia cho tổng số từ trong bản dịch tham chiếu. Số lượng thao tác càng ít, chỉ số *TER* càng thấp, đồng nghĩa với việc bản dịch của mô hình càng gần với bản dịch chuẩn và phản ánh hiệu quả dịch tốt.

Một chỉ số *TER* thấp cho thấy mô hình dịch máy đã thực hiện được một bản dịch khá chính xác, với ít lỗi cần sửa. Ngược lại, một *TER* cao cho thấy mô hình cần nhiều thao tác chỉnh sửa, điều này phản ánh sự khác biệt lớn giữa bản dịch tự động và bản dịch tham chiếu, đồng thời chỉ ra rằng mô hình vẫn chưa đạt được độ chính xác cao trong việc tái tạo các cấu trúc ngữ pháp và ngữ nghĩa.

Mặc dù *TER* có thể là một chỉ số trực quan và dễ hiểu, nhưng nó có một số hạn chế. Chẳng hạn, *TER* không phân biệt giữa các loại chỉnh sửa, do đó một thao tác nhỏ như thay thế một từ đồng nghĩa có thể có cùng trọng số với việc thay đổi hoàn toàn cấu trúc câu. Ngoài ra, *TER* cũng không đánh giá được mức độ tự nhiên hoặc sự mượt mà của câu dịch, do đó cần kết hợp với các chỉ số khác như *BLEU* hoặc *METEOR* để có một cái nhìn toàn diện hơn về chất lượng dịch máy.

2.5.4 Đánh giá thủ công (*human evaluation*)

Quan trọng trong việc xác định độ tự nhiên (*fluency*), sự mạch lạc (*coherence*) và tính chính xác ngữ nghĩa (*semantic adequacy*) của bản dịch. Trong khi các chỉ số tự động như *BLEU*, *METEOR* và *TER* có thể đánh giá độ chính xác của bản dịch ở mức độ n-gram, chúng không thể hoàn toàn đo lường các yếu tố ngữ nghĩa sâu sắc và sự tự nhiên của văn bản dịch.

Quá trình đánh giá thủ công thường được thực hiện bởi các chuyên gia ngôn ngữ hoặc người bản ngữ, những người có khả năng đánh giá mức độ tự nhiên và sự phù hợp của bản dịch trong ngữ cảnh cụ thể. Đánh giá thủ công giúp nhận diện các vấn đề mà các chỉ

số tự động có thể bỏ qua, chẳng hạn như sự mượt mà trong câu, các cấu trúc ngữ pháp không tự nhiên hoặc sự chuyển nghĩa không chính xác giữa các từ và cụm từ.

Các tiêu chí thường được sử dụng trong đánh giá thủ công bao gồm:

1. Độ trôi chảy (*fluency*): Đánh giá xem câu dịch có dễ hiểu, tự nhiên và phù hợp với ngữ pháp của ngôn ngữ đích hay không. Một bản dịch có độ trôi chảy cao sẽ được người bản ngữ dễ dàng hiểu và cảm nhận là tự nhiên.
2. Tính chính xác (*adequacy*): Đánh giá mức độ mà bản dịch có thể truyền tải chính xác ý nghĩa của văn bản nguồn. Điều này không chỉ liên quan đến việc dịch đúng từ vựng, mà còn về việc duy trì các khái niệm và ý tưởng quan trọng từ bản gốc.
3. Khả năng truyền đạt đúng ý nghĩa: Đánh giá liệu bản dịch có truyền tải đầy đủ và chính xác thông tin từ văn bản gốc sang ngôn ngữ đích, bao gồm cả các yếu tố ngữ nghĩa và ngữ cảnh.

Mặc dù tốn thời gian và nguồn lực, đánh giá thủ công mang lại cái nhìn sâu sắc và toàn diện hơn so với các chỉ số tự động, đặc biệt khi đánh giá các yếu tố ngữ nghĩa mà các phương pháp tự động khó có thể đánh giá chính xác.

Việc kết hợp đồng thời các chỉ số đánh giá tự động với đánh giá thủ công sẽ giúp đảm bảo quá trình kiểm tra chất lượng bản dịch được thực hiện một cách khách quan, toàn diện và đáng tin cậy. Đây là cơ sở quan trọng để cải thiện và tối ưu hóa mô hình dịch máy trong các giai đoạn tiếp theo.

2.6 So sánh các phương pháp dịch máy

2.6.1 SMT - *statistical machine translation*

Nguyên lý hoạt động:

SMT là phương pháp dịch máy dựa trên xác suất thống kê. Ý tưởng cốt lõi là:

“Cho một câu tiếng Anh e , hệ thống tìm câu tiếng Việt f sao cho xác suất $F(f|e)$ là lớn nhất.”

Theo định lý Bayes, ta tối đa hóa:

$$\arg \max_f P(f|e) = \arg \max_f P(e|f) \times P(f)$$

Trong đó:

1. $P(f)$ là mô hình ngôn ngữ tiếng Việt (*Language Model*), đánh giá độ tự nhiên của câu đích.
2. $P(f|e)$ là mô hình dịch (*Translation Model*), đo lường xác suất dịch từ câu gốc sang câu đích.

Việc huấn luyện các mô hình xác suất này dựa trên *corpus* song ngữ đã được cân chỉnh câu.

Ưu điểm:

1. Dễ triển khai nếu có đủ dữ liệu song ngữ.
2. Tách biệt giữa mô hình ngôn ngữ và mô hình dịch, dễ điều chỉnh độc lập.
3. Từng là tiêu chuẩn công nghiệp trước thời kỳ học sâu.

Nhược điểm:

1. Phụ thuộc mạnh vào việc cân chỉnh ngữ chính xác.
2. Gặp khó khăn với ngữ cảnh dài, ngôn ngữ linh hoạt (như tiếng Việt).
3. Không học được biểu diễn từ ngữ nghĩa, dẫn đến bản dịch máy mẫn, rời rạc.
4. Mỗi cụm từ được dịch độc lập $\rightarrow$ thiếu trôi chảy trong câu.

Kết luận:

SMT tạo nền móng vững chắc cho các hệ thống dịch máy, nhưng đã dần lỗi thời do giới hạn về ngữ nghĩa và khả năng tính toán quá hóa. Tuy nhiên, các cấu trúc vẫn cần chỉnh, tách mô hình ngôn ngữ vẫn ảnh hưởng đến các mô hình hiện đại.

2.6.2 Seq2seq + LTSM - *Sequence-to-sequence with LTSM*

Nguyên lý hoạt động:

Mô hình *Seq2Seq* là một trong những đột phá đầu tiên của *deep learning* trong dịch máy. Cấu trúc chính của mô hình này bao gồm hai phần:

1. *Encoder*: Sử dụng *RNN* (Recurrent Neural Network) hoặc *LSTM* (Long Short-Term Memory) để đọc từng từ trong câu tiếng Anh, và mã hóa toàn bộ câu thành một vector ngữ cảnh duy nhất. Mô hình này giúp máy tính có thể hiểu được thông tin của toàn bộ câu bằng cách lưu trữ thông tin từ từng từ và kết nối chúng lại với nhau.
2. *Decoder*: Nhận vector ngữ cảnh từ *Encoder*, rồi sinh từng từ trong câu tiếng Việt theo thứ tự từ trái sang phải. Quá trình này giúp tạo ra bản dịch từ ngữ cảnh tổng thể của câu, thay vì dịch từng từ riêng lẻ.

Công thức tổng quát:

$$h_t = LSTM(x_t, h_{t-1})$$

Trong đó, h_t là trạng thái ẩn tại thời điểm t , x_t là đầu vào tại thời điểm t , và h_{t-1} là trạng thái ẩn của thời điểm trước đó.

Ưu điểm:

1. Có khả năng học được cấu trúc ngôn ngữ phức tạp thông qua các trạng thái ẩn (*hidden states*), giúp mô hình dịch máy có thể hiểu và tái tạo cấu trúc ngữ pháp trong ngữ cảnh của câu.
2. Áp dụng được với mọi cặp ngôn ngữ, không cần luật ngữ pháp cố định. Điều này có nghĩa là mô hình có thể dịch giữa bất kỳ hai ngôn ngữ nào miễn là có đủ dữ liệu huấn luyện.
3. Học trực tiếp từ dữ liệu song ngữ mà không cần luật thủ công, giúp giảm thiểu công sức trong việc xây dựng các quy tắc ngữ pháp truyền thống.

Nhược điểm:

1. Mọi thông tin được nén vào một vector cố định, điều này có thể gây mất thông tin khi câu dài hoặc phức tạp, vì mô hình phải mã hóa toàn bộ câu vào một vector duy nhất.
2. Mô hình dễ quên từ đầu câu khi dịch các câu có ngữ cảnh xa. Do *Seq2Seq* chỉ dựa vào một vector duy nhất để mô tả thông tin của câu, nó có thể gặp khó khăn trong việc giữ lại ngữ cảnh khi khoảng cách giữa các từ liên quan quá xa.
3. Tốc độ huấn luyện chậm do *RNN* xử lý tuần tự, điều này làm cho quá trình huấn luyện trở nên chậm hơn so với các mô hình song song như *Transformer*.

Kết luận:

Seq2Seq là một cột mốc quan trọng, mở ra thời đại mới cho dịch máy bằng mạng nơ-ron. Tuy nhiên, mô hình này chỉ đạt hiệu quả cao khi kết hợp với cơ chế *Attention*. Cơ chế *Attention* cho phép mô hình tập trung vào các phần quan trọng của câu nguồn khi dịch, giúp cải thiện khả năng dịch trong các ngữ cảnh phức tạp và giữ được ngữ nghĩa chính xác hơn.

2.6.3 Attention mechanism

Nguyên lý hoạt động:

Attention là cơ chế cho phép mô hình chọn lọc thông tin từ đầu vào khi sinh từng từ trong đầu ra, thay vì dựa hoàn toàn vào một vector duy nhất như trong *Seq2Seq* truyền thống. Cơ chế này giúp mô hình có thể tập trung vào những phần quan trọng của câu đầu vào khi tạo ra bản dịch, thay vì phải sử dụng một biểu diễn cố định cho toàn bộ câu.

1. Tại mỗi bước sinh từ, mô hình tính toán một vector trọng số (α_t) thể hiện mức độ "chú ý" đến từng từ trong câu đầu vào. Giá trị của α_t giúp mô hình xác định từ nào trong câu nguồn có tầm quan trọng nhất để sử dụng cho việc sinh từ tiếp theo trong câu đích.
2. Output là tổng có trọng số các vector trạng thái ẩn của *encoder*:

$$c_t = \sum_{i=1}^n \alpha_{t,i} \times h_i$$

Trong đó, c_t là vector ngữ cảnh tại bước t , và h_i là các trạng thái ẩn của *encoder* từ các từ trong câu đầu vào. Các trọng số α_t quyết định mức độ ảnh hưởng của từng trạng thái ẩn h_i đối với từ được sinh ra ở bước t .

Ưu điểm:

1. Giải quyết vấn đề mất thông tin khi câu dài: Thay vì mã hóa toàn bộ câu vào một vector duy nhất, *Attention* cho phép mô hình tập trung vào các phần quan trọng của câu, giúp giảm thiểu tình trạng mất thông tin trong các câu dài hoặc phức tạp.
2. Mô hình tập trung chính xác hơn vào từ/cụm từ quan trọng: Mô hình có thể tự động học cách chú ý đến các từ quan trọng trong câu, thay vì phải dựa vào thông tin từ toàn bộ câu, giúp bản dịch trở nên chính xác hơn.
3. Tăng đáng kể chất lượng bản dịch, đặc biệt với các ngôn ngữ có cấu trúc khác nhau: *Attention* đặc biệt hữu ích khi dịch các ngôn ngữ có cấu trúc ngữ pháp khác biệt, như dịch giữa tiếng Anh và tiếng Việt. Nó giúp mô hình duy trì sự chính xác và tự nhiên trong bản dịch.

Nhược điểm:

1. Tăng độ phức tạp tính toán và thời gian huấn luyện: Cơ chế *Attention* yêu cầu tính toán trọng số cho từng từ trong câu nguồn, điều này làm tăng độ phức tạp tính toán và có thể làm chậm quá trình huấn luyện.
2. Vẫn phụ thuộc vào *RNN* $\rightarrow$ xử lý tuần tự, không song song hóa tốt: Mặc dù *Attention* giúp mô hình cải thiện khả năng dịch, nhưng nó vẫn phụ thuộc vào *RNN*, vốn có tính chất xử lý tuần tự và không thể tận dụng tốt khả năng song song hóa.

Kết luận:

Attention là tiền đề cho các kiến trúc dịch hiện đại (như *Transformer*). Mô hình này vẫn là một trong những tiêu chuẩn mạnh nếu kết hợp với các mô hình như *BERT* hoặc *Seq2Seq* nâng cao. Nó đã mở ra hướng đi mới cho dịch máy, đặc biệt trong việc cải thiện chất lượng bản dịch và khả năng xử lý ngữ nghĩa trong ngữ cảnh phức tạp.

2.6.4 Transformer

Nguyên lý hoạt động:

Transformer là kiến trúc phi *RNN* đầu tiên trong *NLP* (Natural Language Processing), hoàn toàn dựa trên *self-attention* để mô hình hóa mối quan hệ giữa các từ. Thay vì sử dụng các *RNN* hoặc *LSTM* như các mô hình trước, *Transformer* sử dụng một cơ chế hoàn toàn mới, giúp tăng cường khả năng xử lý các câu dài và phức tạp.

1. *Self-attention* cho phép mô hình nhìn toàn bộ câu cùng lúc, tạo trọng số chú ý giữa tất cả các cặp từ. Cơ chế này cho phép mô hình hiểu được các mối quan hệ giữa các từ trong câu mà không phụ thuộc vào thứ tự của chúng, giúp giảm thiểu vấn đề thông tin mất mát trong các câu dài.
2. Mỗi vị trí trong câu được mã hóa bằng cách nhìn toàn bộ ngữ cảnh của câu, không chỉ thông qua các từ xung quanh mà còn dựa vào các mối quan hệ giữa các từ ở các vị trí khác nhau trong câu.
3. Mô hình gồm encoder và decoder chồng nhiều lớp, mỗi lớp bao gồm cơ chế *multi-head attention*, *position encoding*, và *residual connection*.
 - a. *Multi-head attention* giúp mô hình có khả năng học được các mối quan hệ phức tạp giữa các từ bằng cách chia nhỏ trọng số chú ý thành nhiều "đầu" khác nhau, mỗi đầu tập trung vào các phần khác nhau của câu.
 - b. *Position encoding* cung cấp thông tin về vị trí của các từ trong câu, vì *Transformer* không xử lý tuần tự như *RNN*, điều này giúp mô hình giữ được thông tin về thứ tự các từ trong câu.

- c. *Residual connection* giúp cải thiện khả năng huấn luyện của mô hình bằng cách cho phép các tín hiệu được truyền trực tiếp qua các lớp mà không bị suy giảm.

Ưu điểm:

1. Song song hóa quá trình huấn luyện cực tốt: Cơ chế *self-attention* cho phép mô hình xử lý tất cả các từ trong câu cùng một lúc, giúp tăng tốc quá trình huấn luyện đáng kể so với các mô hình tuần tự như *RNN*.
2. Giữ được ngữ cảnh dài và mối quan hệ xa giữa các từ: *Transformer* có khả năng duy trì mối quan hệ giữa các từ trong câu, ngay cả khi chúng cách xa nhau, điều này đặc biệt quan trọng khi dịch các câu phức tạp hoặc dài.
3. Chất lượng dịch vượt trội: *Transformer* hiện là kiến trúc mạnh nhất trong dịch máy, cho phép tạo ra bản dịch chính xác và tự nhiên hơn các mô hình trước đó.
4. Là nền tảng của các mô hình lớn như *BERT*, *GPT*, *MarianMT*: Các mô hình này đều dựa trên *Transformer* và đã đạt được những thành tựu vượt bậc trong nhiều bài toán xử lý ngôn ngữ tự nhiên.

Nhược điểm:

1. Yêu cầu tài nguyên tính toán cao: *Transformer* yêu cầu *GPU* mạnh và bộ nhớ *RAM* lớn để có thể huấn luyện hiệu quả, điều này có thể gây khó khăn trong việc triển khai các mô hình lớn trên các phần cứng không đủ mạnh.
2. Hiệu suất giảm nếu dữ liệu huấn luyện không đủ lớn: Mô hình *Transformer* yêu cầu một lượng lớn dữ liệu huấn luyện để hoạt động hiệu quả. Nếu dữ liệu không đủ lớn, mô hình có thể không đạt được hiệu suất tối ưu.
3. Cần kỹ thuật điều chỉnh siêu tham số phù hợp: Để tối ưu hóa hiệu suất của mô hình *Transformer*, việc điều chỉnh các siêu tham số như số lượng lớp, kích thước của *hidden layers*, và tốc độ học là rất quan trọng.

CHƯƠNG III. THU THẬP DỮ LIỆU

3.1. Nguồn dữ liệu

Bộ dữ liệu phục vụ cho mô hình được thu thập từ nền tảng Kaggle tại địa chỉ:


<https://www.kaggle.com/datasets/tuannguyenvananh/iwslt15-englishvietnamese>.

Trong nghiên cứu này, nguồn dữ liệu được sử dụng là bộ song ngữ Anh–Việt được công bố trên nền tảng Kaggle, được trích xuất từ kho ngữ liệu IWSLT15. Bộ dữ liệu được xây dựng dựa trên các bài nói của TED Talks, trong đó mỗi câu tiếng Anh đều có câu tương ứng được dịch sang tiếng Việt và ngược lại. Đây là nguồn tư liệu có chất lượng cao, do TED Talks là diễn đàn chia sẻ kiến thức đa lĩnh vực, bao gồm khoa học, công nghệ, giáo dục, nghệ thuật và kinh tế. Nhờ vậy, ngôn ngữ trong bộ dữ liệu có phạm vi nội dung rộng, đảm bảo sự đa dạng về phong cách diễn đạt và cấu trúc câu.

Bộ dữ liệu huấn luyện bao gồm khoảng 133.000 đến 140.000 cặp câu song ngữ, với văn bản được xử lý ở mức cơ bản trước khi công bố, chẳng hạn như loại bỏ ký tự nhiễu hay chuẩn hóa định dạng. Điều này giúp giảm đáng kể lượng công việc tiền xử lý trong giai đoạn đầu của nghiên cứu. Ngoài tập huấn luyện, bộ dữ liệu còn cung cấp tập kiểm thử độc lập với mục đích đánh giá mô hình trên các câu không xuất hiện trong quá trình học, đảm bảo tính khách quan trong kết quả mô phỏng.

3.2. Phân tích và tiền xử lý dữ liệu

3.2.1. Độ dài trung bình câu





Một trong những đặc trưng quan trọng của dữ liệu là độ dài trung bình câu ở hai ngôn ngữ. Dựa trên kết quả thống kê thể hiện trong biểu đồ, câu tiếng Anh trong tập huấn luyện có độ dài trung bình 20.32 từ, thấp hơn đáng kể so với tiếng Việt với 24.86 từ. Xu hướng này tiếp tục được duy trì trong các tập dữ liệu khác. Cụ thể, trong tập kiểm thử, độ dài trung bình câu tiếng Anh đạt 18.02 từ, trong khi tiếng Việt đạt 22.08 từ. Đối với tập validation, giá trị tương ứng là 21.08 từ cho tiếng Anh và 26.17 từ cho tiếng Việt.

Sự chênh lệch này phản ánh đặc điểm cấu trúc ngôn ngữ của hai hệ thống. Tiếng Anh có xu hướng sử dụng cấu trúc câu ngắn gọn, trong khi tiếng Việt thiên về diễn đạt mở rộng, bao gồm nhiều cụm từ bổ nghĩa. Điều này cho thấy mô hình dịch cần học cách xử lý các câu tiếng Việt dài và chứa nhiều biến thể ngữ nghĩa hơn. Đồng thời, độ dài câu tăng lên cũng làm tăng độ phức tạp trong việc nắm giữ ngữ cảnh dài của mô hình, đặc biệt đối với các kiến trúc Transformer có giới hạn về số lượng token đầu vào.

3.2.2. Từ phổ biến

Top 10 từ phổ biến nhất (loại trừ Stopword) - Tập train






Tần suất từ xuất hiện trong tập dữ liệu phản ánh sự khác biệt đáng kể giữa hai ngôn ngữ. Trong tiếng Anh, các từ xuất hiện nhiều nhất bao gồm “apos”, “you”, “this”, “so” hay “they”. Đây là các từ chức năng (function words) thường xuyên được sử dụng trong cấu trúc câu, nhưng ít đóng góp thông tin ngữ nghĩa nội dung. Việc “apos” xuất hiện với tần suất rất cao là kết quả của quá trình chuẩn hóa ký tự từ dấu nháy (’), xuất hiện nhiều trong các câu hội thoại và diễn văn TED Talks.

Trong tiếng Việt, tần suất từ lại tập trung vào các đại từ, hư từ và các từ quen thuộc trong sinh hoạt thường ngày, chẳng hạn như “chúng”, “không”, “ta”, “bạn” và “người”. Đây đều là các từ có vai trò kết nối giữa các thành phần câu và thể hiện sắc thái giao tiếp tự nhiên của tiếng Việt. Việc các từ này xuất hiện dày đặc phản ánh phong cách diễn đạt trong TED Talks, nơi người nói thường dùng đại từ để giải thích, minh họa hoặc trình bày quan điểm.

Việc phân tích tần suất từ giúp đánh giá sự cân bằng của tập dữ liệu và hỗ trợ việc xây dựng từ điển (vocabulary) tối ưu cho mô hình. Mật độ xuất hiện cao của từ chức năng giúp mô hình học tốt hơn cấu trúc ngữ pháp, trong khi từ nội dung giúp mô hình nắm bắt chủ đề và ngữ nghĩa chính xác hơn.

3.2.3. Độ che phủ từ vựng



Độ che phủ từ vựng phản ánh mức độ mà mô hình có thể nhận diện và xử lý các từ trong tập kiểm thử và validation dựa trên từ điển được tạo ra từ tập huấn luyện. Biểu đồ cho thấy độ che phủ của tiếng Anh đạt mức rất cao, lần lượt là 95.46% ở tập validation và 95.14% ở tập test. Điều này cho thấy tập từ vựng tiếng Anh trong dữ liệu huấn luyện đã mô tả tốt đa số từ trong các tập đánh giá, thể hiện tính nhất quán cao của tiếng Anh trong ngữ liệu TED Talks.

Ngược lại, độ che phủ từ tiếng Việt thấp hơn đáng kể, với 84.57% ở validation và 84.06% ở test. Sự chênh lệch lớn này phần nào phản ánh đặc điểm cấu trúc từ vựng tiếng Việt – một ngôn ngữ đơn lập với nhiều khả năng kết hợp từ, khiến số lượng biến thể xuất hiện trong văn bản tương đối lớn. Điều này đồng thời cho thấy rằng mô hình dịch tiếng Việt cần xử lý nhiều từ ngoại từ điển (OOV – Out of Vocabulary), đòi hỏi kỹ thuật tách từ (tokenization) hiệu quả hoặc sử dụng các phương pháp phân tách subword như Byte-Pair Encoding (BPE) để giảm thiểu hiện tượng này.

Độ che phủ từ thấp hơn ở tiếng Việt cũng có thể ảnh hưởng trực tiếp đến kết quả dịch, đặc biệt trong các câu có cấu trúc phức tạp hoặc chứa các cụm từ ít gặp trong dữ liệu huấn luyện. Do đó, việc tối ưu bước tiền xử lý là cần thiết nhằm thu hẹp khoảng cách này.

3.2.4. Tiền xử lý dữ liệu

Trước khi đưa vào mô hình, dữ liệu được tiến hành tiền xử lý thông qua nhiều bước nhằm đảm bảo tính sạch, tính nhất quán và phù hợp với yêu cầu của mô hình Transformer. Giai đoạn này đóng vai trò đặc biệt quan trọng, bởi chất lượng của dữ liệu đầu vào là yếu tố có ảnh hưởng trực tiếp đến khả năng học của mô hình cũng như độ chính xác của kết quả dịch.

Quá trình đầu tiên là làm sạch văn bản. Ở bước này, những ký tự đặc biệt, dấu câu không hợp lệ, khoảng trắng thừa hoặc các ký hiệu kỹ thuật không liên quan đều được loại bỏ. Văn bản đồng thời được chuẩn hóa theo một định dạng thống nhất thông qua việc chuyển toàn bộ về chữ thường, giúp mô hình giảm bớt số lượng token không cần thiết và duy trì sự đồng nhất về mặt hình thức giữa các mẫu dữ liệu.

Sau khi văn bản đã được làm sạch, hệ thống tiếp tục tiến hành chuẩn hóa dấu câu và khoảng trắng. Việc này giúp mô hình phân biệt rõ ràng các ranh giới câu và từ, từ đó cải thiện khả năng phân tách token và giảm thiểu các mẫu bị hiểu nhầm do lỗi định dạng. Những câu có độ dài bất thường cũng được xem xét và xử lý. Các câu quá dài thường chứa quá nhiều thông tin gây nhiễu cho mô hình, trong khi các câu quá ngắn lại không phản ánh đủ ngữ nghĩa cần thiết. Do đó, những câu này được loại bỏ hoặc điều chỉnh để đảm bảo rằng tập dữ liệu huấn luyện đại diện chính xác cho cấu trúc ngôn ngữ của ngữ liệu gốc.

Một trong những bước quan trọng nhất trong giai đoạn tiền xử lý là tách từ (tokenization). Ở bước này, văn bản được chia thành các đơn vị nhỏ hơn như từ hoặc subword. Tokenization là nền tảng của các mô hình NLP hiện đại, đặc biệt đối với Transformer, do mô hình không xử lý trực tiếp văn bản thô mà làm việc trên chuỗi token đã mã hóa. Việc lựa chọn chiến lược tokenization phù hợp giúp mô hình xử lý hiệu quả những từ ít gặp, giảm thiểu hiện tượng từ ngoài từ điển (OOV) và cải thiện khả năng khái quát hóa trong quá trình huấn luyện.

Nhìn chung, giai đoạn tiền xử lý dữ liệu đảm bảo rằng toàn bộ tập dữ liệu được chuẩn hóa, sạch và có cấu trúc rõ ràng, từ đó tạo điều kiện thuận lợi cho mô hình học được mối quan hệ ngôn ngữ một cách tối ưu.

3.2.5. Chia dữ liệu huấn luyện và kiểm thử

Dữ liệu được chia thành hai phần chính: tập huấn luyện và tập kiểm thử. Tập huấn luyện bao gồm hai file song ngữ train.en và train.vi, với số lượng 134.028 câu cho mỗi ngôn

ngữ. Đây là tập dữ liệu lớn nhất và đóng vai trò cốt lõi trong việc dạy mô hình học cách ánh xạ giữa tiếng Anh và tiếng Việt. Việc hai tập song ngữ có số lượng câu tương đương nhau giúp đảm bảo tính cân bằng và đối xứng trong quá trình huấn luyện, tránh hiện tượng mô hình thiên lệch về một ngôn ngữ nhất định.

Bên cạnh tập huấn luyện, bộ dữ liệu còn bao gồm tập kiểm thử với hai file `tst2012.en` và `tst2012.vi`, mỗi file chứa 1.268 câu. Các câu trong tập kiểm thử hoàn toàn không xuất hiện trong tập huấn luyện, đảm bảo tính khách quan trong việc đánh giá khả năng tổng quát hóa của mô hình. Những câu này thường mang nội dung đa dạng, phản ánh bối cảnh phong phú của các bài nói TED, từ đó cho phép mô hình được kiểm nghiệm trong nhiều tình huống khác nhau, bao gồm các câu dài, câu ngắn, câu chứa thuật ngữ chuyên ngành hoặc câu có cấu trúc ngữ pháp phức tạp.

Tỷ lệ phân chia dữ liệu như vậy bảo đảm rằng mô hình được cung cấp đủ dữ liệu để học nhưng vẫn duy trì một lượng mẫu kiểm thử thích hợp để đánh giá chất lượng. Điều này đặc biệt quan trọng trong các bài toán dịch máy, nơi sự đa dạng ngữ cảnh ảnh hưởng mạnh mẽ đến độ chính xác của mô hình.


CHƯƠNG IV. PHÁT TRIỂN PHƯƠNG ÁN CHO BÀI TOÁN

4.1. Cơ sở lựa chọn hướng tiếp cận và Mô hình

- **Hướng tiếp cận:** Lựa chọn Neural Machine Translation (NMT) với kiến trúc Transformer vì khả năng mô hình hóa ngữ cảnh dài và hiệu suất xử lý song song vượt trội so với RNN truyền thống.
- **Chiến lược:** Sử dụng mô hình Pretrained thay vì huấn luyện từ đầu để đảm bảo độ chính xác tốt ban đầu, tiết kiệm thời gian và phù hợp với mục tiêu học phần (tập trung vào phân tích pipeline).
- **Mô hình được chọn:** **MarianMT** (cụ thể là Helsinki-NLP/opus-mt-en-vi), dựa trên kiến trúc Transformer Encoder–Decoder, được huấn luyện trên tập dữ liệu OPUS, tối ưu cho cặp ngôn ngữ Anh – Việt.

4.2. Mô hình MarianMT

MarianMT thuộc họ mô hình dịch máy **Neural** được phát triển dựa trên kiến trúc Transformer Encoder–Decoder. Mô hình đã được huấn luyện trên tập dữ liệu OPUS – một trong những kho ngữ liệu song ngữ lớn nhất thế giới.



Đặc điểm	Thông số	Ý nghĩa
Kiến trúc	Transformer Encoder–Decoder	Tiêu chuẩn NMT hiện đại.
Số lớp	6 lớp Encoder và Decoder	Đảm bảo khả năng học ngữ cảnh sâu.
Kích thước	512 chiều	Xử lý câu dài và giữ phân bố ngữ nghĩa.
Attention	8 attention heads	Học được nhiều góc nhìn

Tokenizer	SentencePiece BPE	Xử lý hiệu quả từ hiếm, từ ghép,...
------------------	-------------------	-------------------------------------

4.3. Phân tích dữ liệu đầu vào và chiến lược xử lý ngôn ngữ

Dữ liệu đầu vào của bài toán bao gồm các câu tiếng Anh có độ dài và mức độ phức tạp khác nhau. Để chuẩn bị dữ liệu cho mô hình, nhóm áp dụng các bước tiền xử lý mang tính kỹ thuật nhằm đảm bảo sự tương thích với tokenizer của mô hình và giảm nhiễu ngôn ngữ:

1. Chuẩn hóa Unicode tiếng Việt theo chuẩn NFC.
2. Chuẩn hóa chữ thường nhằm giảm độ phân tán của từ vựng.
3. Xử lý dấu câu và ký tự đặc biệt bằng biểu thức chính quy để đảm bảo câu đầu vào “sạch” nhất có thể.
Loại bỏ khoảng trắng thừa và chuẩn hóa định dạng câu.
4. Giới hạn độ dài đầu vào, đảm bảo số token không vượt quá ngưỡng 128 tokens theo kiến trúc mô hình.

Ví dụ:

"Machine translation is challenging."

→ ['_Machine', '_translation', '_is', '_challenging', '.']

4.4. Kiến trúc phương án: Pipeline dịch máy

4.4.1. Mã hóa (Encoding)

Giai đoạn Mã hóa là bước đầu tiên trong Pipeline dịch máy, chịu trách nhiệm chuyển câu tiếng Anh đầu vào thành một biểu diễn ngữ nghĩa giàu thông tin, có thể sử dụng được cho giai đoạn Giải mã.

1. Tokenization (Mã hóa Tiểu từ - Subword)

Câu tiếng Anh đầu vào, sau khi đã **được tiền xử lý** được đưa vào Tokenizer của MarianMT, sử dụng thuật toán Byte-Pair Encoding (BPE) thông qua thư viện SentencePiece.

Lợi ích Kỹ thuật:

- Khắc phục Vấn đề OOV: Giải quyết hiệu quả vấn đề Từ vựng ngoài, mô hình vẫn có thể xử lý và dịch từ hiếm, từ ghép hoặc thuật ngữ mới bằng cách kết hợp các subword phổ biến đã học.
- Cân bằng Voca Size: Giảm đáng kể kích thước từ vựng (Vocabulary Size) so với word-level, giúp mô hình nhỏ gọn và dễ quản lý tài nguyên hơn, đồng thời giữ được ngữ nghĩa cơ bản.

Ví dụ: "unusual" → ['un', '##usual'] (Giả định cách tách)

2. Cơ chế Encoder của Transformer

Các subword token sau đó được chuyển thành chuỗi ID số và đưa vào Encoder của kiến trúc Transformer.

1. Embedding và Positional Encoding:

- Các ID token → Vector Embedding biểu diễn ngữ nghĩa của từng subword.
- Đồng thời, Positional Encoding (Mã hóa Vị trí) được thêm vào các vector này.

2. Quá trình Xử lý của Encoder:

- Các vector được xử lý qua 6 lớp Encoder của MarianMT.
- Trọng tâm của Encoder là Multi-Head Self-Attention. Cơ chế này cho phép mô hình phân tích mối quan hệ ngữ cảnh giữa *tất cả các token trong câu đầu vào với nhau*
- Mỗi đầu attention (8 heads) học một khía cạnh ngữ cảnh khác nhau.

3. Đầu ra của Encoder (Contextual Representation):

- Encoder tạo ra một tập hợp các vector ngữ cảnh. Đây là biểu diễn ngữ nghĩa cuối cùng của câu tiếng Anh.
- Những vector này giữ toàn bộ thông tin về cấu trúc cú pháp, ngữ pháp và sẽ được truyền sang Decoder để bắt đầu quá trình Giải mã.

4.4.2. Giải mã (Decoding) với Beam Search

Giai đoạn Giải mã chịu trách nhiệm chuyển đổi biểu diễn ngữ nghĩa đã được mã hóa từ Encoder thành câu tiếng Việt hoàn chỉnh. Decoder hoạt động theo cơ chế sinh auto-regressive.

1. Cơ chế Hoạt động của Decoder

1. Đầu vào: Decoder nhận hai loại thông tin chính:
 - Vector ngữ cảnh (Context Vectors): Được truyền trực tiếp từ Encoder.
 - Các token đã sinh trước đó: Decoder sử dụng các token tiếng Việt đã được sinh ra trong các bước trước đó làm đầu vào cho bước hiện tại, giúp duy trì tính liên kết và ngữ pháp của câu đích.
2. **Cơ chế Attention trong Decoder:**
 - Masked Self-Attention: Decoder sử dụng cơ chế tự-attention tương tự Encoder, nhưng được masked để đảm bảo một token chỉ chú ý đến các token đã sinh ra trước nó.
 - Encoder-Decoder Attention (Cross-Attention): Đây là cơ chế cốt lõi trong dịch máy. Decoder chú ý đến output của Encoder để quyết định từ nào nên được sinh ra tiếp theo dựa trên ý nghĩa của câu nguồn.
3. **Sinh Token:**
 - Decoder tính toán xác suất cho toàn bộ từ vựng đích và chọn từ có xác suất cao nhất. Quá trình này lặp lại cho đến khi mô hình sinh ra token kết thúc câu (<EOS>).

2. Tối ưu hóa bằng Beam Search

Thay vì chỉ chọn từ có xác suất cao nhất ở mỗi bước (Greedy Search), nhóm sử dụng thuật toán Beam Search để duy trì và đánh giá nhiều chuỗi dịch tiềm năng song song, giúp cải thiện đáng kể chất lượng và độ trôi chảy của bản dịch.

Thông số Beam Search	Giá trị	Ý nghĩa
\$num_beams\$	5	Mô hình sẽ theo dõi 5 chuỗi dịch (beam) tốt nhất ở mỗi bước giải mã, thay vì chỉ 1. Việc này giúp giảm nguy cơ mắc lỗi sớm và tạo ra bản dịch có xác suất tổng thể cao hơn.
\$length_penalty\$	1.0	Một hệ số điều chỉnh để tránh việc mô hình thiên vị các câu dịch quá ngắn hoặc quá dài. Giá trị 1.0 nghĩa là không áp dụng hình phạt độ dài.

\$early_stopping\$	True	Cho phép Beam Search dừng lại ngay khi đã tìm thấy số lượng bản dịch hoàn chỉnh (\$num_beams\$) và không cần tiếp tục mở rộng tất cả các beam còn lại.
---------------------------	------	--

CHƯƠNG V. TRIỂN KHAI VÀ ĐÁNH GIÁ

Sau khi hoàn tất quá trình nghiên cứu lý thuyết, lựa chọn mô hình và huấn luyện, chương này tập trung vào việc hiện thực hóa kết quả nghiên cứu thành một ứng dụng cụ thể và thực hiện các quy trình đánh giá khách quan để đo lường hiệu suất của mô hình.

5.1. Xây dựng Giao diện Demo

Để cung cấp một cái nhìn trực quan và cho phép kiểm thử trực tiếp khả năng dịch thuật của mô hình đã huấn luyện, nhóm đã xây dựng một ứng dụng demo tương tác.

- **Mục tiêu:** Ứng dụng demo được tạo ra nhằm mục đích trực quan hóa kết quả của mô hình dịch máy. Nó cho phép người dùng (bao gồm cả các thành viên nhóm phát triển và giảng viên hướng dẫn) có thể tương tác, nhập dữ liệu đầu vào tùy ý và ngay lập tức nhận được bản dịch, qua đó kiểm chứng được tính ứng dụng thực tế của hệ thống.
- **Công nghệ sử dụng:**
 - Ngôn ngữ lập trình chính là Python, do hệ sinh thái thư viện mạnh mẽ cho khoa học dữ liệu và học máy.
 - Giao diện người dùng (UI) được xây dựng bằng thư viện Gradio. Đây là một lựa chọn tối ưu cho phép tạo nhanh các giao diện web đơn giản, có khả năng tương tác cao cho các mô hình học máy mà không đòi hỏi kiến thức chuyên sâu về phát triển web front-end.
- **Chức năng cốt lõi:**
 - Trái tim của ứng dụng là mô hình MarianMT (một kiến trúc Transformer hiệu quả cao cho dịch máy) đã được tinh chỉnh (fine-tuned) chuyên biệt cho cặp ngôn ngữ Anh-Việt.
 - Giao diện cung cấp hai chức năng dịch song song:
 1. **Dịch Anh - Việt:** Người dùng nhập một câu hoặc đoạn văn bản bằng tiếng Anh vào ô đầu vào, hệ thống sẽ sử dụng mô hình MarianMT và trả về bản dịch tiếng Việt tương ứng.
 2. **Dịch Việt - Anh:** Tương tự, người dùng có thể nhập văn bản tiếng Việt để nhận lại bản dịch tiếng Anh, chứng minh khả năng xử lý song ngữ của mô hình.

5.2.Đánh giá chất lượng mô hình dịch

5.2.1. Đánh giá Định lượng

Phương án dịch máy sử dụng MarianMT được đánh giá định lượng trên tập thử nghiệm (Test Set) bằng ba thước đo tiêu chuẩn trong lĩnh vực Dịch máy Thần kinh (NMT).

Thước đo	Nguyên tắc đánh giá	Kết quả (Test Set)	Nhận định
BLEU	Mức độ trùng khớp N-gram giữa bản dịch mô hình và bản dịch tham chiếu.	35.84	Mức tương đối tốt, phản ánh khả năng tái tạo cụm từ chính xác. (Càng cao càng tốt)
METEOR	Độ khớp từ, stemming và từ đồng nghĩa .	56.52	Cao, cho thấy mô hình nắm bắt tốt khía cạnh ngữ nghĩa và chấp nhận các diễn đạt tương đương. (Càng cao càng tốt)
TER	Số lượng chỉnh sửa tối thiểu để bản dịch mô hình thành bản dịch chuẩn.	52.88	Mức phù hợp, phản ánh mức độ lỗi/chỉnh sửa cần thiết trung bình. (Càng thấp càng tốt)

5.2.2. Đánh giá Định tính

Đánh giá định tính, hay đánh giá cảm quan, là bước quan trọng để đo lường các khía cạnh chất lượng dịch mà các chỉ số tự động như BLEU hay METEOR không thể nắm bắt được

Tiêu chí	Mô tả	Điểm Trung bình	Nhận định
Fluency	Mức độ tự nhiên, mượt mà của tiếng Việt.	4.5/5	Điểm số cao cho thấy bản dịch có độ trôi chảy tốt, đọc lên nghe tự nhiên như văn phong tiếng Việt.
Adequacy	Mức độ giữ đúng nghĩa câu tiếng Anh.	4.0/5	Khả năng bảo toàn ngữ nghĩa tốt, đảm bảo thông tin chính xác được truyền tải.
Grammaticality	Độ chính xác ngữ pháp.	4.7/5	Điểm cao nhất, cho thấy mô hình hiếm khi mắc các lỗi ngữ pháp cơ bản trong tiếng Việt.

5.2.3. Phân tích lỗi

Thông qua quan sát các câu dịch trên tập test, nhóm ghi nhận bốn loại lỗi điển hình:

1. **Sai lệch Thì Động từ:** Mô hình gặp khó khăn khi xử lý các câu phức có **cấu trúc điều kiện** hoặc các câu chứa **trạng từ thời gian** phức tạp, dẫn đến việc dịch sai thì (quá khứ, hiện tại, tương lai) so với ngữ cảnh.
2. **Dịch Sắt Nghĩa Quá Mức (Literal Translation):** Đối với **thành ngữ** (idioms) hoặc **cụm động từ** (phrasal verbs) trong tiếng Anh, mô hình có xu hướng dịch từng từ (word-by-word) thay vì dịch ý nghĩa ẩn dụ hoặc ý nghĩa tổng thể của cụm từ.
3. **Rút gọn Cấu trúc Câu Dài:** Trong các câu tiếng Anh dài và phức tạp, mô hình đôi khi **rút gọn** hoặc **bỏ bớt thành phần câu** (clausal components), khiến sắc thái ngữ nghĩa chi tiết hoặc độ trang trọng của câu bị giảm nhẹ.
4. **Nhầm lẫn Từ Đa Nghĩa (Polysemy):** Lỗi này xảy ra khi mô hình dịch sai từ có nhiều nghĩa (polysemous words), đặc biệt trong **văn phong học thuật** hoặc kỹ thuật, nơi ngữ cảnh đòi hỏi sự lựa chọn từ vựng rất chính xác.

CHƯƠNG VI. TÀI LIỆU THAM KHẢO

- [1] Lam P. T. (2025), *Phenikaa School of Computing: Natural Language Processing Lectures*. Phenikaa University.
- [2] Jurafsky, D., & Martin, J. H. (2021). *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition* (3rd ed.). Pearson.
- [3] Chomsky, N. (2006). *Language and Mind* (3rd ed.). Cambridge University Press.
- [4] Manning, C. D., & Schütze, H. (1999). *Foundations of Statistical Natural Language Processing*. MIT Press.
- [5] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. NAACL-HLT 2019.