



Time Series - Machine learning

Phân tích dữ liệu kinh doanh (Đại Học Quốc Gia Thành Phố Hồ Chí Minh Trường Đại
Hoc Công Nghệ Thông Tin)



messages.pdf_cover_qr_code_label

Dự đoán giá cổ phiếu bằng các model Machine Learning và Deep Learning

First Author¹[0000–1111–2222–3333], Second Author^{2,3}[1111–2222–3333–4444], and Third Author³

University of Information Technology

Tóm tắt nội dung Dự đoán giá cổ phiếu là một bài toán quan trọng trong lĩnh vực tài chính định lượng nhưng cũng gặp nhiều thách thức do đặc tính không dừng, nhiễu cao và phụ thuộc thời gian phức tạp của chuỗi dữ liệu. Trong báo cáo này, chúng tôi nghiên cứu bài toán dự đoán giá cổ phiếu dựa trên chuỗi thời gian lịch sử bằng cách tiếp cận thông qua dự đoán suất sinh lợi (return) thay vì dự đoán trực tiếp giá, nhằm cải thiện tính ổn định của dữ liệu và hiệu quả học của mô hình.

Nghiên cứu tiến hành thực nghiệm trên ba bộ dữ liệu giá cổ phiếu của các công ty công nghệ lớn gồm Apple, Microsoft và Google. Ba nhóm mô hình được xem xét và so sánh bao gồm mạng hồi tiếp LSTM, mô hình học máy XGBoost và mô hình Transformer Encoder dựa trên cơ chế self-attention. Hiệu quả của các mô hình được đánh giá thông qua các chỉ số RMSE, MAE và MAPE trên chuỗi giá sau khi được khôi phục từ return dự đoán.

Kết quả thực nghiệm cho thấy Transformer Encoder có khả năng khai thác tốt hơn các phụ thuộc dài hạn trong chuỗi thời gian so với LSTM, trong khi XGBoost đạt sai số thấp trên một số bộ dữ liệu nhờ khả năng học phi tuyến mạnh. Những kết quả này cho thấy tiềm năng của các mô hình hiện đại trong bài toán dự đoán chuỗi thời gian tài chính và mở ra hướng nghiên cứu sâu hơn cho các kiến trúc dựa trên attention.

Từ khóa: Dự đoán giá cổ phiếu; Chuỗi thời gian; Suất sinh lợi; LSTM; XGBoost; Transformer Encoder.

1 Giới thiệu (Introduction)

Chuỗi thời gian tài chính, đặc biệt là dữ liệu giá cổ phiếu, là một trong những dạng dữ liệu phức tạp và khó dự đoán nhất do mang tính không dừng, nhiễu cao và chịu ảnh hưởng mạnh từ các yếu tố kinh tế – xã hội bên ngoài. Bài toán dự đoán giá cổ phiếu có vai trò quan trọng trong quản lý rủi ro, hỗ trợ ra quyết định đầu tư và xây dựng chiến lược giao dịch tự động.

Trong nghiên cứu này, chúng tôi tiếp cận bài toán dự đoán giá cổ phiếu dưới góc nhìn học máy và học sâu, tập trung vào việc dự đoán **suất sinh lợi (return)** thay vì dự đoán trực tiếp giá. Cách tiếp cận này giúp giảm ảnh hưởng của xu hướng dài hạn và cải thiện khả năng học của mô hình. Ba nhóm mô hình được xem xét bao gồm LSTM, XGBoost và Transformer Encoder. Báo cáo này trình bày chi tiết dữ liệu, phương pháp và kết quả thực nghiệm, trong đó phần Transformer Encoder được trình bày ở mục sau.

2 Nghiên cứu liên quan (Related Work)

Dự đoán chuỗi thời gian tài chính đã được nghiên cứu rộng rãi với nhiều phương pháp khác nhau. Các mô hình thống kê truyền thống như ARIMA hay GARCH có ưu điểm về tính diễn giải nhưng thường không đủ linh hoạt để mô hình hóa các quan hệ phi tuyến phức tạp trong dữ liệu thị trường.

Với sự phát triển của học máy, các mô hình như Support Vector Regression và các phương pháp dựa trên cây quyết định (Random Forest, Gradient Boosting) đã được áp dụng để khai thác các mẫu phi tuyến. Tuy nhiên, các phương pháp này phụ thuộc mạnh vào việc thiết kế đặc trưng và không mô hình hóa trực tiếp cấu trúc chuỗi thời gian.

Trong những năm gần đây, các mô hình học sâu như LSTM và GRU đã chứng minh hiệu quả trong dự đoán chuỗi thời gian nhờ khả năng ghi nhớ thông tin theo thời gian. Dù vậy, các mô hình hồi tiếp vẫn gặp hạn chế trong việc học phụ thuộc dài hạn và khó song song hóa. Điều này thúc đẩy việc áp dụng Transformer và các biến thể dựa trên cơ chế attention cho bài toán dự đoán tài chính.

3 Phương pháp đề xuất (Method)

3.1 Tổng quan dữ liệu và tiền xử lý (Data Overview & Preprocessing)

Nghiên cứu sử dụng ba bộ dữ liệu giá cổ phiếu đại diện cho các công ty công nghệ lớn tại thị trường Mỹ, bao gồm Apple, Microsoft và Google.

- **Apple (AAPL)**: Dữ liệu giá cổ phiếu trong giai đoạn gần đây, bao gồm các cột Open, High, Low, Close và Volume.
- **Microsoft (MSFT)**: Dữ liệu lịch sử giá cổ phiếu với cấu trúc tương tự, phản ánh biến động dài hạn của thị trường.
- **Google (GOOG)**: Dữ liệu giá cổ phiếu kéo dài nhiều năm, cho phép đánh giá khả năng tổng quát hóa của mô hình trên chuỗi thời gian dài.

Tất cả các bộ dữ liệu đều được sắp xếp theo thứ tự thời gian tăng dần và chỉ sử dụng giá đóng cửa (Close) cho bài toán dự đoán. Để giảm tính không dừng của chuỗi giá, dữ liệu được chuyển đổi từ giá sang suất sinh lợi (return) theo công thức:

$$r_t = \frac{P_t - P_{t-1}}{P_{t-1}}, \quad (1)$$

trong đó P_t là giá đóng cửa tại thời điểm t .


Sau khi chuyển đổi, chuỗi return được chuẩn hóa và tổ chức dưới dạng cửa sổ trượt (sliding window) với độ dài L . Tại mỗi thời điểm t , đầu vào của mô hình được biểu diễn bởi:

$$X_t = [r_{t-L+1}, r_{t-L+2}, \dots, r_t], \quad (2)$$

và nhãn tương ứng là r_{t+1} . Tất cả các mô hình trong nghiên cứu đều sử dụng cùng một quy trình tiền xử lý nhằm đảm bảo tính công bằng khi so sánh.

3.2 Các mô hình sử dụng

Encoder Transformer Hình 1 minh họa kiến trúc tổng quát của Transformer Encoder sử dụng trong nghiên cứu này. Mô hình gồm N khối encoder xếp chồng, mỗi khối gồm: (i) Multi-Head Self-Attention, (ii) Feed-Forward Network, kèm residual connection và layer normalization.



Hình 1: Minh họa kiến trúc Transformer Encoder cho dự đoán log-return

Self-Attention và Multi-Head Attention Tại một encoder block, với đầu vào ma trận $\mathbf{Z} \in \mathbb{R}^{L \times d_{model}}$, ta tạo ba phép chiếu:

$$\mathbf{Q} = \mathbf{Z}\mathbf{W}^Q, \quad \mathbf{K} = \mathbf{Z}\mathbf{W}^K, \quad \mathbf{V} = \mathbf{Z}\mathbf{W}^V, \quad (3)$$

với $\mathbf{W}^Q, \mathbf{W}^K, \mathbf{W}^V \in \mathbb{R}^{d_{model} \times d_k}$.

Cơ chế scaled dot-product attention:

$$\text{Attn}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}} \right) \mathbf{V}. \quad (4)$$

Để tăng khả năng biểu diễn, multi-head attention sử dụng H “đầu” attention:

$$\text{head}_h = \text{Attn}(\mathbf{Q}_h, \mathbf{K}_h, \mathbf{V}_h), \quad (5)$$

$$\text{MHA}(\mathbf{Z}) = \text{Concat}(\text{head}_1, \dots, \text{head}_H) \mathbf{W}^O, \quad (6)$$

với $\mathbf{W}^O \in \mathbb{R}^{(H \cdot d_k) \times d_{model}}$.

Feed-Forward Network và chuẩn hóa Sau attention, mô hình dùng FFN theo từng vị trí:

$$\text{FFN}(\mathbf{u}) = \phi(\mathbf{u}\mathbf{W}_1 + \mathbf{b}_1) \mathbf{W}_2 + \mathbf{b}_2, \quad (7)$$

với $\phi(\cdot)$ thường là ReLU hoặc GELU.

Mỗi encoder block được mô tả (dạng Pre-LN phổ biến):

$$\mathbf{Z}' = \mathbf{Z} + \text{Dropout}(\text{MHA}(\text{LN}(\mathbf{Z}))), \quad (8)$$

$$\mathbf{Z}^{new} = \mathbf{Z}' + \text{Dropout}(\text{FFN}(\text{LN}(\mathbf{Z}'))). \quad (9)$$

Tầng dự đoán (Prediction Head) Sau N encoder blocks, ta thu được biểu diễn $\mathbf{Z}^{(N)} \in \mathbb{R}^{L \times d_{model}}$. Có hai cách lấy đặc trưng để dự đoán $\hat{r}_{t+1}$:

(1) **Lấy token cuối:**

$$\mathbf{h}_t = \mathbf{Z}_L^{(N)}, \quad (10)$$

tức vector tại bước thời gian cuối của số.

(2) **Pooling:** trung bình theo thời gian:

$$\mathbf{h}_t = \frac{1}{L} \sum_{i=1}^L \mathbf{Z}_i^{(N)}. \quad (11)$$

Sau đó dự đoán return:

$$\hat{r}_{t+1} = \mathbf{h}_t^\top \mathbf{w}_{out} + b_{out}. \quad (12)$$

Hàm mất mát và chiến lược huấn luyện Mô hình được huấn luyện để tối ưu sai số dự đoán return. Với tập huấn luyện $\mathcal{D}$, dùng MSE:

$$\mathcal{L}(\theta) = \frac{1}{|\mathcal{D}|} \sum_{t \in \mathcal{D}} (r_{t+1} - \hat{r}_{t+1})^2. \quad (13)$$

XGBoost Trong thực nghiệm, chúng tôi sử dụng:

- Early stopping theo loss/metric trên tập validation.
- Dropout trong attention và FFN để giảm overfitting.
- Chuẩn hóa dữ liệu đầu vào (fit trên train, áp dụng cho val/test) nhằm tránh rò rỉ thông tin.

Suy luận (Inference) và chuyển đổi sang giá Ở pha suy luận, với mỗi cửa sổ X_t ta thu được $\hat{r}_{t+1}$. Với dự đoán nhiều bước, có thể dùng chiến lược **recursive forecasting**: đưa $\hat{r}_{t+1}$ vào cửa sổ tiếp theo để dự đoán $\hat{r}_{t+2}$, v.v.

Sau khi có chuỗi return dự đoán, chuyển về giá bằng:

$$\hat{P}_{t+k} = P_t \cdot \exp \left(\sum_{i=1}^k \hat{r}_{t+i} \right). \quad (14)$$

4 Thực nghiệm (Experiments)

4.1 Chỉ số đánh giá

Hiệu quả của các mô hình được đánh giá thông qua các chỉ số phổ biến trong bài toán dự đoán chuỗi thời gian:

- RMSE (Root Mean Squared Error)
- MAE (Mean Absolute Error)
- MAPE (Mean Absolute Percentage Error)

Các chỉ số được tính trên **giá cổ phiếu** sau khi khôi phục từ return dự đoán.

4.2 So sánh kết quả định lượng

Bảng ?? trình bày kết quả so sánh giữa các mô hình trên ba bộ dữ liệu Apple, Microsoft và Google.